



CENTRO DE ESTUDOS E SISTEMAS AVANÇADOS DO RECIFE

CESAR SCHOOL

CURSO DE MESTRADO PROFISSIONAL EM ENGENHARIA DE SOFTWARE

JULIANO SOUZA DE ASSIS

**INTELIGÊNCIA ARTIFICIAL APLICADA À CLASSIFICAÇÃO PREDITIVA DA
CRITICIDADE PROCESSUAL NO TRIBUNAL DE JUSTIÇA DE PERNAMBUCO:
UMA ABORDAGEM COM MACHINE LEARNING E MÉTRICAS COMPOSTAS
PARA APOIO À GESTÃO JUDICIAL**

RECIFE

2026



JULIANO SOUZA DE ASSIS

**INTELIGÊNCIA ARTIFICIAL APLICADA À CLASSIFICAÇÃO PREDITIVA DA
CRITICIDADE PROCESSUAL NO TRIBUNAL DE JUSTIÇA DE PERNAMBUCO:
UMA ABORDAGEM COM MACHINE LEARNING E MÉTRICAS COMPOSTAS
PARA APOIO À GESTÃO JUDICIAL**

Dissertação de Mestrado apresentada ao Programa de Mestrado Profissional em Engenharia de Software do Centro de Estudos e Sistemas Avançados do Recife – CESAR School, como requisito para a obtenção do título de Mestre em Engenharia de Software.

Orientador: Anderson Tenório Sergio.

RECIFE

2026

Permito a reprodução, total ou parcial, deste trabalho por quaisquer meios físicos ou digitais, exclusivamente para fins de estudo e pesquisa, desde que a fonte seja devidamente referenciada.

A848i Assis, Juliano Souza de
Inteligência artificial aplicada à classificação preditiva da criticidade processual no tribunal de justiça de Pernambuco: uma abordagem com machine learning e métricas compostas para apoio à gestão judicial / Juliano Souza de Assis ; orientação Anderson Tenório Sergio. -- Recife : CESAR School, 2026.
122 p.: il.

Dissertação (Mestrado) - Programa de Pós-graduação em Engenharia de Software do Centro de Estudos e Sistemas Avançados do Recife.

1. Jurimetria. 2. Execução fiscal. 3. Criticidade processual. 4. Machine learning. 5. LightGBM. 6. Gestão judicial I.Sergio, Anderson Tenório. II.Simões, Walter Charles Sousa Seiffert. III.Andrade, Rômulo César Dias de. IV. Título.

Catálogo da Publicação na Fonte (CIP)
Centro de Estudos e Sistemas Avançados do Recife - CESAR School
Bibliotecária Ana Clara Amorim, CRB-2145.



JULIANO SOUZA DE ASSIS

**INTELIGÊNCIA ARTIFICIAL APLICADA À CLASSIFICAÇÃO PREDITIVA
DA CRITICIDADE PROCESSUAL NO TRIBUNAL DE JUSTIÇA DE
PERNAMBUCO: UMA ABORDAGEM COM MACHINE LEARNING E MÉTRICAS
COMPOSTAS PARA APOIO À GESTÃO JUDICIAL**

Trabalho aprovado em Recife: **19/06/2026.**

**Professor: Anderson Tenório Sergio
(CESAR SCHOOL)
Orientador.**

**Professor: Walter Charles Sousa Seiffert Simões
(CESAR SCHOOL)
Avaliador Interno.**

**Professor: Rômulo César Dias de Andrade
(UPE)
Avaliador Externo.**

RECIFE
2026

Soli Deo Gloria.

AGRADECIMENTOS

Deo gratias ago, qui per **Jesum Christum** me sustentavit et illuminavit.

RESUMO

A sobrecarga de Execuções Fiscais no Poder Judiciário brasileiro impõe à gestão processual o desafio de priorizar, semanalmente, um volume elevado de processos sob capacidade operacional fixa. No contexto da Diretoria Estadual das Varas de Execução Fiscal, Fazenda Pública e Acidentes de Trabalho (DEFFA) do Tribunal de Justiça de Pernambuco (TJPE), a priorização semanal apoia-se, entre outros critérios, no indicador de inércia processual DIAS_ABERTOS, cujo caráter unidimensional limita a comparação entre processos de diferentes órgãos, tarefas e trajetórias históricas. Diante desse *gap*, esta pesquisa pergunta: como compor um critério de priorização semanal que integre estado atual e risco de curto prazo, preservando o indicador institucional e respeitando a heterogeneidade do acervo? Como resposta, propõe-se e avalia-se o JusCritIA, sistema preditivo de criticidade processual baseado em *machine learning* e aplicado a estudo de caso real na DEFFA/TJPE. A metodologia adota protocolo de validação temporal *walk-forward* com embargo de uma janela semanal, utilizando 12 *snapshots* semanais ordenados por SNAPSHOT_IDX, referentes ao período de agosto a novembro de 2025, abrangendo treinamento, validação, aplicação e verificação. Ao todo, foram processados 4.130.466 registros, dos quais 1.812.419 compuseram a base elegível de treinamento e 817.505 predições fora da amostra foram avaliadas. O núcleo preditivo emprega LightGBM, sem ponderação automática de classes, para predizer a classe futura QOT (Quartil Órgão Tarefa), definida a partir dos quartis de DIAS_ABERTOS por órgão julgador e tarefa, utilizando como features ORGAO_JULGADOR, TAREFA, DIAS_ABERTOS e PCTL_OT. Os resultados indicam estabilidade preditiva fora da amostra, com F1 ponderado médio de 0,8387 e acurácia média de 0,8392 em cinco janelas temporais de teste. Na avaliação operacional, o CRIT_SCORE_% concentrou casos críticos no topo das listas de prioridade, com ganhos de eficiência de até 39,52% em relação à ordenação exclusiva por DIAS_ABERTOS. Como contribuição principal, o JusCritIA transforma probabilidades preditivas em uma régua contínua de priorização semanal, compatível com a capacidade de intervenção disponível e com os princípios de transparência, auditabilidade e governança do Poder Judiciário.

Palavras-chave: jurimetria; execução fiscal; criticidade processual; *machine learning*; LightGBM; gestão judicial.

ABSTRACT

The overload of tax enforcement proceedings in the Brazilian Judiciary imposes on judicial case management the challenge of prioritizing, on a weekly basis, a high volume of cases under fixed operational capacity. Within the State Directorate for Tax Enforcement, Public Treasury, and Occupational Accident Courts (DEFFA) of the Court of Justice of Pernambuco (TJPE), weekly prioritization relies, among other criteria, on the procedural inertia indicator DIAS_ABERTOS, whose unidimensional nature limits comparisons among cases from different adjudicating bodies, tasks, and historical trajectories. Given this gap, this research asks: how can a weekly prioritization criterion be composed to integrate current state and short-term risk, while preserving the institutional indicator and respecting the heterogeneity of the caseload? In response, this study proposes and evaluates JusCritIA, a predictive system for procedural criticality based on machine learning and applied to a real case study at DEFFA/TJPE. The methodology adopts a walk-forward temporal validation protocol with an embargo of one weekly window, using 12 weekly snapshots ordered by SNAPSHOT_IDX, covering the period from August to November 2025 and encompassing training, validation, application, and verification. In total, 4,130,466 records were processed, of which 1,812,419 composed the eligible training base and 817,505 out-of-sample predictions were evaluated. The predictive core employs LightGBM, without automatic class weighting, to predict the future QOT class (Court-Task Quartile), defined from DIAS_ABERTOS quartiles by adjudicating body and task, using ORGAO_JULGADOR, TAREFA, DIAS_ABERTOS, and PCTL_OT as features. The results indicate stable out-of-sample predictive performance, with a mean weighted F1 of 0.8387 and a mean accuracy of 0.8392 across five temporal test windows. In the operational evaluation, CRIT_SCORE_% concentrated critical cases at the top of the priority lists, with efficiency gains of up to 39.52% compared to ordering exclusively by DIAS_ABERTOS. As its main contribution, JusCritIA transforms predictive probabilities into a continuous weekly prioritization scale, compatible with the available intervention capacity and with the principles of transparency, auditability, and governance of the Judiciary.

Keywords: jurimetrics; tax enforcement proceedings; procedural criticality; machine learning; LightGBM; judicial management.

LISTA DE ILUSTRAÇÕES

Quadro 1 Bases, fontes consultadas e estratégias de busca.....	p. 26
Quadro 2 Síntese cruzada dos trabalhos relacionados.....	p. 28
Quadro 3 JusCritIA e os trabalhos relacionados.....	p. 50
Figura 1 Logomarca do JusCritIA.....	p. 62
Figura 2 Arquitetura metodológica com validação temporal.....	p. 65
Quadro 4 Principais componentes técnicos do JusCritIA.....	p. 68
Figura 3 Matriz de confusão, EF Geral.....	p. 96
Figura 4 Matriz de confusão, VEFE Geral.....	p. 97
Figura 5 Matriz de confusão, VEFM Geral.....	p. 98
Figura 6 Matriz de confusão, VEFE Diretoria.....	p. 99
Figura 7 Matriz de confusão, VEFM Gabinete.....	p. 100
Figura 8 Matriz de confusão, VEFE Gabinete.....	p. 100
Figura 9 Dispersão entre DIAS_ABERTOS e CRIT_SCORE_%, EF Geral.....	p. 104
Figura 10 Dispersão entre DIAS_ABERTOS e CRIT_SCORE_%, VEFE Geral..	p. 104
Figura 11 Dispersão entre DIAS_ABERTOS e CRIT_SCORE_%, VEFM Geral.	p. 104

LISTA DE TABELAS

Tabela 1 Distribuição das referências por grupo temático.....	p. 28
Tabela 2 Cargas semanais (12 <i>snapshots</i>).....	p. 84
Tabela 3 Pareamento t e t+1 e pares com rótulo.....	p. 85
Tabela 4 Volumes e filtros aplicados no treinamento do QOT em EF.....	p. 86
Tabela 5 Distribuição do treino efetivo por <i>snapshot</i>	p. 87
Tabela 6 Estrutura da validação cruzada temporal com embargo = 1.....	p. 88
Tabela 7 Desempenho por <i>fold</i> (<i>F1-weighted</i> e acurácia).....	p. 88
Tabela 8 Estatísticas agregadas fora da amostra (<i>Out-of-Fold</i> , OOF).....	p. 89
Tabela 9 <i>Benchmark</i> contextual de métricas em estudos jurídicos com IA.....	p. 89
Tabela 10 Importância dos atributos do modelo QOT.....	p. 93
Tabela 11 Ablação do PCTL_OT.....	p. 94
Tabela 12 Ganho do CRIT_SCORE_% vs. DIAS_ABERTOS.....	p. 106

LISTA DE ABREVIATURAS E SIGLAS

AI: *Artificial Intelligence*, Inteligência Artificial

BI: *Business Intelligence*, Inteligência de Negócios

CNJ: Conselho Nacional de Justiça

DEFFA: Diretoria Estadual das Varas de Execução Fiscal, Fazenda Pública e Acidentes de Trabalho

DSR: *Design Science Research*, Pesquisa em Ciência do *Design*

EF: Execuções Fiscais

EU: *European Union*, União Europeia

F1: *F1 score*, Medida F1

ML: *machine learning*, Aprendizado de Máquina

NPU: Numeração Processual Única

OECD: *Organisation for Economic Co-operation and Development*, Organização para a Cooperação e Desenvolvimento Econômico

OOF: *Out-of-Fold*, Fora da amostra

REFORMS: *Reproducibility and Reporting Standards for machine learning-Based Science*, Padrões de Reprodutibilidade e Relato para Ciência Baseada em Aprendizado de Máquina

STF: Supremo Tribunal Federal

STJ: Superior Tribunal de Justiça

TJPE: Tribunal de Justiça de Pernambuco

TJSP: Tribunal de Justiça de São Paulo

TOP-N: lista dos N processos mais prioritários

TRIPOD+AI: *Transparent Reporting of a multivariable prediction model for Individual Prognosis or Diagnosis plus AI*, Relato transparente de modelo multivariável de predição para prognóstico ou diagnóstico individual com IA

VEFE: Vara de Execução Fiscal Estadual

VEFM: Vara de Execução Fiscal Municipal

Walk-forward: *Walk-forward validation*, protocolo de validação temporal prospectiva com preservação da ordem cronológica

SUMÁRIO

1 INTRODUÇÃO.....	p. 12
1.1 Contexto e motivação institucional.....	p. 12
1.2 Problema de pesquisa.....	p. 14
1.3 Objetivo geral.....	p. 15
1.3.1 Objetivos específicos.....	p. 15
1.4 Contribuições.....	p. 16
1.5 Organização da dissertação.....	p. 18
1.6 Alinhamento às diretrizes do CNJ e à governança de IA.....	p. 19
1.7 Escopo e não escopo.....	p. 19
1.8 Pressupostos, delimitação e encerramento do capítulo.....	p. 21
2 REFERENCIAL TEÓRICO.....	p. 25
2.1 Protocolo de seleção dos trabalhos relacionados.....	p. 25
2.2 Jurimetria, mineração de processos e monitoramento preditivo no Judiciário.....	p. 30
2.2.1 Estatística descritiva, quantis e discretização para o QOT e o CRIT_SCORE_%.....	p. 34
2.3 Inteligência artificial aplicada ao Judiciário brasileiro.....	p. 36
2.4 Monitoramento preditivo de processos e modelos de risco.....	p. 40
2.5 Governança, explicabilidade e restrições operacionais no uso de IA.....	p. 42
2.5.1 Síntese crítica e identificação da lacuna de pesquisa.....	p. 44
2.6 Avaliação preditiva em dados temporais e risco de vazamento de informação.....	p. 51
2.7 Probabilidades preditivas e interpretação de risco.....	p. 54
2.8 Integração entre indicadores tradicionais e estimativas preditivas.....	p. 55
2.9 Limites conceituais e interpretativos do uso de inteligência artificial no Judiciário.....	p. 57
3 METODOLOGIA.....	p. 58
3.1 Natureza da pesquisa.....	p. 58
3.2 Enquadramento metodológico, <i>Design Science Research</i>	p. 60
3.3 Procedimentos metodológicos e operacionalização do artefato.....	p. 61
3.3.1 Justificativa da escolha do LightGBM	p. 63
3.3.2 Arquitetura metodológica.....	p. 65

3.4 Fontes de dados e preparação dos dados.....	p. 68
3.5 Protocolo de validação temporal.....	p. 70
3.6 Métricas de avaliação e leitura operacional.....	p. 72
3.7 Governança, <i>accountability</i> e reprodutibilidade.....	p. 76
3.8 Considerações éticas e limites teóricos.....	p. 79
3.8.1 Riscos de viés, efeitos institucionais e leitura responsável.....	p. 79
3.8.2 Limites de generalização e condições de validade.....	p. 80
4 ARTEFATO E ANÁLISE DOS RESULTADOS.....	p. 81
4.1 Descrição do artefato e do ambiente de execução.....	p. 81
4.1.1 Critérios de avaliação empírica e parâmetros de aceitação.....	p. 83
4.2 Caracterização das cargas analisadas e recortes operacionais.....	p. 84
4.3 Desempenho preditivo global do modelo.....	p. 88
4.3.1 Análise de sensibilidade ao balanceamento de classes.....	p. 92
4.3.2 Importância dos atributos do modelo QOT.....	p. 93
4.3.3 Análise de ablação do PCTL_OT.....	p. 94
4.4 Análise das matrizes de confusão e padrões de erro.....	p. 95
4.5 Relação entre CRIT_SCORE_% e DIAS_ABERTOS, análise de dispersão e eficiência TOP-N.....	p. 101
4.6 Interpretação operacional e estratégia de triagem com capacidade semanal limitada.....	p. 108
4.7 Síntese das evidências à luz dos critérios de avaliação.....	p. 109
5 CONCLUSÕES, CONTRIBUIÇÕES, LIMITAÇÕES E TRABALHOS FUTUROS.....	p. 110
5.1 Síntese dos resultados e resposta à questão de pesquisa.....	p. 110
5.2 Contribuições do trabalho.....	p. 111
5.3 Implicações práticas para a gestão sob capacidade semanal limitada.....	p. 112
5.4 Limitações e controles adotados.....	p. 112
5.5 Trabalhos futuros.....	p. 113
5.6 Considerações finais.....	p. 114
REFERÊNCIAS.....	p. 115

1 INTRODUÇÃO

1.1 Contexto e motivação institucional

A morosidade processual no Judiciário brasileiro constitui desafio central à eficiência e à credibilidade da Justiça. Dados do Conselho Nacional de Justiça (CNJ) indicam que 66,21% das reclamações recebidas pela Ouvidoria em 2024 referem-se à lentidão na tramitação, o que corrobora a percepção de paralisação prolongada de processos e reforça a necessidade de critérios objetivos de priorização (Conselho Nacional de Justiça, 2025a, p. 12).

No âmbito do Tribunal de Justiça de Pernambuco (TJPE), a Resolução n. 505/2023, art. 33, determina que processos sem movimentação processual vertical significativa por período superior a 100 dias sejam submetidos à apreciação da Ouvidoria (Tribunal de Justiça de Pernambuco, 2023, art. 33). Embora o SIMAP (Sistema de Monitoramento e Acompanhamento Processual) esteja em uso, persistem gargalos decorrentes da sobrecarga de casos, da suspensão de feitos e da ausência de critérios preditivos para uma priorização eficiente.

O cenário atual registra 83,8 milhões de processos pendentes, dos quais 22% estão suspensos, e a Justiça Estadual responde por 64,9 milhões, equivalentes a 77% do total (Conselho Nacional de Justiça, 2024, p. 19). As execuções fiscais configuram o principal gargalo, pois concentram 31% dos casos pendentes, sendo 86% na Justiça Estadual e 14% na Justiça Federal, reúnem 59% das execuções em atraso e apresentam taxa de congestionamento de 87,8% (Conselho Nacional de Justiça, 2024, p. 22). Diante disso, no primeiro trimestre de 2025, o tema “morosidade processual” permaneceu no topo das reclamações ao CNJ, somando 60,64% das manifestações (Conselho Nacional de Justiça, 2025b, p. 12).

Neste contexto, iniciativas de jurimetria e mineração de processos passaram a ocupar papel estratégico quando aplicadas com rigor metodológico. Essas abordagens demonstram como transformar logs de movimentações em informação acionável para a gestão, ao medir tempos entre eventos, identificar gargalos e extrair atributos temporais que sustentam análises descritivas e preditivas voltadas à priorização processual (Cruz et al., 2023, p. 99-103).

Na prática cotidiana da Diretoria Estadual das Varas de Execução Fiscal, Fazenda Pública e Acidentes de Trabalho (DEFFA), instalada pela Instrução Normativa TJPE nº 19/2024, objeto desta pesquisa, a priorização do trabalho se dá por recorte semanal estratégico e se apoia em indicadores descritivos de inércia processual. Em particular, processos com maior tempo sem movimentação relevante tendem a receber prioridade, entre outros critérios. Embora útil como indicador operacional, essa leitura é unidimensional e não explicita variações de ritmo entre órgãos, tarefas e trajetórias processuais.

No contexto brasileiro, a literatura recente consolidou a mineração de processos como ferramenta estratégica para gestão judicial, ao extrair de logs processuais indicadores de tempo, gargalos e variações de percurso, apoiando diagnósticos e ações de melhoria contínua nas rotinas forenses. Aplicada aos dados dos tribunais, essa abordagem permite transformar movimentações em informação acionável para priorização e monitoramento, reduzindo ineficiências e dando transparência ao fluxo do trabalho (Lima et al., 2023, p. 39-43).

A literatura internacional aponta fundamentos e práticas de mineração de processos com ênfase tanto em diagnósticos, descoberta e conformidade, quanto em monitoramento preditivo. O *Process Mining Handbook* sistematiza técnicas de pré-processamento de dados, engenharia de atributos temporais e sequenciais e módulos de *predictive process monitoring*, conectando logs de eventos a modelos de aprendizado de máquina (Van der Aalst; Carmona, 2022, p. 320-346).

No presente trabalho, esse enquadramento orienta a construção de uma abordagem integrada para análise da criticidade processual no âmbito da DEFFA/TJPE. A proposta preserva o uso do indicador institucional de tempo em aberto dos processos, representado como DIAS_ABERTOS, e o articula a uma estimativa preditiva orientada à próxima janela semanal de trabalho, produzida a partir de modelos de aprendizado de máquina.

O índice determinístico de eficiência processual (IEP) é apresentado exclusivamente como variável contextual de leitura, derivada de distribuições históricas por órgão e tarefa, sem compor o cálculo do critério preditivo. A abordagem é concebida para apoiar a priorização recorrente de processos em ambiente real de gestão, sob princípios de transparência, rastreabilidade e governança compatíveis

com o uso de inteligência artificial no Poder Judiciário (Conselho Nacional de Justiça, 2020, 2025c).

Do ponto de vista tecnológico, o núcleo preditivo adota o *Light Gradient Boosting Machine (LightGBM)* como algoritmo principal para o modelo QOT (Quartil Órgão Tarefa), escolha amparada por evidência empírica em contexto judicial brasileiro em base de processos eleitorais dos Tribunais Regionais Eleitorais do Nordeste, em que se observaram valores elevados de ajuste para previsão do tempo total processual a partir de atributos de movimentações e de características das unidades judiciárias (Cruz et al., 2023, p. 102).

Este trabalho emprega uma abordagem centrada em dados, baseada em aprendizado de máquina supervisionado, com validação temporal e explicabilidade, com o objetivo de subsidiar o apoio à decisão e a eficiência da triagem processual, por meio de um critério multidimensional de criticidade, utilizado para ordenar prioridades em listas de trabalho semanais compatíveis com a capacidade operacional existente.

1.2 Problema de pesquisa

A criticidade processual na DEFFA/TJPE enfrenta, ao menos, dois desafios centrais: o elevado volume de processos em tramitação e a heterogeneidade das trajetórias processuais. No cenário atual, a priorização baseia-se predominantemente no indicador institucional de inércia, expresso nos dados como processos abertos há determinado número de dias, padronizado no sistema como `DIAS_ABERTOS` e referido, ao longo deste trabalho, como “dias parados”. Esse indicador constitui a régua oficial e disponível, porém unidimensional e de limiar fixo, o que limita a comparação contextual entre processos pertencentes a diferentes órgãos, tarefas e dinâmicas operacionais.

Formula-se, assim, a seguinte questão de pesquisa: **como compor um critério de priorização preventiva, em escala semanal, que integre o estado atual e a tendência de curto prazo, preserve o uso de “dias parados” e respeite a heterogeneidade de classes, tarefas e trajetórias processuais, mantendo aderência às rotinas e metas do Poder Judiciário estadual brasileiro?**

A resposta é operacionalizada pelo JusCritIA, cujo desempenho é avaliado por métricas preditivas e pela comparação de eficiência operacional em relação ao *baseline* institucional DIAS_ABERTOS.

Para ser útil à gestão, a solução precisa operacionalizar a priorização como lista semanal de trabalho por órgão julgador, tarefa, dias parados. Essa lista deve preservar as colunas originais indispensáveis à execução, incluindo um identificador operacional do processo, além de incorporar, como produtos da análise do artefato, as variáveis geradas pelo sistema. Como conjunto mínimo necessário, a lista deve apresentar CRIT_SCORE_%, QOT previsto, “dias parados” e DELTA_IEP_DIAS.

Outras colunas podem ser incluídas como complementares, por exemplo IEP, MEDIA_OT_DIAS, desde que permaneçam secundárias ao núcleo operacional. O objetivo não é substituir o indicador tradicional, mas robustecer sua função, conectando o cenário atual ao risco de criticidade no curto prazo, com entregáveis auditáveis, compatíveis com a capacidade de intervenção disponível.

Dentre esses elementos, “dias parados” constitui o indicador institucional já adotado pela DEFFA/TJPE, enquanto as métricas de cobertura de casos críticos, desempenho preditivo e ordenação por CRIT_SCORE_% são propostas, avaliadas e discutidas no âmbito deste trabalho.

1.3 Objetivo geral

Construir e avaliar o JusCritIA, um sistema preditivo de criticidade processual para a DEFFA/TJPE, capaz de apoiar a priorização semanal de Execuções Fiscais por meio do critério composto CRIT_SCORE_%, derivado de modelo de *machine learning* com validação temporal, em conformidade com as diretrizes de governança do Poder Judiciário.

1.3.1 Objetivos específicos

1. Identificar, a partir do estado da arte em jurimetria preditiva, mineração de processos e *machine learning* aplicado ao Judiciário, a lacuna que fundamenta o design do JusCritIA e justifica as escolhas metodológicas adotadas.

2. Definir a arquitetura metodológica e computacional do JusCritIA, contemplando a preparação dos dados processuais, a construção das variáveis preditivas, a modelagem do classificador QOT e os critérios de governança compatíveis com as diretrizes do CNJ.
3. Implementar e experimentar o artefato no estudo de caso da DEFFA/TJPE, utilizando 12 *snapshots* semanais de Execuções Fiscais com protocolo de validação temporal *walk-forward* e embargo igual a 1, produzindo listas operacionais de priorização ordenadas pelo CRIT_SCORE_%.
4. Avaliar o desempenho preditivo e a utilidade operacional do JusCritIA por meio de acurácia, F1 ponderado, matrizes de confusão e comparação do ganho de eficiência das listas TOP-N ordenadas por CRIT_SCORE_% em relação ao *baseline* institucional DIAS_ABERTOS, sob capacidade semanal limitada.

1.4 Contribuições

Contribuição 1. Definição do CRIT_SCORE_% como critério de priorização multidimensional orientado a risco.

A principal contribuição desta pesquisa consiste na definição, operacionalização e avaliação do CRIT_SCORE_%, um critério contínuo de priorização de processos orientado à estimativa de risco de permanência prolongada em estados críticos de tempo em aberto. O CRIT_SCORE_% é derivado das probabilidades preditivas produzidas pelo modelo de classificação de quartis futuros de tempo em aberto (QOT) e definido pela expressão $CRIT_SCORE_ \% = (P_QOT4 + 0,6 \times P_QOT3) \times 100$, a qual enfatiza a identificação de processos com maior probabilidade de integração aos quartis superiores. Esse critério supera a limitação da régua fixa baseada exclusivamente no tempo decorrido desde o último evento, preservando o uso do indicador institucional de dias abertos como *baseline* e incorporando uma dimensão preditiva contextual. O CRIT_SCORE_% é concebido explicitamente como instrumento de suporte à decisão gerencial e triagem semanal, sem pretensão de inferência causal ou de mensuração direta de redução de estoque processual.

Contribuição 2. Artefato analítico integrado para priorização recorrente.

Como materialização do critério proposto, o trabalho entrega um artefato analítico que preserva todas as colunas originais das cargas institucionais e acrescenta variáveis geradas pelo sistema, incluindo DIAS_ABERTOS, PCTL_OT, IEP (determinístico), DELTA_IEP_DIAS, QOT_PRED, P_QOT12, P_QOT3, P_QOT4 e CRIT_SCORE_%. Para fins operacionais e de anonimização, as listas TOP-N destinadas ao consumo gerencial incluem exclusivamente as colunas geradas pelo sistema. O artefato apresenta regras de cálculo e pesos explicitamente documentados, garantindo reprodutibilidade e auditabilidade da versão avaliada na pesquisa.

Contribuição 3. Protocolo de avaliação orientado à prática institucional.

A pesquisa propõe um protocolo de avaliação que combina métricas globais de desempenho preditivo (acurácia e *F1-weighted* sob validação temporal *walk-forward*) com análises descritivas estratificadas por órgão julgador e tarefa. A avaliação examina a coerência entre QOT_PRED, que por sua vez indica a classe predita pelo modelo QOT para o quartil futuro de tempo em aberto do processo, considerando a próxima janela temporal, com as classes agregadas conforme o mapeamento operacional adotado (QOT1 e QOT2 agrupados, QOT3 e QOT4), as probabilidades associadas aos quartis críticos e a distribuição observada de dias abertos, verificando a estabilidade das matrizes de confusão e das faixas de risco ao longo de janelas sucessivas. Essa abordagem prioriza a utilidade operacional e a interpretabilidade gerencial das saídas do modelo, assegurando métricas diretamente acionáveis na rotina de triagem semanal.

Contribuição 4. Enquadramento institucional e rigor metodológico.

A solução é desenvolvida em conformidade com diretrizes nacionais de governança e uso responsável de inteligência artificial no Poder Judiciário, adotando princípios de minimização de dados, ausência de dados sensíveis e documentação explícita da configuração do modelo avaliado. A escolha do *LightGBM* é justificada por critérios de eficiência computacional, consumo de memória e desempenho em dados tabulares, com experimentos conduzidos em ambiente local, fora da rede institucional, como medida adicional de preservação do sigilo dos dados. Transparência, rastreabilidade e possibilidade de auditoria são tratadas como requisitos de projeto.

1.5 Organização da dissertação

A dissertação está organizada de modo a conduzir o leitor do contexto institucional e do problema de pesquisa até a apresentação da solução proposta, a análise dos resultados e as considerações finais, preservando encadeamento lógico, clareza expositiva e rastreabilidade ao longo do texto.

O **Capítulo 1. Introdução** apresenta o contexto institucional que motiva o estudo, com base em dados oficiais do Conselho Nacional de Justiça, formula o problema de pesquisa, define o objetivo geral e os objetivos específicos, sintetiza as contribuições do estudo e situa a pesquisa no marco normativo e estratégico do Poder Judiciário.

O **Capítulo 2. Referencial Teórico** revisa a literatura recente, com foco no período de 2020 a 2025 e complementado por obras de referência metodológica e conceitual de anos anteriores, abordando jurimetria aplicada ao Judiciário, mineração de processos, monitoramento preditivo de processos, modelos de aprendizado de máquina para dados tabulares e aspectos de validação, explicabilidade e governança. O capítulo encerra com uma síntese crítica que explicita a lacuna científica e aplicada endereçada por este trabalho.

O **Capítulo 3. Metodologia** descreve o tipo e a abordagem da pesquisa, detalha o enquadramento metodológico adotado, caracteriza os dados e o recorte empírico, apresenta os procedimentos de preparação dos dados, a construção das variáveis, a modelagem preditiva, o protocolo de validação temporal, as métricas utilizadas e os mecanismos de governança e reprodutibilidade do sistema proposto.

O **Capítulo 4. Artefato e Análise dos Resultados** apresenta o sistema desenvolvido e analisa os resultados obtidos a partir de sua aplicação no contexto da DEFFA/TJPE. O capítulo integra, em um único eixo, a descrição da solução implementada e a análise empírica dos resultados, incluindo a avaliação do desempenho do modelo, a interpretação das saídas geradas e a discussão dos achados à luz dos objetivos e critérios de avaliação formulados.

O **Capítulo 5. Conclusões, Contribuições, Limitações e Trabalhos Futuros** sintetiza as contribuições da pesquisa, discute suas implicações para a gestão pública e para o uso de inteligência artificial no Poder Judiciário, explicita as limitações do estudo e aponta direções para trabalhos futuros.

1.6 Alinhamento às diretrizes do CNJ e à governança de IA

O JusCritIA foi concebido em conformidade com o marco normativo do Poder Judiciário brasileiro, dialogando diretamente com a Resolução CNJ n. 325/2020, que institui a Estratégia Nacional do Poder Judiciário e enfatiza a gestão orientada a dados, e com a Resolução CNJ n. 615/2025, que disciplina o desenvolvimento, a utilização e a governança de soluções baseadas em inteligência artificial no Judiciário.

No plano institucional, o sistema observa a Resolução TJPE n. 505/2023, que estabelece o dever de monitoramento de processos sem movimentação relevante por período superior a 100 dias nas matérias de execução fiscal, fazenda pública e acidentes de trabalho.

Em consonância com essas diretrizes, o sistema foi concebido exclusivamente como instrumento de apoio à decisão gerencial, sem qualquer automatização de atos decisórios ou de mérito processual. A interpretação humana é mantida como instância final de deliberação e o CRIT_SCORE_% opera como critério de ordenação e triagem, não como mecanismo substitutivo do julgamento institucional.

Os aspectos técnicos de governança, reprodutibilidade, *accountability* e considerações éticas são detalhados nas seções 3.7 e 3.8, onde estão integrados ao enquadramento metodológico adotado.

1.7 Escopo e não escopo

Este trabalho tem como escopo o desenvolvimento e a avaliação de um sistema de apoio à gestão processual, denominado JusCritIA, voltado à triagem e priorização semanal de processos de Execução Fiscal, com base em dados processuais estruturados.

O sistema atua como um radar operacional. Seu objetivo é estimar o risco relativo de aumento de criticidade de cada processo no ciclo seguinte de análise, correspondente ao próximo *snapshot* semanal. A partir dessa estimativa, são geradas listas ordenadas (TOP-N) para apoiar a alocação da força de trabalho disponível em cada período.

O JusCritIA não realiza decisão judicial, não analisa mérito processual e não substitui a atuação de magistrados, servidores ou gestores. Tampouco propõe automatização de atos decisórios. Seu papel restringe-se ao apoio informacional à gestão, por meio da priorização baseada em risco preditivo.

O sistema também não tem como objetivo modelar trajetórias processuais de longo prazo nem prever desfechos finais dos processos. Todas as análises, previsões e recomendações são formuladas exclusivamente no horizonte semanal, em consonância com a periodicidade das cargas de dados utilizadas e com a dinâmica operacional observada no contexto estudado.

Do ponto de vista metodológico, o trabalho não busca estabelecer relações causais entre variáveis processuais. A abordagem adotada limita-se à identificação de padrões associativos com capacidade preditiva mensurável, avaliados por meio de técnicas de validação temporal apropriadas.

A escolha do horizonte de previsão semanal está alinhada ao *modus operandi* atualmente adotado pela DEFFA/TJPE. Nessa conjuntura, a gestão do acervo e a alocação da força de trabalho são realizadas em ciclos semanais, com apoio de *dashboards* utilizados rotineiramente no suporte à tomada de decisão.

No mesmo sentido, a saída do modelo preditivo foi estruturada de forma compatível com a classificação de criticidade já utilizada na prática institucional. Atualmente, processos com até 49 dias são considerados saneados, aqueles entre 50 e 99 dias são tratados como pré-críticos, processos com 100 dias ou mais são classificados como críticos, classificação já incorporada em painéis de controle utilizados pela gestão. Para manter alinhamento paralelo com essa leitura por faixas, as saídas do modelo QOT foram organizadas por discretização em três categorias operacionais, QOT1+QOT2, QOT3, QOT4, o que preserva a interpretação gerencial do risco no horizonte semanal sem converter as faixas de dias em regra do modelo.

A modelagem proposta neste trabalho realiza, portanto, um agrupamento das classes QOT originalmente definidas em quatro quartis relativos (QOT1 a QOT4) em três categorias operacionais, a saber, QOT1+QOT2, QOT3 e QOT4. Esse agrupamento visa alinhar a saída do modelo ao padrão de leitura já adotado pela DEFFA, ao mesmo tempo em que fornece base adequada para a definição de um critério contínuo de priorização operacional, derivado das probabilidades preditas pelo modelo operacional, apresentado nos capítulos seguintes.

1.8 Pressupostos, delimitação e encerramento do capítulo

A aplicação do JusCritIA parte de pressupostos mínimos relacionados à qualidade, consistência e estabilidade dos dados processuais utilizados. O sistema assume que as informações extraídas dos sistemas judiciais refletem, de forma suficientemente fiel, o estado dos processos em cada *snapshot* semanal. Um pressuposto central do modelo é a estabilidade operacional das classificações de órgão julgador e tarefa ao longo do tempo. Alterações estruturais nessas classificações, como mudanças de nomenclatura ou redefinição de fluxos sem histórico compatível, podem introduzir ruído e afetar a capacidade preditiva do modelo.

O funcionamento do sistema também pressupõe regularidade na periodicidade das cargas semanais. A validação temporal e a definição do horizonte de previsão estão diretamente associadas a essa cadência. Quebras na sequência temporal, atrasos prolongados ou variações abruptas no intervalo entre *snapshots* podem comprometer a coerência das estimativas. Do ponto de vista metodológico, o modelo opera com capacidade de generalização limitada ao curto prazo, correspondente ao ciclo semanal analisado, sem pressupor estabilidade estrutural de longo prazo nem invariância completa do comportamento processual ao longo do tempo.

Entre os riscos identificados, a presença de ruído nos registros processuais merece atenção especial, decorrente de inconsistências no lançamento de tarefas, atrasos operacionais ou variações na forma de registro entre unidades, fatores que podem impactar tanto o cálculo das variáveis de entrada quanto a definição das classes relativas de criticidade. O desempenho do sistema está condicionado à manutenção das condições institucionais observadas durante o período de treinamento e validação, sendo recomendável o monitoramento contínuo do modelo e a reavaliação periódica de seus resultados à medida que o contexto operacional evolui.

No interior dessa delimitação, também se explicitam os elementos que sustentam a pertinência da proposta, sua contribuição específica e a forma de

avaliação adotada para verificar sua utilidade no contexto estudado. A originalidade deste trabalho não reside na proposição de um novo algoritmo de aprendizado de máquina, mas na integração de um sistema preditivo operacionalmente viável ao contexto real da gestão das Execuções Fiscais, com validação empírica baseada em dados históricos e restrições institucionais concretas.

O JusCritIA combina técnicas consolidadas de aprendizado supervisionado com um *pipeline* de dados orientado à realidade do Judiciário, incorporando validação temporal compatível com a natureza sequencial dos dados processuais. Do ponto de vista metodológico, a relevância do trabalho está na construção do CRIT_SCORE_%, critério contínuo de priorização operacional derivado de probabilidades preditivas, que permite ordenar processos segundo o risco relativo de aumento de criticidade no curto prazo, superando a limitação de abordagens baseadas exclusivamente em indicadores acumulativos. No plano institucional, o sistema não substitui práticas consolidadas na DEFFA/TJPE, mas as complementa com uma dimensão preditiva que amplia a eficiência da triagem e da alocação da força de trabalho.

A avaliação do JusCritIA é estruturada a partir de evidências empíricas complementares, organizadas para distinguir a qualidade preditiva, o comportamento em diferentes contextos operacionais e o impacto prático da priorização. O desempenho preditivo é apresentado de forma global por meio de métricas agregadas, incluindo acurácia e F1 ponderado, com o desvio padrão entre *folds* como medida complementar de estabilidade temporal, e aprofundado pela análise das matrizes de confusão por recorte operacional, que explicita a distribuição dos erros entre classes e seus impactos práticos na triagem.

Os recortes contemplam EF Geral, VEFE e VEFM, com estratificações por LOCAL_TAREFA. O impacto operacional é avaliado por tabelas de eficiência de triagem baseadas em listas TOP-N, nas quais a ordenação por CRIT_SCORE_% é comparada à ordenação por DIAS_ABERTOS sob diferentes capacidades semanais, detalhadas no Capítulo 4.

Para garantir precisão conceitual e evitar ambiguidades, apresentam-se as definições dos principais termos utilizados no trabalho, conforme seu significado operacional no sistema JusCritIA.

Execuções Fiscais (EF). Conjunto de processos judiciais incluídos na análise exclusivamente quando a classe processual corresponde a Execução Fiscal, conforme critério de filtragem implementado no sistema.

Execuções Fiscais Estaduais (VEFE). Recorte das Execuções Fiscais composto pelos processos vinculados a unidades jurisdicionais com competência em Execução Fiscal Estadual, segundo a classificação institucional utilizada no sistema.

Execuções Fiscais Municipais (VEFM). Recorte das Execuções Fiscais composto pelos processos vinculados a unidades jurisdicionais com competência em Execução Fiscal Municipal, segundo a classificação institucional utilizada no sistema.

NPU (Numeração Processual Única). Identificador canônico do processo utilizado para vinculação entre registros e para pareamento do mesmo processo entre *snapshots* consecutivos.

Snapshot. Carga periódica de dados processuais correspondente a um instante temporal específico. No presente trabalho, os *snapshots* possuem periodicidade semanal.

Horizonte temporal semanal. Intervalo entre o *snapshot* corrente (t) e o *snapshot* imediatamente subsequente ($t+1$), que define o período de referência das previsões realizadas pelo sistema.

QOT_FIXO. Quartil numérico determinístico, com valores inteiros de 1 a 4, calculado no *snapshot* corrente a partir da distribuição do indicador DIAS_ABERTOS no grupo órgão julgador e tarefa. É utilizado internamente no processamento como base para a categorização do quartil atual.

QOT. Representação categórica do quartil atual do processo no *snapshot* corrente, derivada do QOT_FIXO, assumindo os valores QOT1, QOT2, QOT3 e QOT4. Este é o campo canônico exportado e utilizado nas análises descritivas e empíricas.

QOT_FUTURO. Classe de quartil atribuída ao processo no *snapshot* subsequente ($t+1$), utilizada como variável alvo no treinamento e na validação temporal, construída por pareamento do mesmo processo entre *snapshots* consecutivos.

QOT_PRED. Classe predita para o processo no horizonte temporal semanal subsequente, resultante da aplicação do classificador temporal, expressa nas categorias QOT1+QOT2, QOT3 ou QOT4.

Probabilidades preditas (P_QOT12, P_QOT3, P_QOT4). Estimativas probabilísticas associadas a cada classe predita, utilizadas como base para a priorização contínua dos processos.

CRIT_SCORE_% (Critério Contínuo de Priorização Operacional). Critério contínuo de ordenação dos processos, calculado a partir da combinação ponderada das probabilidades P_QOT3 e P_QOT4, utilizado exclusivamente para triagem e priorização operacional semanal.

DIAS_ABERTOS. Indicador descritivo que representa o número de dias transcorridos desde a data de entrada do processo na tarefa atual até o *snapshot* corrente, refletindo o tempo de permanência do processo nessa tarefa no estado observado no momento da carga.

PCTL_OT. Percentil relativo do processo dentro do seu grupo órgão julgador e tarefa no *snapshot* corrente, calculado com base na posição do DIAS_ABERTOS na distribuição do grupo.

MEDIA_OT_DIAS. Valor médio histórico do indicador DIAS_ABERTOS para o grupo órgão julgador e tarefa, utilizado como referência agregada de comportamento processual.

DELTA_IEP_DIAS. Diferença entre o estado atual do processo e a média histórica do seu grupo operacional, expressa em dias, utilizada como medida de desvio relativo.

Validação temporal com embargo. Procedimento de avaliação que respeita a ordem temporal dos *snapshots*, com exclusão de um intervalo intermediário entre os conjuntos de treino e teste, com o objetivo de reduzir dependência temporal artificial.

Lista TOP-N. Lista ordenada dos N processos com maior prioridade segundo um critério de ordenação específico, utilizada para simular a alocação semanal da força de trabalho disponível.

Este capítulo apresentou a contextualização do problema, os objetivos do trabalho e a delimitação conceitual necessária para a correta compreensão da solução proposta. Foram definidos, de forma explícita, os termos operacionais utilizados ao

longo da dissertação, sempre em consonância com a implementação efetiva do sistema JusCritIA e com os dados processuais analisados.

A delimitação terminológica estabelecida assegura consistência entre o arcabouço conceitual, o método adotado e os resultados empíricos apresentados nos capítulos subsequentes, evitando ambiguidades interpretativas e garantindo rastreabilidade entre texto, código, logs e artefatos gerados.

Encerrada essa etapa introdutória, o capítulo seguinte apresenta o referencial teórico que fundamenta esta pesquisa, incluindo o protocolo de seleção dos trabalhos relacionados, situando a aplicação de jurimetria, mineração de processos e modelos preditivos no contexto do Poder Judiciário, bem como explicitando a lacuna científica e aplicada endereçada pelo sistema JusCritIA.

2 REFERENCIAL TEÓRICO

2.1 Protocolo de seleção dos trabalhos relacionados

A seleção das referências que fundamentam este trabalho seguiu um protocolo estruturado de busca, triagem e organização temática, com o objetivo de assegurar cobertura adequada do estado da arte, transparência na construção do referencial teórico e aderência direta ao problema investigado.

As buscas foram realizadas em mecanismo de busca ampla, portais científicos, bibliotecas digitais, periódicos eletrônicos especializados e fontes institucionais diretamente relacionadas ao tema, incluindo *Google Scholar*, *Springer Link*, *PLOS ONE*, *Frontiers*, MDPI, *ACM Digital Library*, Conselho Nacional de Justiça (CNJ), Tribunal de Justiça de Pernambuco (TJPE), FGV Justiça, *Organisation for Economic Co-operation and Development* (OECD) e EUR-Lex. Também foram utilizados, por acesso direto, periódicos, repositórios e bibliotecas científicas especializados constantes do corpus final, como BMJ, *PeerJ*, *Wiley Online Library*, *Science Advances*, *AIS eLibrary*, *CEUR Workshop Proceedings*, Computação Brasil/SBC, *OTexts*, IJACSA, SCIRP e periódicos acessados por DOI.

Para artigos empíricos, *surveys* e revisões de literatura, adotou-se como cobertura prioritária o período de 2020 a 2025, por corresponder ao estado recente da

produção científica em jurimetria, mineração de processos, monitoramento preditivo, governança de IA, avaliação temporal de modelos e reporte transparente de estudos baseados em aprendizado de máquina.

Não se aplicou restrição temporal rígida a obras de fundamentação metodológica, conceitual, estatística ou normativa, nem a trabalhos fundacionais diretamente necessários à sustentação do método, do artefato ou do contexto institucional analisado. Nessa condição, foram mantidas referências anteriores ao recorte prioritário quando indispensáveis à compreensão do problema ou à justificativa das escolhas metodológicas adotadas, como Hevner et al. (2004), Francischini e Francischini (2015), Provost e Fawcett (2016), Severino (2016), Ke et al. (2017), Knafllic (2018) e Turban, Sharda e Delen (2019). Adicionalmente, incluiu-se Sobrino et al. (2026), por constituir referência contemporânea e semanticamente próxima ao problema investigado, ao abordar priorização operacional semanal por listas ranqueadas em contexto de backlog e capacidade institucional limitada.

As estratégias de busca combinaram termos em português e inglês, organizados por eixo temático, contemplando jurimetria, mineração de processos, monitoramento preditivo, aprendizado de máquina em dados tabulares, validação temporal, *forecasting*, governança de IA no setor público, explicabilidade, *accountability*, métricas de avaliação, reporte de modelos e *Design Science Research*. O Quadro 1 apresenta as bases e fontes consultadas, bem como exemplos das estratégias de busca e navegação adotadas.

Quadro 1 Bases, fontes consultadas e estratégias de busca

Base / fonte	Finalidade principal	Exemplos de estratégias de busca / navegação
Google Scholar	Busca ampla e exploração inicial do estado da arte	“jurimetria”; “mineração de processos judiciário”; “process mining judiciary”; “ <i>predictive process monitoring</i> ”; “judicial AI governance”
Springer Link	Artigos e capítulos sobre IA, Judiciário, processo, avaliação temporal e process mining	“ <i>predictive process monitoring</i> ”; “future research directions process science”; “time series <i>forecasting</i> evaluation”; “good governance public sector AI”
PLOS ONE	Artigos empíricos com aplicação de ML em contexto jurídico e preditivo	“bias in adjudication artificial intelligence”; “predict outcomes of legal appeals Brazilian federal courts”; “predicting the number of days in court cases”; “judges versus artificial intelligence juror decision-making”
Frontiers	Estudos sobre IA, transparência, <i>accountability</i>	“transparency <i>accountability</i> AI systems”; “Evaluating AI decision tools Ecuador courts”

Base / fonte	Finalidade principal	Exemplos de estratégias de busca / navegação
	e aplicações judiciais	
MDPI	Estudos sobre <i>forecasting</i> , <i>data leakage</i> e monitoramento preditivo sob incerteza	“ <i>machine learning</i> methods time series prediction”; “ <i>data leakage</i> feature selection <i>machine learning</i> performance”; “predictive monitoring business processes uncertainty”
ACM Digital Library	Trabalhos em anais e publicações sobre IA e Direito	“process mining-enabled jurimetrics Brazilian court”; “AI and Law conference proceedings”
Periódicos, bibliotecas e repositórios científicos de acesso direto	Recuperação complementar de estudos específicos do corpus final	“TRIPOD+AI”; “predicting Brazilian court decisions”; “reproducibility machine-learning-based research”; “Karl Popper jurimetrics”; “MSD-Splitting C4.5 decision tree”; “VICTOR Brazilian legal documents classification”; “weighted F1 legal document classification”; “hybrid <i>machine learning</i> case delays durations lower courts”; “weighted F1 imbalanced multiclass tree-based ensemble classification”
CNJ	Normas, relatórios e diretrizes institucionais	navegação direta por resoluções, relatórios “Justiça em Números”, relatórios trimestrais da Ouvidoria e documentos sobre governança de IA
TJPE	Normas e documentos institucionais do contexto empírico estudado	navegação direta por resoluções, instruções normativas e documentos institucionais relacionados à DEFFA e ao monitoramento processual
FGV Justiça	Estudos aplicados sobre IA no Judiciário brasileiro	navegação direta por publicações da FGV Justiça
OECD	Diretrizes internacionais de governança e IA no setor público	“governing with artificial intelligence public sector”; “AI public sector <i>accountability</i> ”; “judicial AI governance”
EUR-Lex	Regulação europeia aplicável ao uso de IA em contextos de alto risco	“Artificial Intelligence Act”; “high-risk AI systems judiciary”; “EU AI regulation public sector”

Fonte: Elaborada pelo autor a partir das bases e estratégias efetivamente refletidas no corpus final.

Os critérios de inclusão adotados foram: estudos empíricos com dados processuais reais ou com aderência direta ao contexto judicial; revisões, surveys, handbooks, livros e obras metodológicas capazes de sustentar escolhas conceituais, estatísticas ou computacionais do trabalho; documentos institucionais e normativos diretamente relacionados ao uso de IA, governança, gestão judicial e monitoramento processual; e trabalhos em anais e relatórios técnicos diretamente pertinentes ao problema investigado.

Os critérios de exclusão foram: artigos empíricos sem aderência ao problema de gestão, priorização, monitoramento preditivo ou governança no Judiciário; trabalhos centrados exclusivamente em predição de mérito ou resultado judicial sem

conexão com triagem, classificação, duração processual ou apoio à gestão; estudos sem detalhamento metodológico mínimo ou sem relação direta com as decisões de projeto desta pesquisa; e referências redundantes em relação a outras mais completas, atuais ou diretamente alinhadas ao escopo do trabalho.

Ao final do processo de triagem, foram selecionadas 65 referências, distribuídas em sete grupos temáticos, conforme a Tabela 1.

Tabela 1 Distribuição das referências por grupo temático

Grupo temático	Referências
Jurimetria, mineração de processos e aplicações judiciais no Brasil	9
Process mining e monitoramento preditivo, internacional	7
IA no Judiciário, governança, adoção e <i>accountability</i>	12
Validação temporal, <i>forecasting</i> e <i>machine learning</i>	10
Métricas, explicabilidade, reporte e reprodutibilidade	9
Documentos institucionais e normativos	8
Obras de fundamentação metodológica, estatística, analítica e conceitual	10
Total	65

Fonte: Elaborada pelo autor a partir das referências selecionadas.

O Quadro 2 apresenta a síntese cruzada das principais referências mobilizadas no referencial teórico, indicando contexto, método principal e contribuição para esta pesquisa.

Quadro 2 Síntese cruzada dos trabalhos relacionados

Referência	Contexto	Método principal	Contribuição para esta pesquisa
Cruz et al. (2023)	TREs Nordeste, Brasil	LightGBM, mineração de processos	Justifica o uso do LightGBM em contexto judicial brasileiro e o emprego de atributos processuais derivados
Verçosa et al. (2024)	Processos judiciais, Brasil	ML e <i>process mining</i>	Valida a combinação de ML com atributos processuais em estudo de duração
Lima et al. (2023)	Judiciário brasileiro	Mineração de processos	Fundamenta extração de atributos de logs processuais
Lage-Freitas et al. (2022)	Tribunais brasileiros	ML para decisões judiciais	Contextualiza ML preditivo no Judiciário brasileiro
Menezes-Neto; Clementino (2022)	Justiça Federal, Brasil	<i>Deep learning</i>	Referência de predição em dados judiciais brasileiros
Oliveira et al. (2022)	Tribunais brasileiros	ML para duração de processos	Referência de predição de tempo processual
Resck et al. (2025)	STF, Brasil	Classificação temática com explicações visuais	Contextualiza IA aplicada à triagem judicial e à explicabilidade

Referência	Contexto	Método principal	Contribuição para esta pesquisa
Ceravolo et al. (2024)	Internacional	<i>Survey de predictive process monitoring</i>	Define o campo do monitoramento preditivo de processos
Bousdenkis et al. (2023)	Internacional	<i>Predictive monitoring</i> sob incerteza	Reforça limites e desafios do monitoramento preditivo em cenários incertos
Van der Aalst; Carmona (2022)	Internacional	<i>Handbook de process mining</i>	Base conceitual de mineração de processos
Unger et al. (2021)	TJSP, Brasil	Mineração de processos	Evidencia aplicação de <i>process mining</i> ao desempenho judicial, com identificação de gargalos e causas de ineficiência
Pernici et al. (2023)	Tribunais italianos	Mineração de processos	Referência de duração de processos em tribunais
Cerqueira et al. (2020)	ML séries temporais	Validação temporal	Fundamenta protocolo <i>walk-forward</i> com embargo
Collins et al. (2024)	ML preditivo	TRIPOD+AI	Orienta reporte transparente do modelo
Kapoor et al. (2024)	ML científico	REFORMS	Orienta reprodutibilidade e reporte
Guitton et al. (2025)	28 democracias	Survey adoção IA	Contextualiza adoção de IA no Judiciário global
Cheong (2024)	Internacional	Transparência algorítmica	Sustenta discussão sobre transparência e <i>accountability</i> em sistemas de IA
Sobrinho et al. (2026)	Ministério Público de Zacatecas, México	Random Forest; listas semanais ranqueadas; Precision@300	Trabalho correlato recente de priorização operacional semanal sob backlog; difere do JusCritIA por predizer finalização em seis meses, não criticidade futura semanal.
Bhatnagar e Huchhanavar (2026)	Cortes inferiores indianas	Modelos híbridos de <i>machine learning</i> , AutoML, ensemble e explicabilidade	Reforça o uso do F1 ponderado em tarefa judicial de classificação, com aplicação à predição de atraso/duração processual.
Araujo et al. (2020)	STF, Brasil	Dataset VICTOR e classificação de documentos jurídicos	Evidencia o uso de métricas de classificação, incluindo F1 ponderado, em base jurídica brasileira com múltiplas categorias e distribuição desigual de classes.
Soon et al. (2024)	Classificação multiclasse desbalanceada	Comparação de modelos <i>tree-based</i> e ensembles em base desbalanceada	Reforça metodologicamente a adequação do F1 ponderado em problemas multiclasse desbalanceados, próximos ao desafio métrico do JusCritIA.

Fonte: Elaborada pelo autor.

Posteriormente, o Quadro 3 sintetiza o posicionamento do JusCritIA em relação aos trabalhos relacionados.

2.2 Jurimetria, mineração de processos e monitoramento preditivo no Judiciário

No contexto da jurimetria, compreendida como a aplicação de métodos estatísticos à análise do fenômeno jurídico, a evolução recente das abordagens preditivas ampliou o repertório informacional disponível para a gestão judicial, sem eliminar o papel de indicadores consolidados baseados na observação histórica do acervo. Nessa perspectiva, a jurimetria é caracterizada como uma investigação empírica orientada à compreensão do cenário real de determinada matéria, à incidência de práticas específicas e às tendências legais e sociais observáveis em diferentes períodos e contextos institucionais (Silva, 2025, p. 107-114).

Essa capacidade analítica se consolidou recentemente, associada à intensificação da digitalização no setor público e, em particular, à incorporação progressiva de tecnologias digitais e sistemas baseados em dados na administração da justiça. Relatórios internacionais destacam que tais tecnologias passaram a apoiar não apenas a eficiência e a resiliência dos sistemas judiciais, mas também a qualidade das decisões administrativas em ambientes marcados por restrições estruturais persistentes, como limitações orçamentárias, escassez de pessoal e acúmulo crônico de demandas.

Nesse cenário, a ampliação do repertório informacional, exemplificada por sistemas como o VICTOR no Supremo Tribunal Federal brasileiro, voltado à triagem de recursos, ou o PretorIA na Corte Constitucional colombiana, não substitui indicadores consolidados de acompanhamento, mas fortalece decisões operacionais mais bem informadas em contextos de elevada complexidade institucional (OECD, 2025, p. 5, 66, 265-267).

A aplicação de métodos quantitativos à análise do funcionamento do Poder Judiciário tem se consolidado, nos últimos anos, como um campo interdisciplinar que articula direito, ciência de dados e engenharia de sistemas. No contexto dessa convergência, a jurimetria emerge como abordagem voltada à mensuração empírica de fenômenos processuais, com foco na identificação de padrões de tramitação, tempos de resposta, gargalos operacionais e variações entre unidades judiciais. Diferentemente de análises normativas ou dogmáticas, a jurimetria atua pela

observação sistemática de dados processuais, permitindo diagnósticos baseados em evidências e sustentando iniciativas de gestão orientada a dados no Judiciário.

A jurimetria pode ser compreendida, no plano metodológico, como um conjunto de práticas de mensuração e inferência empírica que se distribuem em três níveis analíticos complementares. No primeiro nível, descritivo, se busca quantificar o comportamento observado do sistema judicial por meio de estatísticas e distribuições associadas a volume, tempos de tramitação e padrões de movimentação. No segundo nível, diagnóstico, são investigadas associações e fatores correlatos a variações de desempenho entre unidades, tarefas e classes, com atenção à heterogeneidade estrutural que caracteriza o Judiciário. No terceiro nível, preditivo, se empregam modelos capazes de estimar estados futuros condicionados ao estado atual do processo, com o objetivo de apoiar a triagem e a priorização sob restrições de capacidade. Essa estratificação é relevante porque delimita com maior precisão o papel das técnicas quantitativas no Judiciário, ao distinguir a mensuração de fenômenos observados de inferências prospectivas que requerem validação temporal e cautela interpretativa (Ceravolo et al., 2024, p. 2-6).

No âmbito internacional, a literatura de mineração de processos fornece o arcabouço teórico e técnico que fundamenta grande parte dessas análises. A sistematização apresentada por Van der Aalst e Carmona organiza o campo ao definir conceitos centrais, como logs de eventos, casos, atividades e marcação de tempo, além de categorizar técnicas de descoberta, conformidade e aprimoramento de processos. O handbook consolida a mineração de processos como disciplina madura, capaz de transformar registros operacionais em modelos interpretáveis do fluxo de trabalho. Tal como demonstrado para outros domínios organizacionais, essa capacidade é igualmente aplicável a tribunais e órgãos públicos (Van der Aalst; Carmona, 2022, p. 3-15).

A contribuição da mineração de processos para a jurimetria se apresenta particularmente relevante quando se reconhece que os fenômenos processuais não se reduzem a métricas agregadas de tempo, mas se manifestam como sequências de eventos organizadas por regras institucionais, filas de trabalho e prioridades administrativas. Nesse contexto, o valor dos logs de eventos não reside apenas na possibilidade de reconstrução do fluxo, mas também na padronização conceitual de elementos essenciais para análises comparáveis, como caso, atividade e marcação

de tempo. Ao fornecer mecanismos de descoberta e conformidade, a mineração de processos também permite explicitar discrepâncias entre o processo previsto e o processo praticado, aspecto crucial em organizações nas quais a execução real é influenciada por políticas internas, restrições de pessoal e variações de infraestrutura (Van der Aalst; Carmona, 2022, p. 3-15).

No contexto brasileiro, Unger et al. (2021, p. 240-244) aplicaram *process mining* a dados reais do Tribunal de Justiça de São Paulo e demonstraram que a abordagem orientada a processos permite analisar o desempenho judicial, identificar gargalos, transições lentas e comportamentos recorrentes no fluxo processual a partir de logs de eventos extraídos de sistemas institucionais.

A partir dessa base descritiva, avanços recentes ampliaram o escopo da mineração de processos para abordagens preditivas. O monitoramento preditivo de processos passou a incorporar modelos de aprendizado de máquina capazes de estimar estados futuros do processo, como duração remanescente, risco de atraso ou probabilidade de violação de prazos. O survey conduzido por Ceravolo et al. sistematiza esse movimento ao definir o *predictive process monitoring* como a integração entre logs processuais e modelos estatísticos ou algorítmicos voltados à antecipação de comportamentos futuros. Os autores destacam que tais abordagens são particularmente relevantes em domínios caracterizados por alta variabilidade e restrições operacionais, desde que acompanhadas por protocolos rigorosos de validação temporal e mecanismos de explicabilidade. No contexto judiciário, essa relevância se justifica pela natureza complexa e variável dos processos, que demandam análise rigorosa (Ceravolo et al., 2024, p. 2-6).

A transição da análise diagnóstica para a predição, contudo, impõe desafios relevantes ao uso dessas técnicas em ambientes judiciais, especialmente no que se refere à interpretação dos resultados e à confiabilidade das estimativas geradas. A interpretação de previsões como afirmações causais pode conduzir a leituras equivocadas, uma vez que modelos preditivos, em geral, capturam padrões correlacionais derivados de dados históricos e podem refletir tanto propriedades do processo quanto artefatos de registro, mudanças organizacionais e variações de política administrativa.

Por esse motivo, a adoção de monitoramento preditivo exige critérios rigorosos de avaliação e validação temporal, de modo a estimar desempenho em

condições prospectivas e reduzir o risco de otimismo indevido em cenários com dependência temporal entre observações. Ademais, a literatura aponta que a utilidade gerencial de previsões depende de sua integração com rotinas de trabalho, uma vez que a simples disponibilidade de estimativas, por si só, não assegura sua conversão em ações de triagem ou priorização com impacto operacional mensurável (Ceravolo et al., 2024, p. 2-6).

Na conjuntura brasileira, estudos empíricos têm demonstrado o potencial da mineração de processos para a análise de tempos de tramitação e padrões de movimentação processual. Pesquisas aplicadas evidenciam que indicadores baseados exclusivamente no tempo decorrido desde o último evento capturam apenas parte da dinâmica processual, sendo insuficientes para comparar processos pertencentes a diferentes órgãos ou tarefas. Trabalhos nacionais mostram que a combinação de atributos temporais, estruturais e contextuais extraídos dos logs amplia a capacidade explicativa e preditiva das análises, reforçando a utilidade dessas técnicas como instrumentos de apoio à gestão judicial (Cruz et al., 2023, p. 99-103; Lima et al., 2023, p. 39-43).

À luz dessas evidências, essa discussão passa a ser especialmente relevante no contexto brasileiro, marcado por elevada heterogeneidade entre órgãos e tarefas. Nesses cenários, a mesma quantidade de tempo em aberto pode assumir significados operacionais distintos conforme o tipo de órgão, a tarefa corrente e o perfil do acervo, o que limita a comparabilidade direta entre processos quando métricas únicas são utilizadas. Embora úteis como sinais iniciais de alerta, tais métricas podem gerar interpretações assimétricas ao desconsiderarem essas diferenças estruturais. Nesse sentido, abordagens que combinam múltiplos atributos extraídos dos logs contribuem para diagnósticos mais compatíveis com a realidade operacional, desde que preservem rastreabilidade e transparência na forma como os indicadores são construídos e utilizados.

A literatura também ressalta que a adoção de modelos preditivos em ambientes judiciais deve ser orientada por princípios de governança, transparência e uso responsável da inteligência artificial. Estudos recentes enfatizam que sistemas de apoio à decisão, quando aplicados ao Judiciário, devem preservar a centralidade da decisão humana, assegurar transparência quanto aos critérios empregados e oferecer saídas interpretáveis para gestores e operadores do direito. Assim sendo, a predição

é compreendida como ferramenta de triagem e priorização, e não como substituta da atividade jurisdicional, alinhando-se às diretrizes contemporâneas de governança algorítmica no setor público (OECD, 2025, p. 4-39).

A literatura recente também reforça que a adoção de análises preditivas no Judiciário deve ser enquadrada como suporte à gestão e à alocação de recursos, sem substituição da decisão humana e com clareza quanto às limitações e ao escopo de uso dos modelos. Esse enquadramento é particularmente relevante quando se considera que previsões podem influenciar rotinas de triagem e priorização, exigindo clareza de finalidade, documentação e mecanismos de *accountability* (responsabilização institucional e prestação de contas) compatíveis com instituições públicas. Diante disso, diretrizes internacionais situam o uso de sistemas algorítmicos como apoio à decisão, com ênfase em transparência e uso responsável, elementos que dialogam diretamente com o contexto judiciário em que a legitimidade institucional e a confiança social são condições de adoção (OECD, 2025, p. 4-39).

Em síntese, os trabalhos relacionados indicam que a combinação entre jurimetria, mineração de processos e monitoramento preditivo constitui uma linha de pesquisa consolidada e relevante para a gestão judicial. Todavia, a literatura também aponta lacunas na operacionalização dessas abordagens em ambientes reais de trabalho, especialmente no que se refere à integração entre indicadores institucionais tradicionais e estimativas preditivas orientadas a janelas curtas de decisão. É nesse espaço aplicado que se insere a presente pesquisa, ao propor um critério de priorização processual fundamentado em risco preditivo, alinhado às rotinas e restrições observadas no contexto do Judiciário estadual brasileiro.

2.2.1 Estatística descritiva, quantis e discretização para o QOT e o CRIT_SCORE_%

Quantis, quartis e percentis são medidas de posição pertencentes à estatística descritiva e têm como finalidade organizar uma distribuição de dados segundo a localização relativa de seus valores. Um percentil indica o ponto abaixo do qual se encontra uma determinada proporção das observações, enquanto os quartis dividem a distribuição em quatro partes iguais, correspondendo aos cortes de 25%, 50% e 75%. Essas medidas são particularmente úteis em distribuições assimétricas,

como as associadas a tempos processuais, pois permitem interpretar o comportamento dos dados sem depender exclusivamente de médias, que podem ser fortemente influenciadas por valores extremos (Wheelan, 2016, p. 32-53).

Com base nessa mesma discussão apresentada por Wheelan, a adoção dessas medidas neste trabalho está fundamentada na abordagem didática proposta por ele, que privilegia a compreensão intuitiva da estatística descritiva e sua aplicação prática em contextos não especializados. Essa característica torna a obra especialmente adequada ao contexto desta pesquisa, na qual conceitos estatísticos precisam ser apresentados de forma acessível, sem perda de rigor, para sustentar decisões analíticas e gerenciais baseadas em dados.

Além de sua função descritiva, os quartis permitem a transformação de valores contínuos em classes ordinais, viabilizando comparações entre processos inseridos em contextos organizacionais distintos. Nesta pesquisa, essa lógica sustenta a definição do QOT (Quartil Órgão Tarefa) como classe operacional, posicionando cada processo em uma faixa relativa ao desempenho observado para o respectivo órgão e tarefa. Essa estratégia reduz a dependência de valores absolutos de tempo e favorece interpretações compatíveis com a heterogeneidade estrutural do Judiciário, sem romper com práticas de acompanhamento já existentes.

Em cenários aplicados, a discretização de variáveis contínuas pode ser acompanhada pelo agrupamento de classes adjacentes, prática frequentemente denominada *coarsening* (discretização em níveis mais amplos). O *coarsening* reduz o número de categorias por meio da fusão de faixas vizinhas, com a finalidade de aumentar a robustez das classes diante de assimetrias, ruído e instabilidade amostral, além de favorecer desempenho preditivo em problemas de classificação ordinal. No contexto deste trabalho, esse agrupamento é tratado como decisão de desenho do artefato, orientada à operacionalização do QOT em três classes (QOT1+QOT2, QOT3, QOT4), preservando interpretabilidade para uso gerencial.

Como exemplo de discretização estatisticamente orientada em pré-processamento supervisionado, Rim e Liu (2020) propuseram o MSD-Splitting, que define pontos de corte a partir da média e do desvio padrão para compor quatro intervalos (Rim; Liu, 2020, p. 43-44). O estudo ilustra que a definição de faixas por critérios estatísticos pode produzir discretizações mais aderentes à distribuição

observada, evitando escolhas arbitrárias de intervalos, com potencial de melhorar a eficiência do *pipeline* de aprendizado supervisionado no contexto avaliado.

Ao aplicar o MSD-Splitting como etapa de pré-processamento no algoritmo C4.5, os autores relataram aumento médio de 5,11% na acurácia (Rim; Liu, 2020, p. 45), além de redução de 96,72% no tempo de execução (Rim; Liu, 2020, p. 46). Esses resultados sustentam, no nível metodológico, a utilidade operacional de discretizações estatisticamente definidas como estratégia de pré-processamento; neste trabalho, a discretização via QOT constitui a base de estratificação, enquanto o *coarsening* permanece caracterizado como ajuste de granularidade posterior, introduzido para ampliar robustez e legibilidade das classes em regime aplicado.

Neste trabalho, o agrupamento de QOT1 e QOT2 em uma única classe segue essa lógica e, simultaneamente, mantém aderência às três faixas já utilizadas nos painéis da Diretoria, saneados, pré-críticos e críticos, classificados por faixas temporais de dias parados em tarefas. A partir dessa estrutura, o modelo estima probabilidades por classe, $P(QOT1+QOT2)$, $P(QOT3)$ e $P(QOT4)$, e o CRIT_SCORE_% emerge como um critério de priorização processual fundamentado em risco preditivo, derivado dessas probabilidades e sintetizado em uma métrica única e interpretável, sem substituir o julgamento humano.

2.3 Inteligência artificial aplicada ao Judiciário brasileiro

A incorporação de sistemas de inteligência artificial no Judiciário brasileiro tem ocorrido de forma gradual e institucionalmente orientada, com foco em atividades de apoio à gestão, à triagem e à organização do acervo processual. A literatura nacional recente descreve que essas iniciativas são concebidas como instrumentos auxiliares à atuação humana, voltadas à classificação, à priorização e à extração de informação, em contraste com propostas de automatização de decisões de mérito. Esse enquadramento decorre de condicionantes normativos, éticos e operacionais, bem como da necessidade de compatibilizar soluções algorítmicas com rotinas administrativas já consolidadas no âmbito judicial.

Estudos recentes identificam que as primeiras iniciativas estruturadas de IA no Judiciário brasileiro foram impulsionadas pela necessidade de lidar com volumes crescentes de processos repetitivos e recursos extraordinários. Nesse cenário,

destacam-se sistemas desenvolvidos no âmbito dos tribunais superiores, voltados à triagem temática e à identificação de padrões relevantes para a gestão do acervo. A literatura aponta que tais soluções se apoiam predominantemente em técnicas de aprendizado supervisionado e processamento de linguagem natural, operando sobre grandes bases documentais, com o objetivo de acelerar fluxos administrativos e reduzir o tempo dedicado a tarefas manuais de classificação (Resck et al., 2025, p. 2-4).

O sistema VICTOR, desenvolvido no Supremo Tribunal Federal, constitui um dos casos mais emblemáticos dessa trajetória. Conforme descrito por Resck et al., o VICTOR foi concebido para auxiliar na triagem de recursos extraordinários, reduzindo drasticamente o tempo necessário para a identificação de temas de repercussão geral. O estudo evidencia que, embora o sistema alcance ganhos expressivos de eficiência operacional, sua arquitetura inicial apresentava limitações quanto à explicabilidade das classificações, aspecto que motivou o desenvolvimento de soluções complementares, como o LegalAnalytics, orientadas à visualização e à interpretação dos resultados por especialistas jurídicos (Resck et al., 2025, p. 6-9).

Em direção convergente, Menezes-Neto e Clementino (2022) treinaram três arquiteturas de *deep learning* em 612.961 recursos dos Juizados Especiais Federais do TRF da 5ª Região e demonstraram desempenho preditivo superior ao de 22 especialistas humanos na antecipação de resultados recursais, reforçando a viabilidade de abordagens preditivas em bases judiciais brasileiras de grande escala (Menezes-Neto; Clementino, 2022, p. 15).

Além dos tribunais superiores, pesquisas empíricas têm analisado o uso de IA em instâncias inferiores e em contextos administrativos do Judiciário. Trabalhos nacionais indicam que modelos preditivos e classificatórios vêm sendo explorados para estimar tempos de tramitação, identificar processos com maior probabilidade de atraso e apoiar a alocação de recursos humanos. Esses estudos ressaltam que a utilidade prática da IA no Judiciário brasileiro está diretamente associada à sua capacidade de dialogar com indicadores já consolidados na gestão, como métricas de tempo em aberto e classificações de criticidade, evitando rupturas abruptas com as rotinas institucionais existentes (Cruz et al., 2023, p. 100-103).

A efetividade de sistemas de inteligência artificial no Judiciário brasileiro está diretamente associada à sua incorporação nas rotinas decisórias cotidianas e à sua aderência às categorias operacionais já reconhecidas pelos gestores e servidores. Soluções que produzem resultados dissociados das práticas de trabalho existentes tendem a enfrentar resistência institucional, independentemente de sua sofisticação técnica. Nesse sentido, a utilidade prática da inteligência artificial não decorre apenas da acurácia dos modelos, mas de sua capacidade de gerar informações compatíveis com os instrumentos de gestão já utilizados, permitindo aprendizado institucional progressivo e adoção incremental, sem rupturas abruptas nos fluxos administrativos consolidados.

A literatura também enfatiza que a adoção de IA no Judiciário brasileiro ocorre sob fortes condicionantes de governança e conformidade normativa. As diretrizes estabelecidas pelo Conselho Nacional de Justiça reforçam que sistemas baseados em IA devem ser utilizados como apoio à decisão, com transparência quanto aos critérios empregados, possibilidade de auditoria e preservação da autonomia dos agentes humanos. Estudos de governança de IA no setor público brasileiro destacam que a ausência de clareza sobre finalidade, responsabilidades e limitações técnicas pode comprometer a confiança institucional e a legitimidade dessas soluções (FGV Justiça, 2025, p. 18-24).

As pesquisas destacam ainda, a importância do enquadramento dos resultados produzidos por sistemas de inteligência artificial como subsídios informacionais à decisão humana, e não como prescrições automáticas de conduta.

Em ambientes judiciais, a forma como estimativas, classificações ou previsões são apresentadas influencia diretamente sua utilização prática, sendo fundamental preservar margens de discricionariedade técnica e interpretativa. A comunicação inadequada de resultados algorítmicos pode favorecer a cristalização de decisões baseadas exclusivamente em saídas automáticas, ampliando riscos institucionais e reduzindo a capacidade crítica dos operadores. Por essa razão, o uso de inteligência artificial no Judiciário demanda cuidado quanto ao modo de apresentação das informações, de forma a apoiar a decisão gerencial sem deslocar responsabilidades ou comprometer princípios institucionais.

Outro aspecto recorrente na literatura diz respeito às restrições operacionais enfrentadas pelos órgãos judiciais brasileiros. Pesquisas apontam limitações de

infraestrutura computacional, restrições orçamentárias e preocupações com sigilo e proteção de dados como fatores determinantes na escolha de arquiteturas algorítmicas. Nesse cenário, modelos executáveis em ambiente local, com menor demanda por recursos computacionais e sem dependência de serviços em nuvem, tendem a ser considerados mais compatíveis com a realidade institucional, sobretudo quando associados a estratégias de anonimização e minimização de dados (Zuiderwijk; Chen; Salem, 2021, p. 6-9; OECD, 2025, p. 96-122).

As restrições operacionais observadas no Judiciário brasileiro, como limitações de infraestrutura, exigências de proteção de dados e necessidade de auditabilidade, não devem ser tratadas apenas como condicionantes externas, mas como critérios estruturantes no desenho das soluções de inteligência artificial. A escolha tecnológica passa, assim, a refletir não apenas considerações de desempenho preditivo, mas também requisitos de interpretabilidade, estabilidade e possibilidade de avaliação contínua. Nesse contexto, modelos que permitem rastreabilidade das saídas e compreensão de seus efeitos tendem a apresentar maior compatibilidade com ambientes institucionais que demandam responsabilidade administrativa e facilidade de auditoria, reforçando a coesão entre decisão técnica e condições reais de uso no setor público.

Essa perspectiva é corroborada por evidências provenientes de outros contextos latino-americanos. Rodríguez-Salcedo et al. (2025, p. 3-6) indicam que os efeitos da implementação de ferramentas de IA em tribunais não podem ser compreendidos de forma dissociada das condições institucionais em que tais sistemas são inseridos, especialmente no que se refere à disponibilidade de dados, aos parâmetros de avaliação e ao desenho metodológico adotado. Nesse sentido, o estudo reforça que a efetividade de soluções algorítmicas no Judiciário não constitui atributo universal nem automaticamente transferível, mas depende do contexto empírico, normativo e organizacional em que essas ferramentas são desenvolvidas e aplicadas.

Diante desse panorama, os trabalhos relacionados indicam que a inteligência artificial aplicada ao Judiciário brasileiro apresenta um estágio de maturidade caracterizado pela consolidação de soluções de suporte à gestão e pela adoção cautelosa de modelos preditivos e classificatórios. As evidências apontam para a

centralidade de princípios como transparência, explicabilidade e governança, associados a ganhos operacionais mensuráveis e à aderência às práticas institucionais.

Esse conjunto de argumentos apresentados na literatura sustenta a relevância de investigações que explorem a priorização processual orientada a risco como instrumento de apoio à decisão gerencial, respeitando as especificidades normativas e organizacionais do contexto judicial brasileiro.

2.4 Monitoramento preditivo de processos e modelos de risco

O monitoramento preditivo de processos constitui um desdobramento natural da mineração de processos ao incorporar técnicas voltadas à antecipação de comportamentos futuros a partir de registros históricos de eventos. Diferentemente das abordagens descritivas e diagnósticas, que se concentram na reconstrução e na análise retrospectiva dos fluxos processuais, o monitoramento preditivo busca estimar estados ainda não observados do processo, como duração remanescente, probabilidade de atraso, risco de violação de prazos ou ocorrência de desfechos indesejáveis. Essa perspectiva amplia o potencial analítico da mineração de processos ao permitir que gestores e tomadores de decisão atuem de forma prospectiva, orientando intervenções antes que problemas se materializem.

A literatura internacional sistematiza esse campo ao caracterizar o *predictive process monitoring* como a integração entre logs de eventos e modelos estatísticos ou algorítmicos capazes de produzir previsões condicionadas ao estado atual do processo. O survey conduzido por Ceravolo et al. organiza as principais categorias de tarefas preditivas, incluindo a estimativa do tempo restante de execução, a previsão de resultados finais e a identificação de riscos associados a trajetórias específicas do processo. Os autores destacam que essas tarefas são particularmente relevantes em contextos organizacionais complexos, nos quais a variabilidade dos fluxos e a heterogeneidade dos casos dificultam a adoção de regras determinísticas de gestão (Ceravolo et al., 2024, p. 3-7).

No plano conceitual, os modelos de risco ocupam posição central nesse conjunto de abordagens. O risco é compreendido, na literatura, como uma medida associada à probabilidade de ocorrência de eventos adversos ou de estados

indesejáveis do processo, calculada a partir de padrões observados em execuções anteriores. Em vez de fornecer previsões pontuais isoladas, os modelos de risco permitem classificar processos segundo níveis relativos de atenção, oferecendo uma base comparativa para priorização e alocação de recursos. Essa lógica é especialmente adequada a ambientes nos quais a capacidade operacional é limitada e a intervenção seletiva se mostra mais viável do que o tratamento uniforme de todos os casos.

Avanços recentes na área evidenciam a preocupação crescente com a interpretabilidade e a robustez das previsões em monitoramento preditivo de processos. Estudos indicam que, em domínios sensíveis, modelos preditivos devem produzir saídas compreensíveis e passíveis de análise por especialistas, de modo a apoiar a tomada de decisão sem comprometer a confiança institucional. Trabalhos voltados à explicabilidade em monitoramento preditivo ressaltam que a utilidade prática dessas soluções depende não apenas de sua acurácia, mas também da clareza com que os fatores associados ao risco são apresentados aos usuários finais (Rizzi et al., 2024, p. 5-9).

No contexto do setor público e da administração da justiça, organismos internacionais reforçam que sistemas baseados em inteligência artificial devem operar como instrumentos de apoio à decisão humana, com transparência, possibilidade de auditoria e adequada compreensão de seus resultados por gestores e operadores institucionais (OECD, 2025, p. 22-28).

Outro eixo recorrente na literatura diz respeito às limitações inerentes ao uso de modelos preditivos baseados em logs processuais. Estudos indicam que a qualidade das previsões está diretamente associada à consistência dos registros, à estabilidade dos processos ao longo do tempo e à adequada ordenação temporal dos eventos. Trabalhos aplicados mostram que inconsistências nos logs, processos incompletos ou instáveis e esquemas de avaliação pouco rigorosos podem afetar a capacidade de generalização dos modelos e a confiabilidade das previsões geradas. Por esse motivo, o monitoramento preditivo é frequentemente apresentado como um campo no qual rigor conceitual e cautela analítica são tão relevantes quanto os avanços algorítmicos (Bousdenkis et al., 2023, p. 2-4, 9-13).

Desenvolvimentos recentes têm ampliado o escopo do *Predictive Process Monitoring* para contextos colaborativos, nos quais o fluxo de trabalho não se esgota

na atuação de um único agente, mas se distribui entre múltiplos participantes responsáveis por etapas distintas da execução processual. Delgado et al. (2025, p. 2-4) assinalam que processos colaborativos interorganizacionais, por sua natureza distribuída, cooperativa e mediada por interações entre diferentes atores, introduzem complexidades adicionais para a implementação, a análise e a predição, especialmente quando a dinâmica do processo depende da articulação entre participantes, mensagens e distintos históricos de execução.

No contexto aplicado, estudos empíricos demonstram que o monitoramento preditivo de processos tem sido explorado com sucesso em áreas como logística, manufatura e serviços, bem como em domínios públicos caracterizados por fluxos complexos e elevada demanda, incluindo sistemas judiciais europeus. Pesquisas baseadas em tribunais italianos, por exemplo, indicam que a modelagem preditiva pode revelar fatores estruturais associados à morosidade processual, desde que interpretada como instrumento de apoio à gestão e não como mecanismo automático de decisão (Pernici et al., 2023, p. 284-289).

Em resumo, a literatura aponta que o monitoramento preditivo de processos e os modelos de risco constituem um arcabouço conceitual consistente para a antecipação de comportamentos processuais e para a priorização orientada por evidências. Ao mesmo tempo, os trabalhos relacionados enfatizam que a adoção dessas abordagens em contextos institucionais sensíveis requer atenção aos limites de validade, à interpretabilidade das saídas e à integração com práticas organizacionais existentes.

Esses elementos fornecem o pano de fundo teórico para investigações que buscam explorar o risco preditivo como critério de apoio à gestão judicial, sem antecipar escolhas metodológicas específicas ou soluções técnicas particulares.

2.5 Governança, explicabilidade e restrições operacionais no uso de IA

A utilização de sistemas de inteligência artificial no setor público, em especial no Poder Judiciário, tem sido acompanhada por um conjunto crescente de preocupações relacionadas à governança, à transparência e à responsabilidade no uso de modelos algorítmicos. Diferentemente de contextos estritamente privados, a adoção de IA em instituições judiciais envolve impactos diretos sobre direitos

fundamentais, legitimidade decisória e confiança social, o que impõe limites claros à forma como essas tecnologias podem ser concebidas e utilizadas.

Organismos internacionais e estudos recentes apontam que a governança de IA no setor público deve priorizar princípios como finalidade clara, supervisão humana, rastreabilidade das decisões e possibilidade de auditoria. Relatórios da Organização para a Cooperação e Desenvolvimento Econômico destacam que sistemas algorítmicos empregados por órgãos governamentais devem atuar como instrumentos de apoio à decisão, e não como substitutos do julgamento humano, especialmente em domínios sensíveis como o Judiciário (OECD, 2025, p. 22-28, 96-128). Essa diretriz reforça a necessidade de modelos que produzam informações compreensíveis e utilizáveis por gestores, evitando automatizações não transparentes ou de difícil interpretação.

A explicabilidade surge, nesse enquadramento, como requisito central para a adoção responsável de IA. A literatura especializada indica que modelos aplicados a processos decisórios públicos devem permitir a análise dos fatores que influenciam suas saídas, de modo a possibilitar questionamentos, correções e aprendizado institucional. Diretrizes como o TRIPOD+AI (TRansparent Reporting of a multivariable Individual Prognosis Or Diagnosis model + *Artificial Intelligence*) ou Orientações atualizadas e padronizadas para relatar (publicar) estudos de modelos de previsão clínica que utilizam métodos de regressão ou aprendizado de máquina (inteligência artificial) enfatizam que sistemas preditivos precisam ser documentados de forma clara, com explicitação de pressupostos, limitações e condições de uso, reduzindo riscos de uso indevido ou interpretação equivocada dos resultados (Collins et al., 2024, p. 4-7).

No âmbito normativo, o Conselho Nacional de Justiça estabeleceu diretrizes específicas para o desenvolvimento e a utilização de soluções de inteligência artificial no Poder Judiciário brasileiro. A Resolução nº 615/2025 define que sistemas baseados em IA devem observar princípios de transparência, controle humano, segurança da informação e proteção de dados pessoais, além de vedar explicitamente a automação de decisões jurisdicionais (Conselho Nacional de Justiça, 2025c). Essas normas consolidam o entendimento institucional de que a IA deve apoiar atividades administrativas e gerenciais, preservando a autonomia e a responsabilidade dos agentes humanos envolvidos.

Outro aspecto recorrente na literatura refere-se às restrições organizacionais e aos desafios de governança enfrentados pelo setor público na adoção de inteligência artificial. Estudos sobre governança de IA indicam que questões relacionadas à privacidade, à segurança da informação e à definição clara de responsabilidades institucionais influenciam de forma decisiva as escolhas tecnológicas realizadas por órgãos públicos. Essas limitações reforçam a necessidade de cautela na incorporação de sistemas baseados em IA, especialmente em contextos nos quais a proteção de dados e a confiança institucional são centrais (Zuiderwijk; Chen; Salem, 2021, p. 6-10).

Além disso, análises recentes ressaltam que a ausência de governança adequada pode amplificar riscos de viés, assimetrias de tratamento e perda de confiança institucional. Estudos sobre ética e regulação da IA no domínio jurídico indicam que sistemas algorítmicos devem ser avaliados não apenas por seu desempenho técnico, mas também por sua aderência a valores institucionais, normas legais e expectativas sociais. A regulação europeia sobre inteligência artificial, ao classificar aplicações judiciais como de alto risco, reforça essa preocupação ao exigir controles adicionais, documentação robusta e mecanismos de responsabilização claros (União Europeia, 2024, p. 12-18).

Diante da literatura analisada, observa-se que a adoção de inteligência artificial no Judiciário deve ser orientada por princípios de governança, explicabilidade e adequação às restrições institucionais. Esses princípios delimitam o uso legítimo de soluções algorítmicas e influenciam diretamente sua aceitação e utilidade no ambiente judicial. Nesse ambiente, a literatura situa os modelos preditivos como instrumentos de apoio à gestão, compatíveis com limites técnicos, legais e organizacionais próprios do Judiciário.

2.5.1 Síntese crítica e identificação da lacuna de pesquisa

A revisão da literatura apresentada nas seções anteriores permite consolidar conhecimentos fundamentais para a compreensão do objeto desta pesquisa e, simultaneamente, explicitar limites recorrentes nas abordagens existentes. No plano conceitual, a convergência entre jurimetria, mineração de processos e monitoramento preditivo de processos configura um arcabouço teórico consistente para a análise

empírica de fenômenos processuais e para a antecipação de comportamentos futuros a partir de padrões históricos.

Os trabalhos analisados indicam que a integração entre técnicas de descoberta de processos, modelagem preditiva e análise de risco constitui uma abordagem promissora para a gestão judicial orientada a evidências, especialmente no apoio à triagem, à priorização e à alocação de recursos.

No contexto brasileiro, evidências empíricas recentes reforçam essa perspectiva ao demonstrar a aplicabilidade da mineração de processos e do aprendizado de máquina para análise de tempos de tramitação, identificação de gargalos operacionais e previsão de duração processual. Pesquisas nacionais mostram que a combinação de atributos temporais, estruturais e contextuais extraídos de logs processuais amplia a capacidade explicativa e preditiva das análises, consolidando seu uso como instrumento de apoio à gestão judicial baseada em dados (Cruz et al., 2023, p. 97-104; Lima et al., 2023, p. 39-43; Verçosa et al., 2024, Seção 3.7; Seção 4.1; Seção 4.2).

No plano tecnológico, observa-se que os sistemas de inteligência artificial em operação no Judiciário brasileiro concentram-se predominantemente em atividades de apoio à gestão, como triagem documental, classificação temática e priorização de acervo, em conformidade com diretrizes normativas que vedam a automação de decisões de mérito. Os casos do VICTOR e do *LegalAnalytics*, desenvolvidos no âmbito do Supremo Tribunal Federal, ilustram ganhos expressivos de eficiência operacional.

Conforme documentado por Resck et al. (2025, p. 2-4; p. 6-9), o *LegalAnalytics* foi concebido especificamente para mitigar limitações de explicabilidade identificadas no VICTOR, incorporando visualizações interpretáveis que permitem maior compreensão dos critérios algorítmicos empregados. Essa experiência evidencia que a adoção bem-sucedida de IA no Judiciário depende não apenas de desempenho técnico, mas também de transparência, aceitabilidade institucional e aderência às rotinas existentes.

Experiências internacionais reforçam essa interpretação ao documentar aplicações similares em diferentes jurisdições. Estudos conduzidos no sistema judicial italiano demonstram que técnicas de mineração de processos e aprendizado de máquina são capazes de identificar fatores estruturais associados à morosidade

processual, desde que sejam compreendidas como instrumentos de apoio à gestão judicial, e não como mecanismos automáticos de decisão (Pernici et al., 2023, p. 284-289).

Em perspectiva comparada, análises em escala internacional evidenciam desafios recorrentes relacionados à heterogeneidade da infraestrutura tecnológica, às limitações de acesso e qualidade dos dados e às preocupações com equidade, transparência e proteção de direitos fundamentais, o que reforça a necessidade de abordagens contextualizadas e institucionalmente sensíveis (Guitton et al., 2025, p. 1-3; 5-6).

No plano normativo e de governança, os trabalhos revisados convergem na identificação de princípios fundamentais para a adoção legítima de sistemas de inteligência artificial no setor público. Transparência, supervisão humana, rastreabilidade e explicabilidade são apontadas como requisitos centrais para a *accountability* e para a manutenção da confiança institucional.

Esses princípios encontram respaldo em marcos regulatórios recentes, como a Resolução CNJ nº 615/2025 e o Regulamento (UE) 2024/1689, que classifica aplicações judiciais como sistemas de alto risco e estabelece obrigações específicas relacionadas à gestão de riscos, à documentação técnica e à preservação do controle humano significativo. Estudos contemporâneos sobre governança e ética em sistemas de inteligência artificial indicam que sua implementação exige mais do que conformidade técnica, demandando clareza administrativa, responsabilidade institucional e proteção efetiva de direitos fundamentais e do bem-estar social (Mišić; Van Est; Kool, 2025, p. 2-4; 10-13; Cheong, 2024, p. 2-4; 7-9).

Deste modo, a explicabilidade assume papel central. A literatura especializada indica que modelos aplicados a processos decisórios no setor público devem permitir a análise dos fatores que influenciam suas saídas, viabilizando questionamento informado, auditoria técnica e aprendizado institucional contínuo.

Diretrizes como o TRIPOD+AI enfatizam a necessidade de documentação clara e sistemática dos pressupostos adotados, das limitações inerentes e das condições de uso de modelos preditivos, como requisito para transparência e responsabilização (Collins et al., 2024, p. 1-5). Estudos empíricos em monitoramento preditivo de processos demonstram, adicionalmente, que a utilidade prática das explicações está diretamente associada à sua clareza e à capacidade de relacionar

atributos e eventos históricos às previsões geradas, reforçando o papel da explicabilidade como elemento funcional e não meramente formal desses sistemas (Rizzi et al., 2024, p. 6-7).

No caso brasileiro, a literatura sobre governança de inteligência artificial aplicada ao Judiciário reforça a presença de condicionantes normativos e institucionais adicionais. As diretrizes do Conselho Nacional de Justiça enfatizam o uso da IA como instrumento de apoio à decisão, exigindo transparência, possibilidade de auditoria e preservação da autonomia humana no processo decisório. Pesquisas nacionais indicam que a ausência de clareza quanto à finalidade, às responsabilidades institucionais e às limitações técnicas das soluções adotadas pode comprometer a confiança institucional, sobretudo em um contexto marcado pela heterogeneidade de infraestrutura tecnológica e de capacitação entre tribunais (FGV Justiça, 2025, p. 18-24).

Estudos internacionais recentes apontam desafios organizacionais convergentes na adoção de IA em sistemas judiciais, incluindo resistência à mudança, lacunas de capacitação, limitações na qualidade e integração dos dados processuais e preocupações persistentes com governança e proteção de dados, mesmo em contextos pós-digitalização (Bianchini et al., 2024, p. 1-7).

Outro eixo recorrente na literatura refere-se às restrições operacionais do setor público. Evidências indicam que limitações de infraestrutura computacional, restrições orçamentárias e exigências rigorosas de segurança da informação influenciam de forma decisiva as escolhas tecnológicas realizadas por órgãos públicos, tornando particularmente relevantes soluções que conciliem robustez técnica, governança adequada e viabilidade de implantação em contextos institucionais concretos (Zuiderwijk; Chen; Salem, 2021, p. 2-6).

Estudos recentes voltados aos desafios da adoção de inteligência artificial no domínio legal destacam, entre os principais pontos críticos, a necessidade de explicabilidade das decisões algorítmicas, a proteção de dados sensíveis e a manutenção de supervisão humana efetiva ao longo de todo o ciclo de uso desses sistemas (Kim; Yi; Park, 2025, p. 3-7).

Adicionalmente, análises contemporâneas alertam que a ausência de governança adequada pode amplificar riscos de viés, assimetrias de tratamento e perda de confiança institucional. Pesquisas sobre ética e regulação da IA no domínio

jurídico indicam que sistemas algorítmicos devem ser avaliados não apenas por métricas de desempenho técnico, mas também por sua aderência a valores institucionais, normas legais e expectativas sociais. Evidências empíricas sugerem que vieses podem ser introduzidos em diferentes etapas do desenvolvimento e da implementação desses sistemas, reforçando a necessidade de supervisão e validação humana contínuas (Javed; Li, 2025, p. 12-16; Watamura et al., 2025, p. 8-18).

Apesar dos avanços consolidados, revisões sistemáticas e estudos aplicados identificam limitações recorrentes na operacionalização de modelos preditivos em ambientes reais. A primeira refere-se à qualidade, à completude e à consistência dos logs de eventos, frequentemente marcados por lacunas, ruído e necessidade de reconstrução. A segunda diz respeito à instabilidade dos fluxos processuais e à capacidade de generalização dos modelos, sobretudo quando esquemas de validação inadequados são empregados. Trabalhos sobre monitoramento preditivo sob incerteza evidenciam que a variabilidade temporal pode comprometer significativamente a confiabilidade das previsões (Bousdenkis et al., 2023, p. 2-6).

Nesse ponto, a literatura metodológica sobre avaliação preditiva em dados temporais oferece contribuições diretas ao demonstrar que abordagens baseadas em validação aleatória tendem a produzir estimativas excessivamente otimistas quando há dependência temporal entre as observações. Estudos indicam que tais procedimentos comprometem a validade externa dos modelos ao permitir vazamento de informação entre conjuntos de treino e teste.

Em contraposição, estratégias como validação *walk-forward* e esquemas baseados em janelas deslizantes são amplamente recomendadas para preservar a ordem temporal dos dados, mitigar o vazamento de informação e assegurar avaliações mais realistas em cenários de uso prospectivo (Cerqueira; Torgo; Mozetič, 2020, p. 1-4; Hewamalage; Ackermann; Bergmeir, 2023, p. 1-5). Revisões recentes sobre métodos de ML aplicados a séries temporais confirmam que a escolha do protocolo de avaliação é determinante para a confiabilidade das estimativas, especialmente em domínios com sazonalidade e dependência temporal estrutural (Hall; Rasheed, 2025, p. 3-5).

Uma terceira limitação, particularmente relevante, refere-se à integração entre indicadores tradicionais de gestão processual e estimativas preditivas orientadas a

janelas curtas de decisão. Embora a literatura avance na modelagem de riscos e durações, observa-se menor atenção à transformação dessas previsões em critérios operacionais de priorização efetivamente utilizáveis por gestores, sob restrições de capacidade e com exigências de explicabilidade e governança. Em síntese, há progresso significativo na predição, mas persistem lacunas na operacionalização institucional dessas estimativas.

A lacuna identificada pode, portanto, ser formulada da seguinte maneira: a literatura carece de investigações que integrem indicadores tradicionais de gestão processual baseados em tempo e estado operacional com estimativas de risco preditivo validadas temporalmente, produzindo critérios de priorização tecnicamente robustos, explicáveis e operacionalizáveis em janelas curtas de decisão, em contextos de restrição de recursos típicos do Judiciário brasileiro.

Essa lacuna orienta diretamente as escolhas metodológicas desta pesquisa. A adoção do protocolo *walk-forward* com embargo=1 responde à limitação recorrente de validação aleatória em dados temporais, identificada em Cerqueira, Torgo e Mozetič (2020) e Hewamalage, Ackermann e Bergmeir (2023). A seleção do LightGBM com probabilidades estimadas por classe responde à necessidade de estimativas de risco interpretáveis sob restrição computacional real, conforme documentado em Cruz et al. (2023) e Resck et al. (2025). O enquadramento do artefato como instrumento de apoio à decisão, sem automação de atos decisórios, responde aos condicionantes normativos e de governança identificados na literatura nacional e internacional.

A definição do CRIT_SCORE_% como régua contínua de priorização semanal responde à lacuna mais específica identificada nesta revisão: a ausência de critérios operacionalizáveis que integrem risco preditivo validado temporalmente com a restrição de capacidade semanal típica do Judiciário brasileiro. Diferentemente de abordagens que produzem previsões sem traduzi-las em ordenação utilizável por gestores, o CRIT_SCORE_% transforma probabilidades preditivas em um critério contínuo de triagem, diretamente compatível com a lógica de priorização já praticada pela DEFFA/TJPE.

Trabalho recente e semanticamente próximo é o de Sobrino et al. (2026), desenvolvido em parceria com a Fiscalía General de Justicia del Estado de Zacatecas,

no México. O estudo propõe um sistema de aprendizado de máquina para apoio à priorização semanal de casos em contexto de backlog e capacidade institucional limitada, mediante geração de listas ranqueadas de 300 casos para revisão operacional. A tarefa preditiva, contudo, difere daquela adotada no JusCritIA: enquanto Sobrino et al. (2026) estimam quais casos abertos apresentam maior probabilidade de finalização em até seis meses, o JusCritIA prediz a criticidade futura em horizonte semanal e converte probabilidades estimadas em um critério contínuo de ordenação, o CRIT_SCORE_%. Desse modo, o trabalho mexicano reforça a relevância contemporânea de sistemas de apoio à priorização operacional no sistema de justiça, mas não resolve a lacuna específica desta pesquisa no contexto de Execuções Fiscais, QOT futuro e comparação com o *baseline* institucional DIAS_ABERTOS.

O Quadro 3 sintetiza o posicionamento do JusCritIA em relação aos trabalhos relacionados, destacando as dimensões metodológicas e de propósito que distinguem esta pesquisa das abordagens existentes. O recorte comparativo não visa hierarquizar os estudos por desempenho técnico, tarefa reservada à Tabela 9, mas evidenciar em quais dimensões o JusCritIA avança em relação ao estado da arte identificado nesta revisão. A análise das seis dimensões elencadas revela que nenhum dos estudos comparados combina, simultaneamente, protocolo de validação temporal, critério explícito de priorização e modelagem da restrição de capacidade semanal.

Quadro 3 JusCritIA e os trabalhos relacionados

Dimensão	Cruz et al. (2023)	Lage-Freitas et al. (2022)	Oliveira et al. (2022)	Resck et al. (2025)	Sobrino et al. (2026)	JusCritIA (2026)
Contexto	TREs Nordeste	Tribunais brasileiros	TRT5 Salvador	STF	Ministério Público de Zacatecas	DEFFA/TJPE
Objetivo	Tempo de tramitação	Decisão binária	Duração processual	Classificação temática	Priorização semanal de casos	Priorização semanal
Protocolo de validação	Divisão aleatória	Divisão aleatória	Divisão aleatória	<i>Cross-validation</i> aleatória	Divisão temporal simples	<i>Walk-forward</i> com embargo=1
Critério de priorização	Não proposto	Não proposto	Não proposto	Não proposto	Lista ranqueada de casos	CRIT_SCORE_%

Dimensão	Cruz et al. (2023)	Lage-Freitas et al. (2022)	Oliveira et al. (2022)	Resck et al. (2025)	Sobrinho et al. (2026)	JusCritIA (2026)
Restrição de capacidade	Não considerada	Não considerada	Não considerada	Não considerada	Considerada	Explicitamente modelada
Governança e explicabilidade	Parcial	Não abordada	Não abordada	Parcial	Apoio humano à decisão	Integrada ao design

Fonte: Elaborada pelo autor.

É nesse espaço que se insere a presente pesquisa, ao propor e avaliar um critério de priorização processual fundamentado em risco preditivo, denominado CRIT_SCORE_%, concebido em conformidade com diretrizes de governança algorítmica e orientado às rotinas e restrições observadas em tribunais estaduais brasileiros.

Os capítulos subsequentes detalham a metodologia adotada para o desenvolvimento e a avaliação do CRIT_SCORE_%, incluindo o desenho experimental, as fontes de dados, o protocolo de validação temporal e os resultados obtidos em termos de desempenho preditivo, explicabilidade e aderência aos requisitos de governança discutidos nesta revisão.

2.6 Avaliação preditiva em dados temporais e risco de vazamento de informação

A avaliação de modelos preditivos aplicados a fenômenos processuais exige atenção específica às propriedades temporais dos dados utilizados. Diferentemente de domínios nos quais as observações podem ser tratadas como independentes e identicamente distribuídas, os dados processuais judiciais apresentam dependência temporal intrínseca, uma vez que cada registro reflete um estado do processo condicionado por eventos anteriores, por políticas administrativas vigentes e por características organizacionais que evoluem ao longo do tempo. Nesse contexto, procedimentos de avaliação que desconsideram a ordem temporal dos dados tendem a produzir estimativas excessivamente otimistas de desempenho, comprometendo a validade externa dos modelos quando aplicados prospectivamente.

No sistema judiciário brasileiro, essa dependência temporal é intensificada por fatores institucionais específicos que alteram, de forma estrutural, o próprio

processo gerador dos dados ao longo do tempo. Alterações normativas relevantes, como a entrada em vigor do Código de Processo Civil de 2015, mudanças legislativas setoriais, reestruturações administrativas, implantação de tribunais virtuais e a progressiva migração para sistemas digitais como o Processo Judicial Eletrônico (PJe) introduzem descontinuidades nos fluxos processuais.

Essas transformações modificam prazos, sequências de atos, rotinas administrativas e padrões de tramitação, afetando tempos médios e a distribuição de tarefas. Como consequência, dados históricos podem deixar de representar adequadamente o comportamento futuro do sistema, o que torna modelos treinados em janelas temporais anteriores potencialmente inadequados para uso prospectivo. Ignorar essas quebras temporais pode conduzir à adoção de modelos aparentemente eficazes em retrospecto, mas pouco confiáveis como instrumentos de apoio à gestão em cenários reais de decisão.

A literatura metodológica demonstra de forma consistente que esquemas tradicionais de validação baseados em amostragem aleatória, como validação cruzada *k-fold* sem restrição temporal, são inadequados para dados sequenciais. Cerqueira, Torgo e Mozetič evidenciam que, em contextos com dependência temporal, a mistura de observações passadas e futuras entre conjuntos de treino e teste gera vazamento de informação, inflando artificialmente métricas de desempenho e mascarando limitações de generalização (Cerqueira; Torgo; Mozetič, 2020, p. 1-4). Em aplicações judiciais, esse problema é particularmente sensível, pois o objetivo do modelo não é explicar o passado, mas apoiar decisões futuras sob restrições reais de capacidade.

O vazamento temporal ocorre quando informações que não estariam disponíveis no momento da decisão influenciam, direta ou indiretamente, o processo de treinamento ou avaliação do modelo. Em dados processuais, esse vazamento pode se manifestar, por exemplo, no uso de variáveis que incorporam o tempo total de tramitação do processo, no emprego de contagens de movimentações que incluem eventos futuros ou na construção de estatísticas agregadas calculadas sobre todo o histórico disponível, sem respeito a um ponto de corte temporal. Hewamalage, Ackermann e Bergmeir destacam que essas práticas permitem que o modelo incorpore conhecimento implícito sobre o futuro, distorcendo a avaliação e

comprometendo sua utilidade operacional (Hewamalage; Ackermann; Bergmeir, 2023, p. 1-5).

Nesse contexto, torna-se fundamental distinguir desempenho retrospectivo de desempenho prospectivo. O desempenho retrospectivo responde à capacidade do modelo de reproduzir padrões observados em dados históricos, enquanto o desempenho prospectivo demonstra sua capacidade de generalizar para dados futuros, sob condições potencialmente distintas daquelas observadas no treinamento. Em ambientes judiciais caracterizados por instabilidade normativa, heterogeneidade organizacional e variações sazonais de demanda, essa distinção assume papel central, pois modelos com elevado desempenho retrospectivo podem apresentar desempenho significativamente inferior quando utilizados como instrumentos de apoio à gestão em tempo real.

Por essa razão, a literatura recomenda a adoção de estratégias de avaliação que preservem explicitamente a ordem temporal dos dados, como validação *walk-forward*, janelas deslizantes ou esquemas baseados em partições temporais sucessivas. Embora tais estratégias sejam detalhadas no campo metodológico, sua fundamentação teórica reside na necessidade de alinhar o processo avaliativo às condições reais de uso do modelo. Ao respeitar a sequência temporal, esses esquemas reduzem o risco de vazamento de informação e permitem estimativas mais realistas do desempenho prospectivo, aspecto crucial em aplicações institucionais sensíveis.

No campo do monitoramento preditivo de processos, estudos enfatizam que a confiabilidade das previsões depende não apenas do modelo empregado, mas também da estabilidade dos fluxos processuais e da adequação dos protocolos de avaliação utilizados. Trabalhos sobre monitoramento preditivo sob incerteza destacam que inconsistências nos logs, instabilidade temporal e validações inadequadas comprometem a capacidade de generalização e a utilidade prática das previsões (Bousdenkis et al., 2023, p. 2-6). Assim, a avaliação temporalmente consciente constitui condição necessária para que probabilidades preditivas possam ser interpretadas como subsídios legítimos à priorização e à alocação de recursos no Judiciário.

Para o JusCritIA, essa fundamentação implica que a validação temporal rigorosa do CRIT_SCORE_% é requisito inegociável para sua utilização como critério

de priorização processual em caráter prospectivo. A interpretação do risco preditivo associado a cada processo depende diretamente da credibilidade das probabilidades estimadas, as quais só podem ser consideradas informativas quando avaliadas em condições que reproduzem, de forma aproximada, o cenário real de decisão. Essa base teórica prepara o terreno para a discussão, na seção seguinte, sobre a interpretação de probabilidades como risco e seus limites interpretativos no contexto judicial.

2.7 Probabilidades preditivas e interpretação de risco

No contexto do monitoramento preditivo de processos, modelos de aprendizado de máquina produzem, em geral, estimativas probabilísticas associadas a eventos futuros de interesse, como risco de atraso, permanência prolongada em determinada tarefa ou violação de prazos administrativos. Diferentemente de classificações rígidas, que atribuem cada processo a uma única categoria, as probabilidades expressam graus relativos de risco, refletindo padrões observados nos dados históricos e preservando a incerteza inerente às previsões.

Essa distinção é fundamental no contexto judicial, pois probabilidades preditivas não devem ser interpretadas como afirmações determinísticas sobre o comportamento futuro de um processo. Em vez disso, elas indicam a frequência relativa com que eventos semelhantes ocorreram em situações passadas, sob condições comparáveis. Assim, o risco é compreendido como uma medida probabilística associada a estados indesejáveis do processo, e não como uma previsão exata de resultado individual.

A literatura especializada enfatiza que a utilidade prática das probabilidades preditivas depende diretamente da forma como essas informações são apresentadas e interpretadas pelos usuários. Estudos indicam que probabilidades são efetivamente úteis como apoio à tomada de decisão quando seus limites são claramente compreendidos e quando são analisadas em conjunto com outras fontes de informação, evitando leituras determinísticas ou causais indevidas. Nesse sentido, a interpretação adequada das saídas probabilísticas constitui condição necessária para que modelos preditivos contribuam de maneira responsável e operacionalmente

relevante em contextos organizacionais complexos, como o Judiciário (Rizzi et al., 2024, p. 5-9).

Outro aspecto central diz respeito aos limites interpretativos das previsões probabilísticas. Modelos preditivos identificam associações estatísticas presentes nos dados históricos, mas não fornecem explicações causais sobre os fenômenos subjacentes. Essa distinção é particularmente relevante no Judiciário, onde a identificação de causas possui significado jurídico específico. A interpretação indevida de probabilidades como evidência causal pode conduzir a leituras equivocadas e a usos inadequados de sistemas preditivos, razão pela qual a literatura ressalta que essas estimativas devem ser compreendidas como subsídios informacionais, e não como explicações ou prescrições automáticas de conduta.

Nesse sentido, o uso de probabilidades permite ordenar processos segundo níveis relativos de atenção, preservando a incerteza inerente às estimativas e oferecendo suporte à priorização sob restrições de capacidade. Essa ordenação não elimina a necessidade de avaliação humana, tampouco substitui critérios institucionais já consolidados, mas amplia o repertório informacional disponível para a gestão processual, especialmente em cenários de elevado volume e heterogeneidade de casos.

É nesse enquadramento que se insere o CRIT_SCORE_%, concebido como um critério de priorização processual fundamentado em risco preditivo, derivado de probabilidades estimadas pelo modelo e sintetizado em uma métrica única e interpretável. O CRIT_SCORE_% não se propõe a explicar causas, nem a substituir indicadores tradicionais ou o julgamento humano, mas a apoiar a triagem e a alocação de esforços de forma prospectiva, em consonância com princípios de transparência, governança e uso responsável da inteligência artificial discutidos na literatura.

Essa compreensão do risco como informação probabilística fornece a base conceitual para a discussão subsequente sobre a convivência entre estimativas preditivas e indicadores tradicionais de gestão processual, tema desenvolvido na próxima seção.

2.8 Integração entre indicadores tradicionais e estimativas preditivas

A gestão judicial historicamente se apoia em indicadores tradicionais derivados da observação retrospectiva do acervo processual, como tempo médio de tramitação, idade dos processos, volume pendente e taxas de congestionamento. Esses indicadores constituem instrumentos consolidados de monitoramento institucional e permitem análises comparativas ao longo do tempo, subsidiando avaliações de desempenho e planejamento administrativo (Francischini; Francischini, 2015, p. 15-28).

Entretanto, a literatura destaca que, quando utilizados de forma isolada, indicadores exclusivamente retrospectivos apresentam limitações para apoiar decisões operacionais em ambientes organizacionais complexos. Métricas únicas tendem a simplificar excessivamente realidades heterogêneas, podendo ocultar variações relevantes entre contextos, tarefas e unidades organizacionais, especialmente em cenários marcados por incerteza e dinâmica processual elevada (Francischini; Francischini, 2015, p. 45-62; Bousdenkis et al., 2023, p. 2-6).

Nesse contexto, abordagens contemporâneas de análise de dados distinguem entre analytics descritivos, voltados à síntese e interpretação de dados históricos, e analytics preditivos, orientados à antecipação de cenários futuros a partir de padrões observados. Enquanto os primeiros oferecem uma visão consolidada do passado, os segundos introduzem uma perspectiva prospectiva, permitindo estimar riscos e tendências relevantes para a tomada de decisão (Turban; Sharda; Delen, 2019, p. 25-45).

A literatura especializada sugere que a integração entre essas duas perspectivas constitui uma abordagem particularmente adequada para apoiar decisões gerenciais em ambientes complexos. Estudos indicam que a combinação de indicadores tradicionais com estimativas preditivas amplia o repertório informacional disponível, superando limitações associadas ao uso isolado de métricas retrospectivas ou modelos preditivos, especialmente em contextos caracterizados por heterogeneidade operacional e incerteza (Bousdenkis et al., 2023, p. 9-13; Turban; Sharda; Delen, 2019, p. 350-380).

É nesse sentido que o CRIT_SCORE_% se insere nesta pesquisa, não como substituto dos indicadores tradicionais, mas como um critério complementar de priorização processual fundamentado em risco preditivo. Sua função consiste em sintetizar probabilidades estimadas pelos modelos em uma métrica única e

interpretável, destinada a apoiar decisões de alocação de esforço e ordenação de processos, preservando o papel dos indicadores clássicos para fins de monitoramento institucional e avaliação histórica.

Essa lógica de integração favorece uma adoção gradual e responsável de ferramentas preditivas no contexto judicial, ao ampliar as capacidades analíticas existentes sem desconsiderar práticas consolidadas nem substituir o julgamento humano. Ao articular indicadores retrospectivos e estimativas prospectivas, é possível apoiar decisões operacionais de maneira mais informada, preservando a aderência a princípios de governança, transparência e controle institucional.

2.9 Limites conceituais e interpretativos do uso de inteligência artificial no Judiciário

A adoção de modelos preditivos no Judiciário precisa manter um enquadramento rigoroso de finalidade e de interpretação, porque as saídas algorítmicas não equivalem a justificativas jurídicas nem a explicações causais do fenômeno processual. Mesmo quando um modelo produz probabilidades estáveis e úteis para triagem, essas probabilidades sintetizam regularidades estatísticas observadas nos dados, sob condições históricas específicas. Assim, a leitura adequada é instrumental e gerencial, voltada a apoiar priorização e alocação de esforço, sem extrapolar para conclusões sobre mérito, culpabilidade, intenção ou correção jurídica (Javed; Li, 2025, p. 12-16).

Um primeiro limite de interpretação decorre do risco de reificação das previsões, quando o usuário passa a tratar a probabilidade como “verdade do caso” ou como evidência de causa. Em ambientes institucionais, esse risco se intensifica porque classificações e escores podem induzir automatismos operacionais e reduzir o espaço de revisão crítica, sobretudo sob pressão por produtividade. A literatura sobre IA aplicada a decisões e rotinas no domínio jurídico enfatiza que sistemas de apoio devem preservar revisão humana efetiva e devem ser entendidos como suporte informacional, não como substitutos da avaliação profissional (Javed; Li, 2025, p. 12-16).

Um segundo limite conceitual envolve vieses e assimetrias, que podem emergir tanto da história registrada nos dados quanto das escolhas de modelagem e

de implantação. Em termos práticos, resultados preditivos podem reproduzir padrões históricos de distribuição de carga, prioridades administrativas, e variações estruturais entre unidades, o que exige cautela para evitar amplificação de desigualdades operacionais. Evidências empíricas sobre percepções de magistrados indicam preocupações recorrentes com responsabilização, transparência e impactos do uso de IA sobre práticas institucionais, reforçando a necessidade de supervisão humana e de governança de uso (Watamura et al., 2025, p. 8-18).

Um terceiro limite, diretamente associado à adoção responsável, refere-se à forma de apresentação das saídas e ao padrão de documentação. Em domínios sensíveis, a literatura de reporte e transparência para modelos preditivos destaca que a utilidade institucional depende de documentação clara de pressupostos, limites de validade, riscos de interpretação e condições de aplicação, permitindo auditoria e revisão técnica quando necessário. Essa exigência não é apenas formal, ela reduz uso indevido e ajuda a manter consistência entre o que o modelo mede e o que a instituição interpreta (Collins et al., 2024, p. 1-12).

No contexto do setor público, diretrizes internacionais reforçam que aplicações de IA em justiça e acesso à justiça devem operar com controle institucional, rastreabilidade e atenção a riscos, considerando restrições reais de infraestrutura, capacidades e processos de trabalho. Esse enquadramento favorece uma adoção incremental, com mecanismos de monitoramento contínuo, revisão humana e prestação de contas, em vez de automação não transparente (OECD, 2025, p. 22-28; p. 265-267).

Por fim, esses limites de interpretação e de uso delimitam o papel de artefatos preditivos nesta pesquisa: apoiar triagem e priorização em janelas curtas de decisão, com transparência, supervisão humana e documentação, sem deslocar responsabilidades institucionais e sem converter probabilidades em juízos normativos. Esse enquadramento é compatível com regimes regulatórios recentes que classificam aplicações judiciais como de alto risco, exigindo controles adicionais, documentação e gestão de riscos ao longo do ciclo de vida (União Europeia, 2024, p. 12-18).

3 METODOLOGIA

3.1 Natureza da pesquisa

Esta pesquisa é classificada como aplicada, orientada à resolução de um problema operacional concreto por meio da concepção, implementação e avaliação de um artefato computacional. O foco recai sobre a produção de uma solução utilizável em contexto institucional, com resultados verificáveis e passíveis de comunicação técnica, em consonância com a concepção de *Design Science Research* que privilegia utilidade e relevância prática associadas ao rigor científico (Hevner et al., 2004, p. 76-78).

A abordagem é predominantemente quantitativa, uma vez que opera sobre registros estruturados e métricas objetivas derivadas do funcionamento do sistema e dos dados processuais analisados. Essa orientação se manifesta na mensuração de desempenho, na análise de erros e na aplicação de critérios formais de avaliação, alinhado às recomendações contemporâneas de reporte transparente em estudos de modelagem preditiva (Collins et al., 2024, p. 6-7).

Essa caracterização é coerente com os critérios metodológicos consolidados na literatura acadêmica brasileira. A dimensão exploratória da pesquisa, voltada ao exame de padrões e relações no contexto analisado, e o estudo de caso como procedimento empírico de investigação aprofundada em uma unidade real são modalidades amplamente reconhecidas para pesquisas aplicadas de natureza quantitativa (Severino, 2016, p. 128; 132).

Do ponto de vista do objetivo analítico, a pesquisa combina dimensões exploratórias e explicativas. É exploratória porque organiza e examina padrões do acervo e do comportamento das variáveis ao longo do tempo. É explicativa porque analisa como escolhas de modelagem, avaliação e priorização impactam os resultados operacionais do artefato, com documentação suficiente para permitir inspeção crítica e reprodução por terceiros, conforme recomendações recentes para ciência baseada em aprendizado de máquina (Kapoor et al., 2024, p. 7-9).

O recorte empírico é observacional, pois utiliza dados já produzidos no ambiente institucional, sem interferência direta nos fluxos reais de trabalho. O controle metodológico é assegurado pela explicitação do *pipeline*, das decisões de projeto e das condições de execução, em resposta às barreiras técnicas e metodológicas de reprodutibilidade amplamente documentadas na literatura recente (Semmelrock et al., 2025, p. 7-10).

Essa caracterização da natureza da pesquisa estabelece a base para o enquadramento metodológico adotado, no qual a construção e a avaliação sistemática do artefato constituem o núcleo da contribuição científica, conforme formalizado na abordagem de *Design Science Research* apresentada na seção seguinte (Hevner et al., 2004, p. 80-82).

3.2 Enquadramento metodológico, *Design Science Research*

O enquadramento metodológico desta pesquisa adota o paradigma de *Design Science Research*, adequado a estudos cujo objetivo central envolve projetar artefatos inovadores para resolver problemas relevantes e avaliar empiricamente sua utilidade. Nesse paradigma, a contribuição científica decorre da qualidade do artefato produzido e da robustez do processo de avaliação, e não apenas da descrição de fenômenos observados (Hevner et al., 2004, p. 75-77).

A *Design Science Research* se distingue de abordagens estritamente descritivas ou explicativas ao enfatizar a construção deliberada de soluções e a demonstração de sua eficácia em contextos reais ou realistas. Essa distinção fundamenta a adoção do paradigma neste estudo, uma vez que o objeto de pesquisa consiste em um sistema computacional que operacionaliza critérios de priorização e análise preditiva (Hevner et al., 2004, p. 78-79).

As diretrizes clássicas propostas por Hevner et al. estruturam o desenvolvimento metodológico do trabalho. Essas diretrizes incluem a exigência de um artefato viável, a relevância do problema abordado, o rigor na construção e na avaliação, e a comunicação adequada dos resultados. Em especial, a Tabela 1 do referido trabalho sintetiza os sete guidelines que orientam a condução e a avaliação de pesquisas em *Design Science Research* (Hevner et al., 2004, p. 83).

Desenvolvimentos recentes reforçam a necessidade de transparência explícita na condução de pesquisas baseadas em *Design Science Research*, sobretudo quando envolvem artefatos computacionais e ciclos iterativos de design e avaliação. Em particular, a proposta de “*journaling*” do processo de DSR sistematiza a documentação contínua das decisões e dos desvios do processo real de design, com o objetivo de reduzir perdas de informação sobre como o conhecimento de design

foi construído e, por consequência, fortalecer a rastreabilidade metodológica e a comunicabilidade do trabalho (Vom Brocke; Gau; Mädche, 2021, p. 1-6).

No contexto de sistemas que incorporam aprendizado de máquina, a transparência metodológica deve ser complementada por práticas rigorosas de documentação e reporte. Diretrizes como TRIPOD+AI e recomendações de consenso como o REFORMS fornecem *checklists* específicos para descrição de dados, especificação de modelos, definição de protocolos de avaliação e comunicação de limitações, alinhado às exigências normativas da *Design Science Research* (Collins et al., 2024, p. 6-8; Kapoor et al., 2024, p. 6-9).

Por fim, a adoção da *Design Science Research* neste estudo incorpora a reprodutibilidade como requisito integrado a todas as fases da pesquisa. Barreiras como especificação incompleta do *pipeline*, dependência de implementações específicas e ausência de documentação adequada comprometem a verificabilidade científica. Assim, o enquadramento metodológico integra explicitamente práticas recomendadas para mitigar essas limitações, conforme sistematizado por Semmelrock et al. (2025, p. 7-10).

3.3 Procedimentos metodológicos e operacionalização do artefato

A condução metodológica da pesquisa foi estruturada de forma a operacionalizar, de maneira controlada e rastreável, os princípios estabelecidos pelo paradigma de *Design Science Research*. Os procedimentos adotados se organizam em etapas iterativas que articulam definição do problema, construção do artefato, avaliação empírica e documentação sistemática do conhecimento de design gerado, em conformidade com as diretrizes clássicas da DSR (Hevner et al., 2004, p. 80-82).

O ponto de partida do processo metodológico consistiu na demonstração formal do problema operacional enfrentado no contexto institucional analisado, caracterizado pela necessidade de priorização racional de processos com base em risco e impacto operacional. Essa etapa envolveu a identificação das restrições do ambiente real, das variáveis disponíveis nos sistemas de informação existentes e dos objetivos práticos a serem atendidos pelo artefato, assegurando aderência ao critério de relevância do problema proposto por Hevner et al. (2004, p. 76-78).

A etapa de design e implementação se concentrou na construção de um sistema computacional capaz de integrar dados processuais, métricas derivadas e modelos preditivos, resultando em um mecanismo unificado de priorização. Nesse contexto, o CRIT_SCORE_% foi definido como critério sintético de priorização processual, derivado de probabilidades preditivas associadas a classes de risco futuro e combinado segundo uma lógica explícita e documentada. Esse critério não constitui um índice abstrato, mas uma métrica operacional interpretável, projetada para apoiar decisões de alocação de esforço e ordenação de tarefas no curto prazo, em consonância com a natureza aplicada da pesquisa.

A Figura 1 apresenta a logomarca adotada para identificação visual do artefato JusCritIA no contexto desta pesquisa. A figura antecede a descrição metodológica e operacional do sistema, situando graficamente o artefato desenvolvido.

Figura 1 Logomarca do JusCritIA



Fonte: Elaborada pelo autor.

A logomarca do JusCritIA sintetiza a finalidade do artefato em uma composição única: a balança remete ao domínio da Justiça; os circuitos junto ao cérebro representam o uso de Inteligência Artificial como apoio analítico; a tipografia reforça a associação direta entre “Jus” (Justiça), “Crit” (criticidade processual) e “IA” (Inteligência Artificial). A figura atua como identificador visual do artefato na dissertação, comunicando a integração entre tecnologia e decisão humana orientada por evidências, sem caracterizar endosso institucional por qualquer órgão ou entidade.

A avaliação do artefato foi conduzida por meio de análise empírica sobre dados reais, respeitando o caráter observacional do estudo. Foram empregados

procedimentos quantitativos de avaliação, incluindo análise de desempenho preditivo, inspeção de erros e verificação do impacto operacional da ordenação gerada pelo CRIT_SCORE_%. Esses procedimentos atendem ao requisito de rigor metodológico da *Design Science Research*, ao demonstrar de forma sistemática a utilidade e as limitações do artefato no contexto para o qual foi projetado (Hevner et al., 2004, p. 83).

A documentação do processo metodológico adotou práticas explícitas de transparência, incluindo o registro das decisões de projeto, das versões do artefato, das configurações experimentais e dos critérios de avaliação utilizados. Essa abordagem segue a proposta de *journaling* do processo de *Design Science Research*, que visa reduzir a perda de informação sobre o percurso real de construção do conhecimento de design e fortalecer a rastreabilidade entre problema, solução e evidências empíricas (Vom Brocke; Gau; Mädche, 2021, p. 1-6).

Adicionalmente, considerando a incorporação de componentes de aprendizado de máquina no artefato, os procedimentos metodológicos foram alinhados a diretrizes contemporâneas de transparência e reprodutibilidade. Foram observadas recomendações para documentação de dados, especificação de modelos, definição clara de protocolos de avaliação e comunicação de limitações, conforme estabelecido em iniciativas como TRIPOD+AI e REFORMS, garantindo consistência entre práticas de ciência de dados e exigências normativas da *Design Science Research* (Collins et al., 2024, p. 6-8; Kapoor et al., 2024, p. 6-9).

Essa combinação de procedimentos assegura que o artefato desenvolvido não apenas resolva o problema operacional identificado, mas o faça de maneira metodologicamente controlada, transparente e verificável, consolidando a contribuição científica da pesquisa no âmbito da *Design Science Research* aplicada a sistemas computacionais preditivos.

3.3.1 Justificativa da escolha do LightGBM

A escolha do *LightGBM* como núcleo preditivo do JusCritIA se apoia em quatro dimensões: desempenho empírico em contexto judicial brasileiro, viabilidade computacional, aderência operacional e conformidade normativa.

Do ponto de vista do desempenho, Cruz et al. (2023) utilizaram o LightGBM na análise de dados processuais dos Tribunais Regionais Eleitorais do Nordeste, com

resultados adequados para classificação com atributos extraídos de *logs* processuais. Resck et al. (2025) avaliaram o LightGBM em comparação com outros modelos para classificação de recursos no STF, obtendo $ACC = 0,97$, *balanced accuracy* = 0,90 e $F1 = 0,83$ para o Tópico 800 em análise comparativa de modelos, entre os resultados mais competitivos do conjunto avaliado (Resck et al., 2025, p. 51). Em domínio distinto do jurídico, Tirink (2025) aplicou o LightGBM à previsão de índices de qualidade do ar em séries temporais de longo prazo, obtendo desempenho estável mesmo sob variação sazonal e padrões não estacionários, o que evidencia a capacidade do algoritmo de generalizar em dados com dependência temporal estrutural, característica que também está presente nos lotes processuais semanais deste estudo (Tirink, 2025, p. 4-7). Esses resultados, provenientes de contextos e estruturas de dados distintos, sustentam a pertinência da escolha do LightGBM para o presente estudo.

Do ponto de vista computacional, o LightGBM foi projetado com foco em eficiência de memória e velocidade de processamento, conforme descrito em Ke et al. (2017). O algoritmo utiliza dois mecanismos principais: o *Gradient-based One-Side Sampling* (GOSS), amostragem unilateral baseada em gradiente, que reduz o volume de dados processados em cada iteração priorizando as amostras com maior erro, e o *Exclusive Feature Bundling* (EFB), agrupamento exclusivo de atributos, que comprime atributos esparsos sem perda relevante de informação.

Esses mecanismos permitem treinar modelos sobre bases de grande volume com consumo reduzido de memória e tempo de processamento. Nesta pesquisa, essa característica foi determinante, pois o modelo foi treinado e avaliado em *notebook* pessoal laboral, sem conexão com redes externas ou à internet, sobre uma base de 4.130.466 registros com 12 *snapshots* semanais. A execução em ambiente isolado reforça a segurança no tratamento dos dados institucionais, uma vez que todo o experimento foi conduzido com dados previamente anonimizados, sem transmissão ou exposição de informações processuais identificáveis.

Do ponto de vista normativo, a Resolução CNJ n. 615, de 11 de março de 2025, estabelece diretrizes para o desenvolvimento, utilização e governança de soluções de inteligência artificial no Poder Judiciário, com ênfase em transparência,

rastreabilidade, segurança e proteção de dados. A FGV Justiça (2025) reforça a necessidade de modelos com saídas interpretáveis e auditáveis.


O LightGBM atende a esses requisitos, pois suas saídas são probabilidades estimadas por classe, que sustentam o CRIT_SCORE_% como régua contínua e auditável. Sua estrutura de árvores permite extrair a importância relativa dos atributos utilizados na classificação, seu treinamento opera sobre atributos estruturais e temporais dos processos, sem exposição de partes ou conteúdo processual, em conformidade com a LGPD e as diretrizes do CNJ.

A resolução preconiza ainda que os sistemas sejam documentados, auditáveis e passíveis de replicação, requisitos atendidos pelo JusCritIA por meio de parâmetros registrados, protocolo reproduzível e resultados rastreáveis por janela temporal e recorte operacional.

3.3.2 Arquitetura metodológica

Para sintetizar a organização interna do artefato, apresenta-se sua arquitetura metodológica, estruturada em quatro camadas encadeadas: pré-processamento dos dados, engenharia de atributos e particionamento temporal, modelagem preditiva com validação temporal e composição e exportação operacional.

Figura 2 Arquitetura metodológica com validação temporal



Fonte: Elaborada pelo autor.

Nota: A figura sintetiza a arquitetura metodológica do artefato, integrando as camadas de pré-processamento, engenharia de atributos, validação temporal, composição operacional das listas TOP-N e verificação posterior em $t+1$.

A Figura 2 sintetiza a arquitetura metodológica do JusCritIA em quatro camadas. A primeira corresponde ao pré-processamento dos dados, com ingestão das cargas, verificação estrutural, limpeza, elegibilidade e segregação dos registros. A segunda organiza a engenharia de atributos e a construção do alvo QOT, com ordenação por `SNAPSHOT_IDX`, pareamento t e $t+1$ por NPU, uso de `ORGAO_JULGADOR`, `TAREFA`, `DIAS_ABERTOS` e `PCTL_OT`, e discretização de `DIAS_ABERTOS` em quartis por órgão julgador e tarefa. A terceira reúne a modelagem com validação temporal walk-forward e embargo igual a 1, o classificador LightGBM multiclasse e a avaliação por F1 ponderado, acurácia e matrizes de confusão. A quarta corresponde à composição e exportação operacional: cálculo do `CRIT_SCORE_%`, listas TOP-N sob capacidade semanal K, comparação com o baseline `DIAS_ABERTOS` e verificação temporal pelo `QOT_FUTURO` observado em $t+1$.

Embora o artefato possua rotinas auxiliares e variáveis de apoio descritas no Quadro 4, o núcleo preditivo avaliado nesta pesquisa utiliza, de forma explícita, as variáveis `ORGAO_JULGADOR`, `TAREFA`, `DIAS_ABERTOS` e `PCTL_OT`. Entre elas, `PCTL_OT` foi introduzida como feature derivada para representar a posição relativa do processo dentro do seu próprio contexto operacional. Seu cálculo parte da distribuição de `DIAS_ABERTOS` no grupo formado por órgão julgador e tarefa, considerado no snapshot corrente. A partir dessa distribuição, cada processo recebe uma posição ordinal, que depois é convertida em percentil, produzindo um valor contínuo que expressa quão avançado o caso está em relação aos demais processos submetidos à mesma tarefa no mesmo órgão. Com isso, a variável deixa de retratar apenas o tempo absoluto de permanência e passa a informar a posição relativa do processo na fila em que ele efetivamente se encontra.

Essa construção melhora a capacidade analítica do modelo porque incorpora heterogeneidade estrutural ao treinamento. Em bases judiciais, o mesmo número de dias parados pode assumir significados operacionais distintos conforme o órgão julgador, a tarefa ou o comportamento histórico da fila. Ao utilizar uma medida

percentual intragrupo, o modelo passa a comparar cada processo com seus pares mais próximos, o que reduz distorções provocadas por diferenças de escala entre contextos distintos. Em termos estatísticos, isso torna a entrada mais informativa do que o uso isolado de DIAS_ABERTOS, pois acrescenta ao valor absoluto uma leitura relativa da distribuição observada, aumentando a sensibilidade do classificador ao contexto em que o processo está inserido.

A utilização de PCTL_OT também não introduz vazamento temporal. O percentil é calculado sempre a partir dos processos disponíveis no próprio *snapshot* corrente, sem recorrer a qualquer informação proveniente de *snapshots* futuros. Assim, a variável é construída apenas com base no estado observável da carga no momento da predição, preservando a lógica prospectiva do estudo. Além disso, como o agrupamento respeita o recorte temporal adotado na validação, a feature permanece aderente ao protocolo *walk-forward* com embargo igual a 1, sem contaminar treino e teste com informação indevida. Desse modo, a derivação de PCTL_OT amplia a qualidade informacional da entrada do modelo sem comprometer a integridade metodológica da avaliação.

As demais variáveis derivadas e determinísticas cumprem função complementar de contextualização analítica, auditoria e operacionalização das saídas. O IEP sintetiza uma referência institucional de permanência esperada na tarefa, construída a partir de métricas já praticadas no âmbito do TJPE. O DELTA_IEP_DIAS expressa o desvio entre o tempo efetivamente observado e essa referência esperada, permitindo identificar situações acima ou abaixo do comportamento médio do grupo. O QOT_FIX0, por sua vez, representa o enquadramento determinístico do processo em quartis calculados a partir da distribuição de DIAS_ABERTOS no contexto do órgão e da tarefa. Em conjunto, essas variáveis preservam aderência a indicadores institucionais já utilizados, especialmente aqueles relacionados a tempos médios por tarefa e a grupos combinados de acompanhamento processual, ao mesmo tempo em que ampliam a capacidade analítica do artefato no contexto preditivo.

O Quadro 4 detalha os principais componentes técnicos associados a essas etapas, incluindo bibliotecas, classes e métodos empregados nas rotinas de carga,

preparação dos dados, modelagem, avaliação e exportação, complementando a visão sintética apresentada pela arquitetura.

Quadro 4 Principais componentes técnicos do JusCritIA

Componente	Tipo	Descrição
<i>LightGBM</i>	Biblioteca	Algoritmo de classificação preditiva
<i>Scikit-Learn</i>	Biblioteca	Pré-processamento, <i>Pipeline</i> e métricas de desempenho
<i>Pandas / Numpy</i>	Biblioteca	Manipulação dos <i>snapshots</i> e cálculo de atributos derivados
<i>Joblib</i>	Biblioteca	Serialização e recarregamento do modelo treinado
<i>Matplotlib / Seaborn</i>	Biblioteca	Geração dos gráficos analíticos
<i>Tkinter</i>	Biblioteca	Interface gráfica local do artefato
<i>ProcessDataAnalyzer</i>	Classe	Núcleo analítico do artefato: carga, pré-processamento, engenharia de atributos, treinamento e exportação
<i>ProcessAnalyzerGUI</i>	Classe	Visualizações analíticas e distribuições QOT
<i>load_data()</i>	Método	Carregamento das planilhas e ordenamento sequencial
<i>process_data()</i>	Método	<i>Pipeline</i> principal: pré-processamento, filtragem, engenharia de atributos, predição e cálculos
<i>_calculate_qot()</i>	Método	Calcula QOT determinístico (QOT1 a QOT4) por órgão tarefa e <i>snapshot</i> , utilizado como referência de auditoria
<i>_calculate_pctl_iqr_ziqr()</i>	Método	Calcula <i>PCTL_OT</i> (percentil contínuo de DIAS_ABERTOS por grupo e <i>snapshot</i>), demais <i>features</i> derivadas
<i>train_qot_model()</i>	Método	Treina o <i>LightGBM</i> por <i>fold</i> , calcula métricas OOF (<i>F1</i> ponderado e acurácia) em cada janela
<i>_predict_qot()</i>	Método	Aplica o modelo treinado, gera <i>QOT_PRED</i> , probabilidades <i>P_QOT3</i> e <i>P_QOT4</i> , e calcula <i>CRIT_SCORE_%</i> = $(P_QOT4 + 0,6 \times P_QOT3) \times 100$
<i>export_results()</i>	Método	Gera o arquivo Excel com abas e lista ordenada por <i>CRIT_SCORE_%</i>
<i>validate_temporal_structure()</i>	Função	Verifica monotonicidade de <i>SNAPSHOT_IDX</i> e ausência de valores nulos antes da validação cruzada
<i>build_snapshot_folds()</i>	Função	Gera os <i>folds walk-forward</i> com embargo = 1, definindo treino, <i>gap</i> e teste por bloco de <i>snapshot</i>

Fonte: Elaborada pelo autor.

3.4 Fontes de dados e preparação dos dados

As fontes de dados utilizadas nesta pesquisa derivam exclusivamente de registros processuais produzidos no ambiente institucional, extraídos de sistemas de informação corporativos e consolidados em bases estruturadas para fins analíticos. Esses dados compreendem informações necessárias à caracterização do estado processual, à mensuração temporal das tarefas e à aplicação dos critérios de priorização e avaliação definidos ao longo do estudo. A utilização de dados reais

reforça o caráter empírico e aplicado da pesquisa, assegurando aderência ao contexto operacional no qual o artefato foi projetado para atuar (Hevner et al., 2004, p. 76-78).

A seleção das variáveis observou critérios de relevância operacional e disponibilidade consistente ao longo das cargas analisadas. Foram considerados apenas campos efetivamente utilizados nos fluxos institucionais e com significado claro para a análise de criticidade e priorização, evitando a inclusão de atributos redundantes ou pouco interpretáveis. Essa decisão visa reduzir ruído analítico e mitigar riscos de viés decorrentes de informações incompletas ou imprecisas, em consonância com práticas recomendadas para estudos baseados em dados observacionais.

O processo de preparação dos dados seguiu uma sequência controlada de etapas, iniciando pela validação estrutural das bases recebidas, verificação de consistência de tipos, normalização de nomenclaturas e tratamento explícito de valores ausentes. Registros inconsistentes ou incompletos foram mantidos apenas quando sua exclusão comprometeria a representatividade do conjunto analisado, sendo devidamente identificados e documentados. Essa abordagem privilegia transparência metodológica e evita intervenções artificiais que poderiam distorcer o comportamento real do sistema avaliado (Vom Brocke; Gau; Mädche, 2021, p. 3-5).

A preparação temporal dos dados considerou como referência única a métrica de tempo associada à permanência do processo na tarefa atual, utilizada como base para o cálculo de criticidade e para a análise preditiva subsequente. A opção por trabalhar com uma métrica temporal direta, em detrimento de múltiplas derivações baseadas em datas, reduz fragilidades associadas ao processo de extração e padronização de componentes temporais a partir de registros com formatos heterogêneos, conhecido como parsing de datas e aumenta a robustez do *pipeline* analítico, especialmente em cenários com grande volume de registros e heterogeneidade de fontes.

No que se refere à rastreabilidade, todas as transformações aplicadas aos dados foram explicitamente documentadas, incluindo regras de filtragem, critérios de exclusão e procedimentos de normalização. Essa documentação integra o processo de registro sistemático e cronológico das decisões metodológicas adotado na pesquisa ou *journaling* metodológico, permitindo reconstruir o estado dos dados em

cada etapa do *pipeline* e verificar a correspondência entre decisões de preparação e resultados observados (Vom Brocke; Gau; Mädche, 2021, p. 1-6).

Por fim, a preparação dos dados foi conduzida de forma alinhada às diretrizes contemporâneas de transparência e reprodutibilidade em estudos que envolvem aprendizado de máquina. A descrição clara das fontes, das transformações aplicadas e das limitações inerentes aos dados observacionais atende às recomendações de reporte estruturado propostas por iniciativas como TRIPOD+AI e REFORMS, assegurando que o conjunto de dados utilizado possa ser compreendido, auditado e reinterpretado por terceiros no âmbito da avaliação científica (Collins et al., 2024, p. 6-8; Kapoor et al., 2024, p. 6-9).

3.5 Protocolo de validação temporal

A avaliação do artefato incorporou um protocolo de validação temporal orientado a reduzir vieses de estimativa e a mitigar riscos de vazamento entre treino e teste, preservando a lógica operacional do ambiente institucional. Esse protocolo foi definido como parte do rigor metodológico exigido em *Design Science Research*, no qual a utilidade do artefato deve ser demonstrada por evidência empírica obtida sob condições de avaliação controladas e comunicáveis (Hevner et al., 2004, p. 80-82; 83).

A organização temporal das observações foi realizada por meio de um identificador ordinal de carga, *SNAPSHOT_IDX*, que representa a sequência semanal de extrações de dados. A ordenação por *SNAPSHOT_IDX* estabelece uma linha de tempo explícita para treino e teste, assegurando que o modelo seja ajustado apenas com informação disponível em períodos anteriores ao período avaliado. Essa escolha reforça rastreabilidade e comunicabilidade do procedimento, pois torna verificável a origem temporal de cada subconjunto utilizado na validação (Vom Brocke; Gau; Mädche, 2021, p. 1-6).

Essa lógica é convergente com a literatura de *forecasting*, na qual Hyndman e Athanasopoulos descrevem a validação cruzada em séries temporais como procedimento em que cada conjunto de teste é formado por observações posteriores ao conjunto de treino, sem utilização de observações futuras na estimação, configuração também conhecida como *rolling forecasting origin* (Hyndman;

Athanasopoulos, 2021, seção 5.10). No presente estudo, o embargo de um *snapshot* estende essa lógica ao interpor uma janela de separação explícita entre treino e teste, reduzindo o risco de vazamento decorrente da dependência temporal entre cargas consecutivas.

Entre os blocos temporais de treino e teste, o protocolo adotou embargo explícito de um *snapshot*, com o objetivo de reduzir contaminação por transições operacionais e efeitos de fronteira entre cargas consecutivas. Esse embargo atua como uma salvaguarda adicional contra vazamento temporal, pois evita que instâncias muito próximas no tempo, e potencialmente dependentes do mesmo ciclo operacional, apareçam simultaneamente em treino e teste. A adoção de controles desse tipo responde a riscos metodológicos recorrentes em estudos que envolvem *pipelines* de aprendizado de máquina com dados observacionais e ciclos temporais (Simmelrock et al., 2025, p. 7-10; Kapoor et al., 2024, p. 6-9).

A estratégia de validação foi definida de forma condicional ao volume de *snapshots* disponíveis. Quando há quantidade suficiente de cargas, o procedimento prioriza validação *walk-forward*, preservando a direção temporal e repetindo o ciclo de treino e teste em janelas sucessivas, de modo a avaliar estabilidade e degradação de desempenho ao longo do tempo. Em cenários com poucas cargas, o protocolo adota *holdout* temporal, mantendo uma separação única entre passado (treino) e futuro (teste), preservando a coerência temporal da avaliação e evitando reamostragens que poderiam reduzir a robustez inferencial (Kapoor et al., 2024, p. 7-9).

Como controle adicional, o protocolo incorporou checagens explícitas para prevenir vazamento temporal por construção indevida de variáveis e por inclusão de campos com informação futura, especialmente em artefatos que combinam engenharia de *features*, priorização e avaliação preditiva. A validação inclui a conferência de que apenas variáveis previstas no *pipeline* do sistema sejam utilizadas, além da inspeção de consistência temporal entre os subconjuntos e os resultados reportados, se alinhando a recomendações contemporâneas de reporte estruturado e documentação de protocolos de avaliação em modelagem preditiva (Collins et al., 2024, p. 6-8; Kapoor et al., 2024, p. 6-9).

Por fim, o protocolo de validação temporal foi tratado como componente integrante da avaliação do artefato, e não como etapa acessória, pois sustenta a interpretação operacional dos resultados e delimita as condições sob as quais o

sistema pode ser utilizado de forma responsável. Essa integração consolida a coerência entre relevância prática e rigor científico, mantendo rastreabilidade de decisões metodológicas e sustentação verificável para as evidências apresentadas nas seções de métricas e análise de resultados (Hevner et al., 2004, p. 80-82; Collins et al., 2024, p. 6-8).

3.6 Métricas de avaliação e leitura operacional

A avaliação do desempenho do artefato foi conduzida por meio de métricas quantitativas explicitamente definidas e interpretadas sob duas perspectivas complementares, uma perspectiva preditiva, que mensura a capacidade do modelo em discriminar classes de risco futuro, e uma perspectiva operacional, que examina como os resultados do modelo sustentam decisões de priorização e alocação de esforço no contexto institucional. Essa dupla leitura atende ao requisito de avaliação rigorosa associado ao paradigma de *Design Science Research*, no qual a utilidade do artefato deve ser demonstrada por evidências empíricas verificáveis (Hevner et al., 2004, p. 80-82).

As métricas principais foram tratadas como derivadas da matriz de confusão e reportadas de forma estruturada, com ênfase em medidas que preservam significado operacional em cenários de classes desbalanceadas. Além da acurácia, que pode ser informativa em condições específicas, foram priorizadas métricas sensíveis a distribuição de classes e ao custo assimétrico de erro, assegurando que a avaliação não dependa de um único número agregado. Essa cautela é necessária porque um modelo pode apresentar valores satisfatórios de F1 ou acurácia e ainda assim errar sistematicamente em classes específicas de maior interesse operacional, falha detectável pela análise da matriz de confusão (Starcke et al., 2025, p. 9-10).

Esse cuidado está alinhado a diretrizes contemporâneas de transparência em estudos de modelagem preditiva e aos fundamentos de avaliação de classificadores estabelecidos na literatura de *data science* aplicada, segundo os quais a precisão simples apresenta limitações relevantes em problemas com classes desequilibradas e a matriz de confusão é o instrumento central para revelar a distribuição dos erros

entre classes e seus impactos operacionais distintos (Collins et al., 2024, p. 6-8; Provost; Fawcett, 2016, p. 188-190).

A acurácia mede a proporção de classificações corretas sobre o total de previsões, oferecendo uma leitura global do desempenho do modelo. É útil como referência de síntese, porém insuficiente como métrica isolada em problemas com distribuição assimétrica entre classes, pois pode mascarar baixo desempenho em classes minoritárias de maior interesse operacional (Rainio; Teuho; Klén, 2024; Sujon et al., 2025).

Formalmente, a acurácia é definida como a razão entre o total de classificações corretas e o total de previsões realizadas, conforme a expressão a seguir.

$$\text{Acurácia} = (VP + VN) / (VP + VN + FP + FN)$$

Nessa expressão, VP (verdadeiros positivos) representa o total de processos corretamente classificados na sua classe real, VN (verdadeiros negativos) o total de processos corretamente excluídos das classes às quais não pertencem, FP (falsos positivos) os processos classificados em uma classe à qual não pertencem e FN (falsos negativos) os processos que deveriam ter sido classificados em uma determinada classe mas não foram. Como o JusCritIA trata um problema multiclasse com três categorias operacionais (QOT1+QOT2, QOT3 e QOT4), o cálculo agrega acertos e erros de todas as classes simultaneamente, acumulando VP e VN sobre as três categorias.

A precisão (*precision*) mede a proporção de previsões positivas que estão corretas, indicando a confiabilidade das classificações realizadas para cada classe. Alta precisão significa que, quando o modelo prevê um processo como pertencente a uma classe crítica, essa previsão tende a estar correta, reduzindo o esforço de inspeção de falsos positivos nas listas de priorização (Sujon et al., 2025).

O *recall* (sensibilidade) mede a proporção de casos positivos reais que foram corretamente identificados pelo modelo. Alta sensibilidade indica maior capacidade de recuperar processos pertencentes a classes críticas, reduzindo o risco de subpriorização. Em termos operacionais, a precisão avalia a proporção de acertos entre os casos classificados como positivos, enquanto o *recall* avalia a proporção de acertos em relação ao total de casos positivos existentes (Sujon et al., 2025).

As expressões formais da precisão e do *recall* são, respectivamente:

$$\text{Precisão} = VP / (VP + FP)$$

$$\text{Recall} = VP / (VP + FN)$$

Nas duas expressões, VP (verdadeiros positivos) permanece no numerador, representando os acertos sobre a classe de interesse. O denominador difere entre elas. Na precisão, divide-se por VP + FP (total de classificações positivas declaradas pelo modelo). No recall, divide-se por VP + FN (total de casos positivos reais existentes na base). Essa diferença de denominador explica a tensão entre as duas métricas, pois ampliar a cobertura de casos positivos reais tende a incorporar mais FP, ao passo que reduzir os FP tende a excluir casos positivos reais.

O F1 ponderado (*F1-weighted*) é a média aritmética ponderada, pelo suporte, dos valores de F1 calculados separadamente para cada classe. Cada F1 individual corresponde à média harmônica entre precisão e recall. É a métrica central desta avaliação por sintetizar o equilíbrio entre precisão e *recall* em um problema multiclasse com distribuição assimétrica entre QOT1+QOT2, QOT3 e QOT4. Essa métrica penaliza modelos que favorecem uma dimensão em detrimento da outra, sendo adequada quando há assimetria entre os custos de falsos positivos e falsos negativos (Rainio; Teuho; Klén, 2024; Sujon et al., 2025).

Formalmente, o F1 de cada classe *i* é calculado pela média harmônica entre precisão e *recall*, conforme a expressão a seguir.

$$F1i = 2 \times (Pi \times Ri) / (Pi + Ri)$$

O fator 2 normaliza o resultado à escala [0, 1], compensando o denominador. O produto $Pi \times Ri$ (precisão multiplicada por *recall*) no numerador garante que o F1 seja zero sempre que qualquer um dos dois for zero, independentemente do valor do outro, penalizando modelos que negligenciam uma das dimensões. O F1 ponderado agrega os valores individuais de cada classe pelo suporte real, conforme a expressão a seguir.

$$F1 \text{ ponderado} = \sum (ni \times F1i) / \sum ni$$

Nessa expressão, ni (suporte da classe *i*, isto é, o número de processos que realmente pertencem à classe *i* no conjunto de teste) pondera cada F1 individual, e o somatório percorre as três classes operacionais do JusCritIA: QOT1+QOT2, QOT3 e QOT4. A ponderação assegura que classes com maior prevalência real contribuam

proporcionalmente mais para a métrica agregada, preservando fidelidade à distribuição observada no estudo de caso.

Em conjunto, acurácia, F1 ponderado e matriz de confusão são suficientes para a avaliação preditiva adotada neste trabalho, pois cobrem três dimensões complementares: desempenho global, equilíbrio multiclasse ponderado pelo suporte das classes e diagnóstico dos padrões de erro entre classes reais e previstas (Rainio; Teuho; Klén, 2024; Sujon et al., 2025; Collins et al., 2024; Provost; Fawcett, 2016).

A adoção do F1 ponderado também encontra respaldo em estudos recentes que utilizam essa métrica em tarefas de classificação supervisionada com distribuição desigual de classes. Em contexto judicial, Bhatnagar e Huchhanavar (2026) reportam *weighted F1-score* de 84,1% em tarefa de classificação voltada à predição de atraso processual em cortes inferiores indianas, demonstrando sua pertinência em problemas de gestão judicial baseados em aprendizado de máquina. No cenário jurídico brasileiro, Araujo et al. (2020), ao apresentarem o dataset VICTOR, reforçam a relevância de métricas de classificação em bases jurídicas de grande escala e com múltiplas categorias documentais. Complementarmente, Soon et al. (2024) avaliam estratégias ensemble baseadas em árvores em cenário multiclasse desbalanceado, reforçando a utilidade do F1 ponderado para sintetizar o desempenho global considerando o suporte real de cada classe.

O ganho TOP-N mede a eficiência operacional do *ranking* por CRIT_SCORE_% em relação ao *baseline* institucional DIAS_ABERTOS. A métrica quantifica a redução do volume inspecionado necessário para atingir a mesma cobertura de casos críticos dentro da capacidade semanal K. Ganho positivo indica maior concentração de processos críticos no topo da lista, reduzindo o esforço de triagem para um mesmo alvo de cobertura.

Além das métricas quantitativas, critérios qualitativos complementam a avaliação do artefato. A generalização é avaliada pela estabilidade do F1 ponderado e da acurácia ao longo dos *folds* temporais, indicando ausência de ajuste a partições específicas. A robustez é examinada pela consistência dos padrões de erro nas matrizes de confusão entre recortes operacionais distintos. A interpretabilidade é assegurada pela estrutura do CRIT_SCORE_%, cujos componentes e pesos são explicitamente definidos, permitindo rastreabilidade das saídas e compreensão pelos gestores institucionais (Kapoor et al., 2024; Semmelrock et al., 2025).

A leitura operacional das métricas foi articulada com o propósito do artefato, que é apoiar priorização processual. Assim, a interpretação dos resultados considerou, de forma explícita, a aceitabilidade de determinados tipos de erro no fluxo de trabalho. Em termos práticos, erros que reduzam a capacidade de identificar classes de maior risco tendem a impactar diretamente a efetividade da ordenação e, por consequência, a utilidade do critério de priorização derivado do modelo. Por essa razão, a avaliação não se limita a reportar métricas, mas explicita o que cada resultado implica para decisões de triagem e planejamento, conforme recomendações de reporte orientado a uso e a contexto (Kapoor et al., 2024, p. 6-9).

A avaliação foi estratificada por recortes relevantes ao domínio, incluindo variações por órgão, tarefa e demais filtros operacionais aplicados no artefato, sempre preservando o protocolo temporal estabelecido na seção anterior. Essa estratificação é necessária porque o desempenho pode variar em função de heterogeneidade institucional e diferenças de distribuição de classes entre recortes, podendo ocultar degradações localizadas quando apenas métricas globais são apresentadas. A opção por detalhar métricas por recorte reforça a transparência e reduz risco de conclusões indevidas baseadas em médias agregadas (Kapoor et al., 2024, p. 6-9).

Por fim, foram adotados cuidados explícitos para evitar interpretações indevidas em presença de desbalanceamento, instabilidade temporal e variações de prevalência entre períodos. Esses cuidados incluem reportar métricas em conjunto com a matriz de confusão, comparar resultados apenas entre janelas temporalmente consistentes e registrar condições de execução, versões e parâmetros relevantes.

Essa prática responde diretamente a barreiras metodológicas reconhecidas em pesquisas aplicadas com aprendizado de máquina, nas quais avaliação pouco transparente e documentação insuficiente comprometem verificabilidade e reprodutibilidade (Semmelrock et al., 2025, p. 7-10).

3.7 Governança, *accountability* e reprodutibilidade

A governança do artefato desenvolvido nesta pesquisa foi concebida como parte integrante do desenho metodológico, e não como elemento acessório posterior à modelagem. Em consonância com a *Design Science Research*, a qualidade científica do artefato não depende apenas de seu desempenho preditivo, mas da

existência de mecanismos explícitos que permitam controle, rastreabilidade, auditoria e responsabilização sobre seu funcionamento e uso em contexto institucional (Hevner et al., 2004, p. 80-83).

Do ponto de vista técnico, a governança do *pipeline* analítico é assegurada por meio do controle rigoroso de versões, da documentação dos parâmetros utilizados, da preservação das configurações de treino, validação e predição, e do registro sistemático das execuções. Cada resultado produzido pelo sistema pode ser associado a uma combinação específica de código, dados de entrada, parâmetros e regras de processamento, permitindo reconstrução exata do estado do artefato em determinado momento. Essa abordagem reduz ambiguidades interpretativas e impede a utilização de resultados sem lastro técnico verificável.

A rastreabilidade metodológica se estende ao tratamento dos dados e à geração dos *outputs*. As regras de filtragem, exclusão, normalização e ordenação são explicitamente documentadas, bem como as decisões relacionadas à manutenção de distribuições reais e ao não emprego de técnicas artificiais de balanceamento. Essa transparência operacional atende ao princípio de governança orientada à evidência, na qual cada decisão automatizada ou assistida pode ser explicada a partir de regras e registros objetivos, e não apenas inferida a posteriori a partir de resultados agregados.

No que se refere à *accountability*, o artefato foi projetado como instrumento de apoio à decisão, e não como mecanismo autônomo de deliberação. A responsabilidade final pelas decisões operacionais permanece atribuída aos agentes institucionais, que utilizam o CRIT_SCORE_% e os demais outputs como subsídios analíticos para priorização e alocação de esforço. Essa separação explícita entre recomendação algorítmica e decisão humana evita a transferência indevida de responsabilidade para o sistema e preserva a aderência às exigências normativas do setor público.

A leitura dos resultados é estruturada de forma a permitir inspeção crítica, incluindo a análise de matrizes de confusão, distribuição de erros e variações por recortes organizacionais. Essa estrutura foi desenhada para estimular análise reflexiva e evitar decisões baseadas apenas em números agregados, sem consideração do contexto e das limitações do modelo. Ao explicitar limites, falhas

recorrentes e assimetrias de desempenho, o artefato contribui para uma cultura institucional de uso responsável de modelos preditivos.

A reprodutibilidade, neste estudo, é tratada como requisito operacional e institucional, e não apenas como ideal acadêmico abstrato. O objetivo central não é permitir a replicação exata em ambientes artificiais ou laboratoriais, mas assegurar que terceiros possam compreender, auditar e reproduzir o comportamento do sistema a partir dos mesmos dados e configurações, dentro das restrições reais do ambiente organizacional. Barreiras clássicas à reprodutibilidade, como dependência de implementações específicas, subespecificação do *pipeline* e ausência de documentação, são mitigadas por meio de práticas sistemáticas de registro e versionamento (Semmelrock et al., 2025, p. 7-10).

No contexto de sistemas preditivos aplicados à gestão pública, essa abordagem de governança se alinha às discussões contemporâneas sobre decisões algorítmicas, nas quais eficiência operacional deve ser equilibrada com transparência, controle e responsabilidade administrativa.

Estudos recentes sobre governança de IA no setor público indicam que esse equilíbrio não emerge espontaneamente da adoção tecnológica, mas depende de mecanismos institucionais explícitos de prestação de contas, supervisão humana e definição clara de responsabilidades ao longo do ciclo de uso do sistema (Mark; Morison, 2025, p. 3-5).

O artefato não é apresentado como solução neutra ou infalível, mas como mecanismo técnico que explicita critérios, probabilidades e ordenações, cabendo à instituição definir, monitorar e revisar seus usos conforme seus objetivos organizacionais e limitações normativas.

Assim, a governança, a *accountability* e a reprodutibilidade constituem dimensões estruturantes do artefato desenvolvido, integradas desde sua concepção até sua avaliação empírica. Essa integração reforça a coerência metodológica do estudo, assegura aderência aos princípios da *Design Science Research* e sustenta a legitimidade do uso de modelos preditivos como instrumentos de apoio à decisão em contextos institucionais complexos.

3.8 Considerações éticas e limites teóricos

3.8.1 Riscos de viés, efeitos institucionais e leitura responsável

A incorporação de componentes preditivos em um artefato computacional aplicado a um ambiente institucional impõe o dever metodológico de explicitar riscos de uso e limites de interpretação. Ainda que o sistema opere sobre registros estruturados e métricas objetivas, os resultados produzidos refletem propriedades do dado observacional, do recorte adotado e das escolhas de modelagem e validação, o que exige cautela na leitura e no emprego operacional dos *outputs*. Em *Design Science Research*, essa explicitação integra o compromisso com rigor e comunicação adequada do conhecimento produzido, incluindo a comunicação de limitações relevantes para uso responsável do artefato (Hevner et al., 2004, p. 80-83).

Os riscos de viés, neste estudo, devem ser compreendidos como efeitos potenciais de assimetrias de distribuição, de heterogeneidade entre órgãos e tarefas, e de diferenças estruturais nos regimes de trabalho refletidas nos dados. Tais efeitos podem produzir variações de desempenho por recortes operacionais, deslocamentos sistemáticos de classe e padrões de erro que impactam a priorização. Por essa razão, a leitura responsável do sistema se apoia na inspeção de evidências interpretáveis, em especial matriz de confusão e métricas por recortes, evitando o uso acrítico de indicadores agregados que podem mascarar falhas relevantes em cenários desbalanceados (Collins et al., 2024, p. 6-8; Kapoor et al., 2024, p. 6-9).

A utilização do CRIT_SCORE_% como critério de priorização reforça a necessidade de leitura orientada a impacto. O critério sintetiza probabilidades preditivas e induz ordenação de atenção e esforço, o que torna os erros operacionalmente assimétricos. Nesse contexto, o uso responsável do artefato requer interpretar a ordenação como apoio à decisão e não como substituto da avaliação institucional, além de reconhecer que mudanças de contexto, variações temporais e particularidades locais podem alterar o comportamento do sistema. Assim, a avaliação foi concebida para evidenciar não apenas acertos médios, mas padrões de erro e implicações práticas para triagem e tratamento, preservando a coerência entre finalidade operacional e leitura científica do desempenho (Hevner et al., 2004, p. 80-82).

3.8.2 Limites de generalização e condições de validade

Os resultados desta pesquisa estão condicionados ao recorte empírico observacional adotado e às características do ambiente institucional no qual os dados foram produzidos. Por se tratar de um artefato projetado para um contexto operacional específico, a validade dos achados se ancora na adequação entre problema, dados, regras de preparação e protocolo de validação temporal. Em consequência, a generalização para outros tribunais, outros regimes de trabalho ou outras configurações de dados não deve ser presumida como automática, devendo ser tratada como hipótese a ser verificada por novos ciclos de avaliação e documentação, conforme o princípio de rigor e avaliação sistemática em *Design Science Research* (Hevner et al., 2004, p. 83).

A validade também depende de condições técnicas que sustentam a verificabilidade do *pipeline*. Barreiras como especificação incompleta, dependências de implementação e ausência de documentação podem comprometer a reprodução do comportamento do sistema e, por extensão, a confiança na interpretação dos resultados. Por essa razão, a pesquisa integra práticas explícitas de documentação, registro de decisões e controle de versões como condição para que terceiros possam compreender e auditar os resultados obtidos, mitigando limitações clássicas de reprodutibilidade em sistemas baseados em aprendizado de máquina (Simmelrock et al., 2025, p. 7-10; Kapoor et al., 2024, p. 7-9).

Por fim, a leitura dos outputs deve respeitar o caráter probabilístico da predição e a natureza instrumental do artefato. A classificação e a ordenação produzidas não expressam verdade material sobre o desfecho de cada processo, mas uma estimativa de risco futuro sob determinadas condições e com base em evidências históricas observadas.

Assim, a validade prática do artefato reside na sua capacidade de apoiar triagem e alocação de esforço de forma rastreável e auditável, mantendo consistência entre reporte, avaliação e comunicação de limitações, conforme diretrizes contemporâneas de transparência em estudos de modelagem preditiva (Collins et al., 2024, p. 6-8).

4 ARTEFATO E ANÁLISE DOS RESULTADOS

4.1 Descrição do artefato e do ambiente de execução

O artefato desenvolvido nesta pesquisa consiste em um sistema computacional destinado à análise preditiva e à ordenação processual com base em risco futuro, em complemento ao *baseline* institucional, concebido para operar sobre dados reais do ambiente institucional analisado. O sistema integra procedimentos de preparação de dados, modelagem preditiva, validação temporal e geração de critérios de ordenação operacional, constituindo uma solução unificada para apoio à tomada de decisão em contextos caracterizados por elevado volume de processos e restrições de capacidade operacional.

Do ponto de vista funcional, o artefato realiza a leitura das cargas semanais de dados processuais, identifica automaticamente as variáveis necessárias à análise, aplica as transformações previamente definidas no *pipeline* metodológico e executa a inferência preditiva sobre a carga corrente. Como resultado, o sistema produz classificações de risco futuro e um critério preditivo de ordenação processual, denominado CRIT_SCORE_%, utilizado em conjunto com o *baseline* institucional.

A implementação do artefato foi realizada em linguagem *Python*, com estrutura modular que separa explicitamente as etapas de ingestão de dados, pré-processamento, inferência, avaliação e exportação de resultados. Essa organização permite a rastreabilidade do processo, a inspeção das decisões intermediárias e a reprodutibilidade dos experimentos, em consonância com os princípios metodológicos estabelecidos no Capítulo 3. O sistema inclui mecanismos de registro de versões, parâmetros e *logs* de execução, permitindo reconstruir o estado do artefato em cada ciclo de análise.

O ambiente de execução foi configurado para operar em infraestrutura computacional padrão, compatível com o contexto institucional, sem dependência de recursos especializados. Essa escolha reforça o caráter aplicado da pesquisa, assegurando que o artefato possa ser executado, avaliado e eventualmente incorporado aos fluxos existentes sem barreiras técnicas adicionais. Todas as dependências de software, bibliotecas utilizadas e configurações relevantes foram

explicitamente documentadas como parte do processo de *journaling* metodológico adotado.

O ciclo de execução documentado no log de 24 de junho de 2026 registra o experimento completo que fundamenta os resultados apresentados neste capítulo. O processamento foi conduzido integralmente em notebook pessoal laboral, sem conexão com redes externas ou à internet, sobre dados previamente anonimizados, em conformidade com as diretrizes de segurança e sigilo institucional.

O carregamento sequencial das 12 cargas semanais teve início às 13:41:10 e foi concluído às 14:27:58, totalizando aproximadamente 47 minutos. Ao longo desse processo, foram processados 4.130.466 registros brutos distribuídos pelos 12 *snapshots* semanais, com média de aproximadamente 344.000 registros por carga. Após a aplicação dos filtros operacionais, o conjunto de treino efetivo em Execução Fiscal resultou em 1.812.419 amostras, excluídos os processos suspensos, arquivados ou sobrestados, que totalizaram 271.874 registros.

A validação temporal *walk-forward* com embargo = 1 foi iniciada às 14:30:55 e concluída às 14:44:39, totalizando aproximadamente 14 minutos sobre os 5 *folds*. O *fold* 1 foi concluído às 14:33:31, com 830.754 amostras de treino; o *fold* 2 às 14:36:47, com 994.914 amostras; o *fold* 3 às 14:39:07, com 1.158.775 amostras; o *fold* 4 às 14:41:59, com 1.322.480 amostras; e o *fold* 5 às 14:44:39, com 1.485.904 amostras. O modelo final foi serializado e salvo às 14:46:54.

O log confirma explicitamente as features utilizadas no treinamento: ORGAO_JULGADOR, TAREFA, DIAS_ABERTOS e PCTL_OT, com registro de que SEMANA_ANO e QOT_FUTURO foram excluídas do conjunto de entrada, preservando a integridade do protocolo temporal. A distribuição global das classes no conjunto de treino foi: QOT1+QOT2 com 906.818 amostras, QOT3 com 454.368 amostras e QOT4 com 451.233 amostras. As métricas OOF foram calculadas sobre 817.505 previsões fora da amostra, com F1 ponderado médio de 0,8387 e acurácia média de 0,8392, conforme registrado no log às 14:44:39.

O ciclo completo, do início do carregamento ao salvamento do modelo, levou aproximadamente 66 minutos. Esse resultado demonstra a viabilidade computacional do artefato em ambiente institucional sem infraestrutura especializada, em

conformidade com o critério de restrição computacional que orientou a escolha do LightGBM descrita na seção 3.3.1.

Do ponto de vista operacional, o artefato foi projetado para atuar exclusivamente como instrumento de apoio à decisão, não realizando qualquer intervenção automática nos fluxos institucionais. A saída do sistema consiste em informações analíticas e ordenações que subsidiam a atuação humana, preservando a responsabilização decisória e mitigando riscos associados à automação indevida. Essa delimitação funcional é coerente com as preocupações de governança e *accountability* discutidas no Capítulo 3 e será retomada na análise dos resultados e nas considerações finais.

A descrição do artefato e do ambiente de execução estabelece a base necessária para a análise empírica apresentada nas seções subsequentes. A partir desse ponto, os resultados passam a ser examinados por meio de métricas globais preditivas, inspeção das matrizes de confusão por recorte, análise operacional por dispersões e eficiência TOP-N, em comparação com o *baseline* institucional DIAS_ABERTOS, antes da discussão integrada à luz da questão de pesquisa e da *Design Science Research (DSR)*.

4.1.1 Critérios de avaliação empírica e parâmetros de aceitação

Para garantir objetividade na avaliação do JusCritIA, esta seção define os critérios quantitativos e operacionais que orientam a interpretação dos resultados, organizados em três dimensões complementares.

A avaliação empírica foi organizada a partir de três hipóteses avaliativas: H1, validade preditiva; H2, adequação do núcleo preditivo; e H3, utilidade operacional. Cada hipótese foi associada a um critério de avaliação, conforme descrito a seguir.

H1/C1, validade preditiva: o classificador QOT mantém desempenho estável fora da amostra sob os atributos de tempo e histórico operacionalizados no modelo. O parâmetro de aceitação é a consistência de F1 ponderado e acurácia ao longo dos *folds*, com variação limitada entre janelas temporais sob validação *walk-forward* com embargo = 1.

H2/C2, adequação do núcleo preditivo: o LightGBM sustenta desempenho estável fora da amostra no problema QOT, com perfil de erro compatível com triagem,

predominância de confusões entre classes adjacentes (QOT3↔QOT4) e ocorrência residual do pior caso (QOT4 real previsto como QOT1+QOT2).

H3/C3, utilidade operacional: o CRIT_SCORE_% produz ganho mensurável de eficiência de triagem em relação ao *baseline* DIAS_ABERTOS nas listas TOP-N, demonstrado pela redução do volume inspecionado necessário para capturar a mesma cobertura de casos críticos dentro da capacidade semanal K.

Os critérios definidos nesta subseção orientam a interpretação integrada dos resultados apresentados nas seções seguintes.

4.2 Caracterização das cargas analisadas e recortes operacionais

A análise empírica realizada neste estudo se baseia em um conjunto de cargas semanais de dados processuais, temporalmente ordenadas e consistentes com o funcionamento real do ambiente institucional analisado. Cada carga representa um retrato operacional do acervo em um determinado instante no tempo, preservando a distribuição original dos processos, tarefas e estados, sem qualquer intervenção corretiva artificial.

As cargas foram estruturadas a partir de extrações periódicas, identificadas por um marcador temporal discreto (*SNAPSHOT_IDX*), que permite ordenar cronologicamente os dados e viabilizar tanto a validação temporal quanto a análise evolutiva do desempenho do artefato. Essa organização reflete o regime real de atualização dos sistemas institucionais e assegura aderência entre o desenho metodológico e as condições efetivas de uso do sistema.

Tabela 2 Cargas semanais (12 *snapshots*)

<i>SNAPSHOT_IDX</i>	<i>Data</i>	<i>Arquivo</i>	<i>Registros</i>
0	15/08/2025	20250815080214_TJPEReports_CARGA_12_1508.xlsx	347.092
1	22/08/2025	20250822072628_TJPEReports_CARGA_11_2208.xlsx	346.823
2	29/08/2025	20250829071223_TJPEReports_CARGA_10_2908.xlsx	346.261
3	05/09/2025	20250905092310_TJPEReports_CARGA_9_0509.xlsx	344.945
4	12/09/2025	20250912081745_TJPEReports_CARGA_8_1209.xlsx	343.534
5	19/09/2025	20250919120042_TJPEReports_CARGA_7_1909.xlsx	343.400
6	26/09/2025	20250926132601_TJPEReports_CARGA_6_2609.xlsx	343.431
7	03/10/2025	20251003090020_TJPEReports_CARGA_5_0310.xlsx	343.020
8	10/10/2025	20251010120054_TJPEReports_CARGA_4_1010.xlsx	342.745
9	17/10/2025	20251017124733_TJPEReports_CARGA_3_1710.xlsx	342.350

SNAPSHOT_IDX	Data	Arquivo	Registros
10	24/10/2025	20251024120022_TJPEReports_CARGA_2_2410.xlsx	342.909
11	31/10/2025	20251031120502_TJPEReports_CARGA_1_3110.xlsx	343.956

Fonte: Elaborada pelo autor a partir do log do JusCritIA, 24 jun. 2026.

As cargas apresentadas na Tabela 2 correspondem aos 12 snapshots históricos utilizados no treinamento e na validação temporal do modelo. Após essa etapa, o arquivo 20251107120037_TJPEReports_CARGA_0_0711.xlsx corresponde à carga corrente de aplicação do modelo treinado, enquanto o arquivo 20251114120742_TJPEReports_CARGA_t+1_1411.xlsx corresponde à carga observada uma semana depois, utilizada para verificação temporal posterior das previsões geradas. A partir dessa organização, a Tabela 3 apresenta o pareamento entre as cargas no tempo t e $t+1$, bem como a quantidade de pares com rótulo utilizados na avaliação temporal.

Tabela 3 Pareamento t e $t+1$ e pares com rótulo

t_idx	t+1_idx	Registros em t	Registros em t+1	Pares com rótulo (pares_com_y)
0	1	347.092	346.823	345.963
1	2	346.823	346.261	344.870
2	3	346.261	344.945	343.883
3	4	344.945	343.534	342.676
4	5	343.534	343.400	342.137
5	6	343.400	343.431	342.344
6	7	343.431	343.020	341.909
7	8	343.020	342.745	341.615
8	9	342.745	342.350	341.304
9	10	342.350	342.909	340.925
10	11	342.909	343.956	340.948

Fonte: Elaborada pelo autor a partir do log do JusCritIA, 24 jun. 2026.

Na Tabela 3, t_idx identifica a carga na semana t e $t+1_idx$ identifica a carga da semana seguinte, utilizada como referência observada para rotulagem supervisionada. O campo “pares com rótulo (pares_com_y)” representa a quantidade de registros da carga t que puderam ser pareados com a carga $t+1$ por NPU (Numeração Processual Única) e que, portanto, receberam o rótulo observado QOT_FUTURO para fins de avaliação do classificador. Em termos práticos, $pares_com_y$ conta registros de t cujo NPU também está presente em $t+1$, permitindo anexar o rótulo observado. A diferença entre o total de registros em t e $pares_com_y$

decorre de registros que não puderam ser pareados entre semanas consecutivas, por exemplo, NPUs que aparecem apenas em uma das cargas ou que não atendem às regras de pareamento adotadas no *pipeline*.

Operacionalmente, o artefato executa o ciclo semanal de treinamento, aplicação e verificação em duas rodadas. Na primeira, o histórico configurado é utilizado para o treinamento do classificador QOT e o modelo resultante é aplicado sobre a carga corrente (t), gerando QOT_PRED e a ordenação CRIT_SCORE_%, que compõem a saída operacional exportada. Na segunda, destinada exclusivamente à verificação supervisionada, a carga observada uma semana depois é utilizada apenas para rotular a carga corrente por pareamento de NPU, permitindo comparar QOT_PRED(t) com QOT_FUTURO($t+1$) sem integração dessa carga posterior ao conjunto de treinamento. As evidências de avaliação são então geradas por meio das matrizes de confusão e demais visualizações previstas no artefato, com aplicação de recortes operacionais.

Do ponto de vista do conteúdo, as cargas incluem registros em SUSP (suspensos), ARQ (arquivados) e SOBR (sobrestados), pois esses estados fazem parte do acervo real e permanecem analisáveis para fins descritivos e de rastreabilidade. No pipeline, a marcação desses estados segrega o conjunto em dois grupos: “out_susp_arq_sobr”, utilizado no treino efetivo, e “susp_arq_sobr”, mantido separado para controle e auditoria, conforme os volumes reportados na Tabela 4. Quando um processo deixa SUSP, ARQ ou SOBR e retorna ao fluxo ativo nas cargas semanais, ele volta a compor o conjunto elegível nas cargas em que esse retorno é observado.

Tabela 4 Volumes e filtros aplicados no treinamento do QOT em EF

Etapas	Registros
Total de registros processados (12 cargas)	4.130.466
Registros para treinamento	3.768.574
Marcação SUSP, ARQ, SOBR, grupo “out_susp_arq_sobr” (mantido para treino)	3.200.014
Marcação SUSP, ARQ, SOBR, grupo “susp_arq_sobr” (separado)	568.560
Após filtro EF (Execução Fiscal) por CLASSE_PROCESSUAL	2.739.546
Após filtro UNIDADES_EF_EXCLUSIVAS (órgãos com competência exclusiva em EF)	2.084.293
EF geral, out_susp_arq_sobr (treino efetivo)	1.812.419
EF geral, susp_arq_sobr (excluído do treino efetivo)	271.874
Volume LOCAL_TAREFA = DIRETORIA (apenas informativo, sem filtrar)	1.251.938

Fonte: Elaborada pelo autor a partir do log do JusCritIA, 24 jun. 2026.

Tabela 5 Distribuição do treino efetivo por *snapshot*

SNAPSHOT_IDX	Registros no treino
0	166.492
1	166.291
2	166.529
3	166.509
4	164.933
5	164.160
6	163.861
7	163.705
8	163.424
9	163.077
10	163.438

Fonte: Elaborada pelo autor a partir do log do JusCritIA, 24 jun. 2026.

Para fins analíticos, os dados foram recortados segundo dimensões operacionais relevantes ao contexto institucional, incluindo órgão julgador, tarefa e perspectiva de atuação. Esses recortes não alteram o funcionamento do modelo, mas permitem avaliar a estabilidade do desempenho e da ordenação gerada em diferentes contextos organizacionais, identificando eventuais assimetrias ou padrões localizados de erro.

Adicionalmente, as cargas foram analisadas respeitando a separação entre carga corrente e histórico utilizado para treinamento, conforme o protocolo de validação temporal descrito no Capítulo 3. Essa separação assegura que os resultados apresentados nas seções seguintes reflitam exclusivamente o comportamento do artefato em condições prospectivas, sem contaminação por informação futura.

O treinamento e a validação temporal do classificador QOT foram restritos ao escopo EF (Execução Fiscal) e, adicionalmente, ao subconjunto de unidades com competência exclusiva em EF, conforme o filtro UNIDADES_EF_EXCLUSIVAS. As análises apresentadas nas seções subsequentes utilizam recortes operacionais para leitura e comparação, consistentes com as listas *TOP-N* e com a leitura institucional, incluindo EF Geral, VEFE (Execução Fiscal Estadual) e VEFM (Execução Fiscal

Municipal), com estratificações por LOCAL_TAREFA (Diretoria e Gabinete), além do destaque do melhor desempenho observado no recorte VEFE Gabinete.

A caracterização das cargas analisadas estabelece, portanto, o contexto empírico necessário para a avaliação do desempenho preditivo global do modelo, que passa a ser examinada na seção seguinte a partir de *benchmarks* quantitativos e evidências derivadas da matriz de confusão.

4.3 Desempenho preditivo global do modelo

O desempenho preditivo global do artefato foi avaliado pela aplicação do modelo às cargas correntes, respeitando o protocolo de validação temporal descrito no Capítulo 3. A avaliação considerou exclusivamente previsões fora da amostra de treinamento, de modo que os resultados reflitam comportamento prospectivo e não ajuste retrospectivo aos dados históricos.

Tabela 6 Estrutura da validação cruzada temporal com embargo = 1

<i>Fold</i>	<i>snapshots</i> de treino	<i>snapshot</i> de embargo (<i>gap</i>)	<i>snapshot</i> de teste	<i>n_train</i>	<i>n_test</i>
1	[0, 1, 2, 3, 4]	[5]	[6]	830.754	163.861
2	[0, 1, 2, 3, 4, 5]	[6]	[7]	994.914	163.705
3	[0, 1, 2, 3, 4, 5, 6]	[7]	[8]	1.158.775	163.424
4	[0, 1, 2, 3, 4, 5, 6, 7]	[8]	[9]	1.322.480	163.077
5	[0, 1, 2, 3, 4, 5, 6, 7, 8]	[9]	[10]	1.485.904	163.438

Fonte: Elaborada pelo autor a partir do log do JusCritIA, 24 jun. 2026.

A análise global tem como objetivo verificar se o classificador mantém estabilidade preditiva ao longo das janelas temporais testadas. Para isso, foram examinadas métricas agregadas por *fold* e estatísticas fora da amostra, reportadas nas Tabelas 7 e 8.

Tabela 7 Desempenho por *fold* (F1-weighted e acurácia)

<i>Fold</i>	F1-weighted	Acurácia
1	0,8378	0,8411
2	0,8233	0,8216
3	0,8488	0,8490
4	0,8417	0,8413
5	0,8418	0,8428

Fonte: Elaborada pelo autor a partir do log do JusCritIA, 24 jun. 2026.

Tabela 8 Estatísticas agregadas fora da amostra (*Out-of-Fold*, OOF)

Métrica	Média	Variância amostral	Desvio-padrão amostral
<i>F1-weighted</i>	0,8387	0,000089230	0,009446
Acurácia	0,8392	0,000106444	0,010317

Fonte: Elaborada pelo autor a partir do log do JusCritIA, 24 jun. 2026

Nota: OOF (*Out-of-Fold*, fora da amostra) $n = 817.505$, $mean_F1 = 0,8387$, $mean_Acc = 0,8392$, embargo = 1.

A Tabela 8 reporta, além das médias, a variância amostral e o desvio-padrão amostral das métricas ao longo dos cinco *folds*. Esses valores evidenciam que o desempenho não depende de uma única partição, pois é observado em múltiplas janelas de teste, com embargo (*gap*) de 1 *snapshot* entre treino e teste. A avaliação agrega previsões OOF (*Out-of-Fold*, fora da amostra), geradas apenas nos *snapshots* de teste de cada *fold*.

Nesta avaliação, o desvio-padrão do *F1-weighted* foi 0,0094 e o da acurácia foi 0,0103, indicando oscilação típica de aproximadamente 1,0 ponto percentual entre *folds*. Esses resultados devem ser lidos em conjunto com o porte do experimento: o treinamento efetivo utilizou 1.812.419 amostras no recorte EF, grupo *out_susp_arq_sobr*, e a avaliação fora da amostra agregou OOF $n = 817.505$ previsões. Assim, as médias reportadas sintetizam desempenho repetido em janelas temporais sucessivas, com dispersão controlada no conjunto testado.

Os valores das Tabelas 7 e 8 indicam desempenho global estável do classificador nas janelas temporais avaliadas, sob validação *walk-forward* com embargo = 1.

A Tabela 9 reúne estudos empíricos recentes de IA aplicada ao domínio jurídico com pontos de comparabilidade parcial em problema, escala, algoritmo ou métrica, permitindo situar o desempenho do JusCritIA no contexto da literatura sem pressupor equivalência direta entre os experimentos.

Tabela 9 *Benchmark* contextual de métricas em estudos jurídicos com IA

Métrica / aspecto	JusCritIA (2026)	Lage-Freitas et al. (2022)	Oliveira et al. (2022)	Resck et al. (2025)	Sobrinho et al. (2026)	Bhatnagar e Huchhanavar (2026)
Tipo de problema	Classificação preditiva de criticidade	Classificação binária de decisões	Predição de duração processual	Classificação multilabel de temas de	Priorização preditiva de casos com	Predição de atraso e duração

Métrica / aspecto	JusCritIA (2026)	Lage-Freitas et al. (2022)	Oliveira et al. (2022)	Resck et al. (2025)	Sobrinho et al. (2026)	Bhatnagar e Huchhanavar (2026)
	processual (QOT futuro)	judiciais	(dias para sentença)	repercussão geral	maior chance de finalização em seis meses	processual em cortes inferiores indianas
Dataset	Execuções Fiscais DEFFA/TJPE	Acórdãos de tribunais brasileiros	TRT5, Salvador/BA	Recursos Extraordinários e ARE do STF	Dados administrativos do sistema PIE, Módulo de <i>Atención Temprana</i> , Zacatecas	Casos criminais de cortes inferiores da Índia
Total utilizado	4.130.466 registros processados; 1.812.419 no treino efetivo filtrado; 817.505 previsões OOF	4.043 casos finais	Mais de 330.000 processos; ~8 milhões de registros	105.126 processos originais; 34.028 com tópico identificado. 10.710 documentos no dataset final	Dados históricos de 2014 a 2024; mais de 234.000 investigações no sistema PIE	22,4 milhões de casos criminais
Algoritmo	<i>LightGBM</i>	ML clássico e <i>Deep Learning</i>	<i>MLP; Gradient Boosting; AdaBoost; Regressive Stacking; SVR</i>	<i>Logistic Regression</i> (principal); <i>LightGBM, XGBoost, RF, AdaBoost, SVM, BERT</i> (comparativo)	<i>Random Forest; Extra Trees; Logistic Regression; Decision Tree</i>	AutoML; modelos ensemble baseados em árvores; XAI
Protocolo de validação	<i>walk-forward</i> temporal, embargo = 1; 5 janelas	Divisão aleatória treino/teste	Divisão aleatória treino/teste	Divisão aleatória estratificada 70/10/20%; <i>cross-validation 5-fold</i>	Divisão temporal simples	Modelagem supervisionada com classificação de atraso e regressão de duração
Métrica	<i>F1-weighted</i> ; acurácia; matriz de confusão	<i>F1-score</i>	R^2 ; acurácia após discretização	<i>AUPRC</i> e <i>AUC</i> (principais); <i>F1</i> e acurácia	<i>Precision@300</i> ; <i>Recall@300</i>	Acurácia; weighted <i>F1-score</i> ; RMSE
Resultado	<i>F1-weighted</i> : 0,8387 ; <i>ACC</i> : 0,8392	~80,2%	$R^2 = 0,819$; <i>ACC</i> : 84%	<i>LGBM ACC</i> : 0,97 ; <i>Balanced ACC</i> : 0,90 ; <i>F1</i> = 0,83	<i>Random Forest</i> com <i>Precision@300</i> médio de 0,74	Acurácia de 80%; weighted <i>F1-score</i> de 84,1%; redução de RMSE nos modelos de duração
OBS	Único estudo com validação temporal prospectiva; problema multiclasse ordinal com heterogeneidade de institucional	Classificação binária sem restrição temporal; dataset menor	Tarefa de regressão ; métricas não comparáveis diretamente	<i>F1</i> e acurácia referem-se ao <i>LightGBM</i> em análise comparativa para um tópico específico ; modelo principal usa <i>AUPRC</i>	Avalia lista ranqueada semanal de 300 casos; não é comparável diretamente ao <i>F1-weighted</i> do JusCritIA	Benchmark contextual: estudo judicial de grande escala, mas voltado à predição de atraso/duração processual; não

Métrica / aspecto	JusCritIA (2026)	Lage- Freitas et al. (2022)	Oliveira et al. (2022)	Resck et al. (2025)	Sobrinho et al. (2026)	Bhatnagar e Huchhanavar (2026)
						é diretamente equivalente à classificação semanal de criticidade QOT do JusCritIA

Fonte: Elaborada pelo autor

A inclusão de Bhatnagar e Huchhanavar (2026) amplia o *benchmark* contextual ao acrescentar um estudo judicial recente e de grande escala que também reporta *F1-score weighted*, reforçando a pertinência dessa métrica em tarefas de classificação aplicadas à gestão judicial. Ainda assim, a comparação permanece parcial, pois o estudo indiano prediz atraso e duração processual, enquanto o JusCritIA classifica criticidade futura semanal em classes QOT.

A métrica *Precision@300* reportada por Sobrinho et al. (2026) não é diretamente comparável ao *F1-weighted* do JusCritIA, pois avalia a precisão dos 300 primeiros casos de uma lista ranqueada para um alvo binário de finalização em seis meses. No JusCritIA, a avaliação principal considera classificação multiclasse de criticidade futura semanal, com acurácia, *F1-weighted* e matriz de confusão.

O contexto analítico do JusCritIA é mais exigente do que o observado nos estudos selecionados. A base totaliza 4.130.466 registros processados, com 817.505 previsões fora da amostra produzidas sob validação *walk-forward* com embargo igual a 1. O problema é multiclasse ordinal com heterogeneidade estrutural entre órgãos e trajetórias processuais, o que supera em complexidade tanto a classificação binária de Lage-Freitas et al. (2022) quanto a predição de duração de Oliveira et al. (2022).

Nesse contexto, o F1 ponderado de 0,8387 e a acurácia de 0,8392 posicionam o JusCritIA em patamar competitivo frente à literatura selecionada. O resultado supera o F1 de ~80,2% de Lage-Freitas et al. (2022, abstract, p. 1), obtido em problema binário com 4.043 casos. Em relação a Resck et al. (2025), o F1 de 0,83 atribuído ao LightGBM refere-se a uma análise comparativa de modelos para o Tópico 800 especificamente, com divisão aleatória estratificada (Resck et al., 2025, p. 51), e não ao desempenho geral do sistema, cujas métricas principais são AUPRC e AUC

(Seção 5.1.2, p. 18). Oliveira et al. (2022, abstract, p. 1), por sua vez, trata de tarefa de regressão de duração processual, o que torna a leitura apenas contextual.

A diferença mais relevante entre o JusCritIA e os demais estudos está no protocolo de validação. Os estudos do *benchmark* baseados em divisão aleatória, Lage-Freitas et al. (2022), Oliveira et al. (2022) e Resck et al. (2025), não respeitam a ordem cronológica dos dados, o que pode permitir que padrões de períodos futuros influenciem o treinamento e tende a produzir estimativas mais otimistas. O protocolo *walk-forward* com embargo = 1 funciona de forma oposta: em cada uma das 5 janelas, o modelo é treinado exclusivamente com dados anteriores ao período avaliado, e uma janela de embargo é interposta para evitar contaminação por processos ainda em evolução. Esse protocolo reproduz as condições reais de uso operacional, tornando o F1 ponderado de 0,8387 uma estimativa mais conservadora e mais confiável do que os valores reportados nos estudos comparados.

Métricas agregadas, contudo, não descrevem como os acertos e erros se distribuem entre as classes nem quais padrões de erro predominam. Por esse motivo, a seção 4.4 aprofunda a análise por meio da matriz de confusão e dos padrões de erro por recorte operacional, o que é decisivo para sustentar a leitura do CRIT_SCORE_% e das listas TOP-N.

4.3.1 Análise de sensibilidade ao balanceamento de classes

Como análise complementar de sensibilidade, comparou-se a configuração final do modelo, sem ponderação automática de classes (*class_weight=None*), com uma configuração alternativa baseada em ponderação automática (*class_weight="balanced"*). A configuração final apresentou *F1-weighted* de 0,8387 e acurácia de 0,8392, enquanto a configuração ponderada apresentou *F1-weighted* de 0,8435 e acurácia de 0,8424.

Embora a configuração com ponderação tenha alcançado desempenho médio ligeiramente superior, a diferença observada foi reduzida: 0,48 ponto percentual no *F1-weighted* e 0,32 ponto percentual na acurácia. Além disso, a configuração final apresentou menor dispersão entre os *folds* temporais, indicando comportamento mais estável ao longo das janelas de validação. Uma explicação plausível é que a ponderação automática amplifica o peso relativo das classes menos frequentes

durante o treinamento, o que pode aumentar a sensibilidade do modelo a oscilações na composição das classes entre diferentes períodos.

Dessa forma, considerando a proximidade das métricas globais, a maior estabilidade temporal e a aderência à distribuição empírica observada no cenário operacional, adotou-se a configuração sem ponderação automática como modelo definitivo.

4.3.2 Importância dos atributos do modelo QOT

A Tabela 10 apresenta a importância global dos atributos do modelo QOT, calculada pelo ganho acumulado dos splits do LightGBM, com as categorias do One-Hot Encoding agregadas em suas features originais e os valores normalizados para totalizar 100%.

Tabela 10 Importância dos atributos do modelo QOT

Atributo	Ganho acumulado	Importância normalizada
PCTL_OT	10.854.678,7004	78,80%
DIAS_ABERTOS	1.316.848,6552	9,56%
TAREFA	1.312.195,1380	9,53%
ORGAO_JULGADOR	290.493,2629	2,11%

Fonte: Elaborada pelo autor a partir do log do JusCritIA, 24 jun. 2026.

Nota: O log registra esses valores como ganho normalizado do LightGBM.

Esses percentuais representam o ganho interno normalizado dos splits do LightGBM, isto é, a contribuição relativa de cada variável para a redução da função de perda ao longo das divisões das árvores, e não correspondem a percentual de acerto, proporção de variância explicada, aumento direto de desempenho preditivo ou efeito causal. Trata-se de uma medida descritiva do comportamento interno do modelo treinado, sensível à parametrização, à cardinalidade das variáveis e à amostra utilizada. Adicionalmente, como o PCTL_OT é derivado de DIAS_ABERTOS, ORGAO_JULGADOR e TAREFA, as variáveis apresentam dependência estrutural entre si, de modo que o ganho pode ser distribuído entre preditores correlacionados ou funcionalmente relacionados. Por essa razão, as importâncias reportadas não

devem ser lidas isoladamente como medida de relevância intrínseca de cada atributo, mas como indicativo agregado das dimensões utilizadas pelo modelo para discriminar as classes QOT (Molnar et al., 2024; Ibebuchi, 2025). Essa leitura cautelosa é consistente com os princípios de transparência e auditabilidade adotados neste estudo, ao explicitar tanto o que a métrica informa quanto os limites do que ela permite concluir.

4.3.3 Análise de ablação do PCTL_OT

A ablação foi conduzida na mesma configuração final do modelo, sem ponderação automática de classes (*class_weight=None*), mantendo-se dados, filtros, *snapshots*, *target*, *folds* temporais, embargo, hiperparâmetros e *seed*; a única diferença experimental foi a retirada do atributo PCTL_OT.

Essa equivalência de protocolo reforça a validade da comparação, pois a importância por ganho descreve o uso interno da variável, enquanto a ablação mede diretamente a perda de desempenho fora da amostra quando o atributo é removido (Molnar et al., 2024; Ibebuchi, 2025).

Tabela 11 Ablação do PCTL_OT

Modelo	F1-weighted	Acurácia
Final, com PCTL_OT	0,8387	0,8392
Sem PCTL_OT	0,5688	0,5730
Diferença	-26,99 p.p.	-26,62 p.p.

Fonte: Elaborada pelo autor a partir do log do JusCritIA, 24 jun. 2026.

Nota: O teste sem PCTL_OT registrou OOF com mean_F1=0.5688 e mean_Acc=0.5730.

A fim de verificar a contribuição do PCTL_OT para o desempenho do classificador, conduziu-se experimento de ablação no qual o modelo foi retreinado sob o mesmo protocolo de validação temporal walk-forward, com hiperparâmetros e janelas idênticos, mas sem essa variável. A retirada do PCTL_OT reduziu o F1 ponderado médio de 0,8387 para 0,5688 e a acurácia média de 0,8392 para 0,5730, quedas de cerca de 27 pontos percentuais, com deterioração consistente nos cinco folds temporais.

O resultado indica que DIAS_ABERTOS, TAREFA e ORGAO_JULGADOR, isoladamente ou em conjunto, não recuperaram desempenho equivalente sem a posição percentual intragrupo sintetizada pelo PCTL_OT. Essa evidência é coerente com a definição do alvo, pois a classe QOT é construída a partir dos quartis de DIAS_ABERTOS por órgão julgador e tarefa, de modo que o PCTL_OT representa a informação mais diretamente alinhada à estrutura da variável predita. A literatura sobre representações baseadas em posição relativa ou rank é mobilizada apenas para sustentar essa escolha de engenharia de atributos, sem atribuir interpretação causal aos resultados do JusCritIA, cuja leitura permanece estritamente preditiva (Cornell; Mitchell; Roughan, 2024; Dempster; Schmidt; Webb, 2024; Rosenblatt et al., 2024).

4.4 Análise das matrizes de confusão e padrões de erro

A matriz de confusão concentra a interpretação da validade preditiva, pois explicita como as classes observadas em $t+1$ (QOT_FUTURO) se relacionam com as classes previstas na carga t (QOT_PRED). Diferentemente de métricas agregadas, essa análise permite identificar quais erros ocorrem, com que intensidade e quais deles importam do ponto de vista operacional.


Nesse sentido, ela é lida como uma comparação entre QOT_PRED(t) e QOT_FUTURO($t+1$), isto é, entre a previsão gerada na carga t e o rótulo observado na carga seguinte. Nesta seção, a leitura prioriza o impacto na triagem, em especial a distinção entre erros adjacentes, mais toleráveis na operação, e o pior caso, quando um processo QOT4 é previsto como QOT1+QOT2, pois esse cenário concentra o principal risco de falso negativo operacional.

Como ponto de partida dessa leitura, a Figura 3 apresenta a matriz de confusão do recorte EF Geral, adotada como referência inicial para a interpretação dos padrões de acerto e erro do classificador. Esse recorte agregado permite visualizar, em uma mesma estrutura, a distribuição global das previsões corretas, das confusões entre classes adjacentes e da ocorrência residual do erro mais sensível para a operação. A partir dessa referência, se torna possível examinar, nas figuras seguintes, se esse mesmo comportamento se mantém ou se se altera quando a análise é estratificada pelos demais recortes operacionais.

Figura 3 Matriz de confusão, EF Geral

Matriz de Confusão (Real (t+1)=QOT_FUTURO) Perspectiva: Base EF | Local: Geral

Total: 164,165 | Acurácia: 81,1%



Fonte: Elaborada pelo autor a partir das saídas do JusCritIA, 24 jun. 2026.

Nos recortes avaliados, o padrão dominante é a confusão entre classes adjacentes, principalmente $QOT3 \leftrightarrow QOT4$, o que é coerente com QOT3 como classe de fronteira entre o grupo menos crítico (QOT1+QOT2) e a classe de maior risco (QOT4). Em termos práticos, parte dos QOT3 reais é prevista como QOT4 e parte dos QOT4 reais é prevista como QOT3, refletindo uma zona de sobreposição em que o risco observado tende a variar de forma gradual, e não por saltos abruptos. Esse comportamento é esperado em problemas de classificação ordinal, em que as classes são adjacentes no significado operacional.


Esse tipo de erro preserva parcialmente a leitura de risco, pois desloca o caso para uma classe próxima e mantém o processo no “bloco crítico” de atenção (QOT3/QOT4), diferentemente de uma confusão entre extremos. Do ponto de vista operacional, esse padrão é mais tolerável porque tende a reorganizar a prioridade dentro do conjunto que cabe na capacidade semanal, mas raramente reclassifica um caso de alto risco como não crítico. Assim, o impacto típico é ajustar a ordem de tratamento entre casos críticos, e não “perder” processos que deveriam estar sob atenção.

A partir desse padrão geral, as matrizes a seguir permitem verificar se a mesma lógica se mantém quando o acervo é estratificado por recortes operacionais. O objetivo é comparar EF Geral, VEFÉ, VEFM e, quando aplicável, os recortes por Local, para identificar se há mudanças relevantes no equilíbrio entre cobertura de

QOT4 e contaminação por QOT3, sem perder de vista o erro mais sensível, QOT4 previsto como QOT1+QOT2. Essa leitura orienta a escolha de uma estratégia de triagem mais conservadora, priorizando a cobertura de QOT4 quando houver conflito.

As Figuras 4 e 5 apresentam as matrizes de confusão dos recortes sob as perspectivas VEFE Geral e VEFM Geral, permitindo observar como o padrão de classificação se comporta quando o acervo de Execuções Fiscais é separado por competência estadual e municipal.


Figura 4 Matriz de confusão, VEFE Geral



Fonte: Elaborada pelo autor a partir das saídas do JusCriticA, 24 jun. 2026.

Na matriz de confusão da VEFE Geral, o erro operacionalmente mais sensível corresponde aos processos com QOT4 real classificados como QOT1+QOT2, pois esse caso equivale, na leitura binarizada entre casos críticos e não críticos, a um falso negativo severo de alto risco. No recorte, esse evento ocorreu em 117 registros, equivalentes a 0,50% do total de predições, indicando baixa incidência desse tipo de erro em relação ao volume analisado. A maior concentração de erros permanece nas confusões entre classes adjacentes, especialmente entre QOT3 e QOT4, o que é mais tolerável na prática de gestão, pois mantém os processos em faixas superiores de atenção. Assim, a matriz sugere que, para VEFE Geral, o modelo preserva a capacidade de triagem dos casos críticos, com risco residual baixo de rebaixamento extremo de processos efetivamente críticos.

Figura 5 Matriz de confusão, VEFM Geral



Fonte: Elaborada pelo autor a partir das saídas do JusCriticA, 24 jun. 2026.

Na matriz de confusão da VEFM Geral, o falso negativo severo também corresponde ao QOT4 real previsto como QOT1+QOT2. Nesse recorte, foram observados 923 casos, equivalentes a 0,89% do total, percentual ainda baixo diante do volume analisado. Embora o número absoluto seja maior do que no recorte VEFE Geral, a leitura proporcional indica que o erro extremo permanece controlado. Também aqui, as principais confusões tendem a ocorrer entre classes adjacentes, sobretudo entre QOT3 e QOT4, o que reduz o impacto operacional em comparação com deslocamentos diretos de QOT4 para QOT1+QOT2. Portanto, a matriz da VEFM Geral indica desempenho compatível com uso em triagem assistida, desde que os falsos negativos severos continuem sendo monitorados em auditorias periódicas do artefato.


Esse resultado é relevante porque indica que o modelo raramente desloca um caso de QOT4 para o grupo menos crítico, reduzindo o risco operacional mais danoso. Isso significa que o erro mais sensível tende a ocorrer de forma residual nos recortes analisados.

Ao mesmo tempo, o fato de não ser zero reforça que a triagem deve manter salvaguardas operacionais, principalmente na definição da capacidade semanal K e na leitura conjunta com o *baseline* DIAS_ABERTOS. Na prática, essa combinação

reduz a chance de um QOT4 real, mesmo quando estimado com risco menor pelo modelo, deixar de ser selecionado na triagem semanal, o que será retomado na análise de priorização da seção seguinte.


As Figuras 6, 7 e 8 aprofundam a análise por recortes operacionais mais específicos, considerando VEFE Diretoria, VEFE Gabinete e VEFE Gabinete. Esses recortes permitem verificar a manutenção dos padrões de erro e acerto em contextos institucionais distintos, evidenciando também a heterogeneidade dos dados conforme o local de tramitação.

Figura 6 Matriz de confusão, VEFE Diretoria




Fonte: Elaborada pelo autor a partir das saídas do JusCrtIA, 24 jun. 2026.

Na matriz de confusão da VEFE Diretoria, o erro mais sensível corresponde ao QOT4 real previsto como QOT1+QOT2. Esse evento ocorreu em 105 registros, equivalentes a 0,52% do total de predições e a 2,0% da classe QOT4 real, indicando baixo rebaixamento extremo de casos críticos. A maior parte dos QOT4 reais foi corretamente classificada como QOT4, com 4.230 registros, equivalentes a 82,4% da classe. A confusão mais relevante ocorreu entre QOT4 e QOT3, com 796 registros, situação menos gravosa do ponto de vista operacional, pois mantém os processos em faixa elevada de atenção. Assim, o recorte VEFE Diretoria apresenta desempenho consistente para triagem prioritária, com acurácia global de 84,4%.

Figura 7 Matriz de confusão, VEFM Gabinete

Fonte: Elaborada pelo autor a partir das saídas do JusCriticA, 24 jun. 2026.

Figura 8 Matriz de confusão, VEFE Gabinete

Fonte: Elaborada pelo autor a partir das saídas do JusCriticA, 24 jun. 2026.

Na matriz de confusão da VEFM Gabinete, observa-se elevada preservação dos casos críticos, com 17.375 registros de QOT4 real corretamente classificados como QOT4, equivalentes a 98,2% da classe. O erro mais sensível, QOT4 real previsto como QOT1+QOT2, ocorreu em 205 registros, correspondentes a 1,2% da classe QOT4 real, mantendo baixo o risco de rebaixamento extremo. O principal ponto de atenção está na previsão de QOT4 para casos de QOT3 real, com 5.359 registros,

ou 30,1% da classe QOT3, o que indica postura mais agressiva de priorização nesse recorte.

Na matriz de confusão da VEFE Gabinete, o desempenho é mais conservador e mais preciso, com acurácia global de 96,3%. O QOT4 real foi corretamente classificado como QOT4 em 597 registros, equivalentes a 96,9% da classe, enquanto o erro extremo de QOT4 real previsto como QOT1+QOT2 ocorreu em apenas 5 registros, ou 0,8% da classe QOT4 real. Também se observa baixa contaminação de QOT3 como QOT4, com apenas 6 registros, equivalentes a 0,8% da classe QOT3, indicando fronteira mais nítida entre as classes críticas nesse recorte.

Consideradas em conjunto, as matrizes indicam que o pior caso operacional, QOT4 real previsto como QOT1+QOT2, permanece em patamar baixo nos recortes analisados, enquanto a maior parte das divergências ocorre em fronteiras adjacentes. A principal diferença operacional está no balanço entre cobertura e precisão dos casos críticos: VEFM Gabinete amplia a cobertura de QOT4, com maior contaminação por QOT3, ao passo que VEFE Gabinete apresenta fronteira mais nítida entre as classes. Essa leitura sustenta o uso do modelo como instrumento de triagem assistida e prepara a análise seguinte, na qual a priorização por CRIT_SCORE_% é comparada ao baseline institucional DIAS_ABERTOS.

4.5 Relação entre CRIT_SCORE_% e DIAS_ABERTOS, análise de dispersão e eficiência TOP-N

A seção 4.4 validou o comportamento preditivo por meio das matrizes de confusão. A partir desse ponto, a análise passa do diagnóstico do classificador para a utilidade operacional do *ranking*, com foco em como o risco previsto se converte em uma lista semanal executável. Assim, o CRIT_SCORE_% passa a ser tratado como critério de ordenação da triagem, aplicado em complemento ao *baseline* institucional DIAS_ABERTOS, preservando a lógica de priorização por tempo em aberto como salvaguarda. Essa passagem de foco explicita o vínculo entre evidência preditiva e decisão prática sob restrição de capacidade semanal.

No JusCriticA, o CRIT_SCORE_% sintetiza o risco previsto pelo classificador em três classes por meio de uma combinação ponderada das probabilidades, com maior peso para QOT4 e peso intermediário para QOT3, conforme a expressão

$CRIT_SCORE_ \% = (P_QOT4 + 0,6 \times P_QOT3) \times 100$. Essa construção produz uma régua contínua de priorização, reduz empates típicos de decisões discretas por classe e atenua a ambiguidade na fronteira $QOT3 \leftrightarrow QOT4$, mantendo como prioridade prática a cobertura de casos com maior probabilidade de criticidade. Consequentemente, o *ranking* passa a privilegiar a ordenação por risco dentro do TOP-N compatível com a capacidade semanal.

O peso 0,6 atribuído a P_QOT3 foi definido em aderência à prática operacional da DEFFA/TJPE, que classifica os processos em três faixas: saneados (0 a 49 dias parados), pré-críticos (50 a 99 dias parados) e críticos (100 ou mais dias parados). $QOT3$ corresponde operacionalmente à faixa pré-crítica, tratada pela gestão como segunda linha de atenção antes da criticidade plena.

Ao incorporar P_QOT3 com peso 0,6 na composição do critério, o $CRIT_SCORE_ \%$ formaliza esse posicionamento em uma régua contínua, reconhecendo os processos pré-críticos como candidatos à intervenção preventiva antes que migrem para a faixa crítica na semana seguinte.

Esse desenho também amplia a capacidade de triagem em cenários de reforço operacional, como forças-tarefa, mutirões ou demandas pontuais de acervo, nos quais a expansão temporária da capacidade semanal torna estratégica a incorporação da faixa pré-crítica ao lote prioritário sem exigir revisão do critério de ordenação.

Além disso, essa ponderação parcial evita que a régua se encerre prematuramente após o esgotamento do lote $QOT4$, preservando sua utilidade em contextos de capacidade ampliada ou continuidade da atuação por mais de um ciclo semanal. A escolha do peso 0,6 é, portanto, uma decisão de design ancorada na lógica institucional já praticada pelo órgão, o que assegura interpretabilidade direta para os gestores e aderência ao modelo de priorização existente.

Do ponto de vista operacional, a régua contínua é adequada ao cenário de capacidade semanal limitada, pois permite ordenação fina dentro do conjunto analisável. Além disso, viabiliza uma leitura conjunta com o *baseline* DIAS_ABERTOS como salvaguarda de triagem, sobretudo nos casos em que o risco previsto é intermediário ou está próximo da fronteira entre classes, sustentando a comparação entre critérios na avaliação de eficiência apresentada adiante nesta seção. Essa

combinação também reduz a chance de um caso crítico ficar fora da lista semanal por subestimação pontual de probabilidade.

Para tornar visível a relação entre o indicador temporal e o critério preditivo de ordenação, as Figuras 9, 10 e 11 apresentam os gráficos de dispersão entre DIAS_ABERTOS e CRIT_SCORE_% nos recortes EF Geral, VEFE Geral e VEFM Geral. A leitura conjunta desses três recortes permite verificar se o *score* apenas reproduz o tempo em aberto ou se acrescenta uma estrutura própria de separação por classe prevista. Com isso, os gráficos funcionam como evidência visual complementar da utilidade operacional do CRIT_SCORE_% como régua contínua de priorização.


Além de evidenciar a relação entre DIAS_ABERTOS e CRIT_SCORE_%, essas dispersões permitem verificar se processos com tempos semelhantes permanecem agrupados ou passam a ocupar posições distintas quando o risco preditivo é incorporado ao *ranking*. Com isso, a leitura visual ajuda a demonstrar se o CRIT_SCORE_% apenas acompanha o tempo em aberto ou se acrescenta uma lógica própria de ordenação nos recortes operacionais analisados.

Em síntese, as dispersões indicam que o CRIT_SCORE_% acrescenta lógica preditiva ao DIAS_ABERTOS, sem eliminar sua função como indicador institucional.

O critério composto traduz a posição relativa de cada processo em seu grupo de referência, formado por órgão julgador e tarefa, para uma escala probabilística comum, produzida por modelo único treinado sobre as unidades de competência exclusiva em EF.


Isso permite comparar processos com tempos em aberto semelhantes, mas posições distintas na distribuição de risco de seus contextos operacionais. Essa leitura contextual refina a lista semanal sob capacidade limitada e reforça a adequação do CRIT_SCORE_% como régua complementar de priorização.

Figura 9 Dispersão entre DIAS_ABERTOS e CRIT_SCORE_%, EF Geral




Fonte: Elaborada pelo autor a partir das saídas do JusCriticA, 24 jun. 2026.

Figura 10 Dispersão entre DIAS_ABERTOS e CRIT_SCORE_%, VEFE Geral



Fonte: Elaborada pelo autor a partir das saídas do JusCriticA, 24 jun. 2026.

Figura 11 Dispersão entre DIAS_ABERTOS e CRIT_SCORE_%, VEFM Geral



Fonte: Elaborada pelo autor a partir das saídas do JusCriticA, 24 jun. 2026.

Nos três recortes, os gráficos de dispersão evidenciam que CRIT_SCORE_% não replica DIAS_ABERTOS. Observa-se separação visual consistente por classe prevista: QOT1+QOT2 concentra-se em valores baixos de CRIT_SCORE_%, QOT3 ocupa a faixa intermediária, QOT4 concentra-se nos maiores valores. Essa estrutura sugere que o *score* incorpora informação preditiva além do tempo em aberto, o que sustenta seu uso como critério de ordenação. A escolha do gráfico de dispersão como forma de apresentação reconhece que, embora menos comum em contextos gerenciais, esse tipo de visualização é adequado para revelar relações entre duas variáveis contínuas em bases de grande volume, permitindo identificar padrões de separação por classe que seriam invisíveis em agregações (Knafllic, 2018, p. 39-40).

A leitura conjunta também qualifica a relação entre criticidade temporal e risco previsto. Há processos com DIAS_ABERTOS baixos com CRIT_SCORE_% elevado, o que sugere risco futuro associado ao padrão órgão-tarefa, a posição percentual intragrupo na carga corrente (PCTL_OT), às probabilidades do classificador. Há também processos com DIAS_ABERTOS elevados que não permanecem necessariamente no topo do CRIT_SCORE_%, o que é compatível com a hipótese de que o *baseline* temporal, isoladamente, não captura toda a variação de risco operacional. Para reduzir exposição de faixas detalhadas, o eixo DIAS_ABERTOS foi apresentado com marcações resumidas, mantendo o limiar 100 como referência operacional.

Para mensurar o ganho operacional do *ranking*, se aplica a avaliação TOP-N com capacidade semanal K. O procedimento ordena os processos por CRIT_SCORE_% e seleciona o *TopK*, contabilizando quantos casos do alvo aparecem nesse conjunto, tomando como referência a classe prevista pelo classificador (QOT_PRED_LABEL). Em seguida, se ordena por DIAS_ABERTOS e se identifica o menor N necessário para capturar a mesma quantidade de casos do alvo. O ganho é calculado como $1 - (K/N)$, interpretado como redução relativa do volume a ser inspecionado para atingir a mesma cobertura.

Nesse cálculo, K representa o tamanho do lote inspecionado no *ranking* por CRIT_SCORE_%, enquanto a coluna “K (CRIT_SCORE_%)” informa quantos registros do alvo foram efetivamente encontrados dentro desse lote. Como etapa complementar de auditoria dos resultados TOP-N, as listas geradas pelo JusCritIA

foram conectadas ao Power BI e conferidas em duas ordenações independentes: uma por CRIT_SCORE_% e outra por DIAS_ABERTOS. Em cada recorte, foram adicionados índices de posição, exportadas as listas ordenadas e realizada conferência por filtros no Excel, considerando os alvos QOT4 e QOT3+QOT4. Assim, quando o Top-K não contém K registros do alvo, como no caso VEFE Diretoria/QOT4 em $K = 8.000$, o N por DIAS_ABERTOS é calculado para igualar a quantidade efetivamente capturada pelo *ranking* preditivo, mantendo o ganho como redução relativa de inspeção entre K e N.

Nesta dissertação, a avaliação TOP-N tem finalidade operacional, pois mede a eficiência de triagem do *ranking* dado um alvo definido na própria saída preditiva (QOT_PRED_LABEL) e uma capacidade semanal K. A validade preditiva permanece ancorada nas matrizes de confusão, que comparam QOT_PRED(t) com QOT_FUTURO(t+1). Assim, TOP-N mede eficiência de priorização sob restrição de capacidade, enquanto a seção 4.4 sustenta o desempenho preditivo do classificador.

Tabela 12 Ganho do CRIT_SCORE_% vs. DIAS_ABERTOS

K	Recorte	Alvo	K (CRIT_SCORE_%)	N por DIAS_ABERTOS	Ganho (1 - K/N)
4.000	EF Geral	QOT4	4.000	4.345	7,94%
4.000	VEFE Diretoria	QOT4	4.000	6.614	39,52%
4.000	VEFM Gabinete	QOT4	4.000	4.427	9,65%
4.000	EF Geral	QOT3+QOT4	4.000	4.037	0,92%
4.000	VEFE Diretoria	QOT3+QOT4	4.000	4.895	18,28%
4.000	VEFM Gabinete	QOT3+QOT4	4.000	4.051	1,26%
8.000	EF Geral	QOT4	8.000	9.952	19,61%
8.000	VEFE Diretoria	QOT4	5.227	11.443	30,09%
8.000	VEFM Gabinete	QOT4	8.000	11.435	30,04%
8.000	EF Geral	QOT3+QOT4	8.000	8.072	0,89%
8.000	VEFE Diretoria	QOT3+QOT4	8.000	10.101	20,80%
8.000	VEFM Gabinete	QOT3+QOT4	8.000	8.417	4,95%

Fonte: Elaborada pelo autor.

A Tabela 12, após auditoria das listas ordenadas por CRIT_SCORE_% e por DIAS_ABERTOS, confirma que o *ranking* preditivo produz ganho operacional positivo em todos os recortes analisados, embora com intensidade variável conforme o alvo e a unidade observada. Para o alvo estrito QOT4, o maior ganho em $K = 4.000$ ocorre em VEFE Diretoria, com 39,52% de redução relativa no volume de processos a

percorrer em comparação com o *baseline* DIAS_ABERTOS. No mesmo K, EF Geral apresenta ganho de 7,94%, enquanto VEFM Gabinete registra ganho de 9,65%.

Em $K = 8.000$, os ganhos para QOT4 tornam-se mais expressivos em EF Geral e VEFM Gabinete, alcançando, respectivamente, 19,61% e 30,04%. Em VEFE Diretoria, o ganho permanece relevante, com 30,09%, mas exige leitura específica: o recorte contém 5.296 registros previstos como QOT4, de modo que não havia 8.000 QOT4 disponíveis para serem capturados. Nessa condição, o Top-8.000 por CRIT_SCORE_% capturou 5.227 registros QOT4, praticamente esgotando o conjunto de casos críticos previstos nesse recorte. Por isso, o N por DIAS_ABERTOS foi calculado para igualar a quantidade efetivamente capturada pelo *ranking* preditivo, e não para alcançar 8.000 QOT4 inexistentes na base.

Quando o alvo é ampliado para QOT3+QOT4, os ganhos tornam-se mais modestos, o que é esperado, pois a ampliação do alvo aumenta a prevalência de casos positivos e reduz a diferença relativa entre as ordenações. Em EF Geral, o ganho permanece próximo de 1%, com 0,92% em $K = 4.000$ e 0,89% em $K = 8.000$. Em VEFM Gabinete, os ganhos também são reduzidos, passando de 1,26% para 4,95%. Já em VEFE Diretoria, a triagem ampliada mantém utilidade operacional mais clara, com ganhos de 18,28% em $K = 4.000$ e 20,80% em $K = 8.000$.

Esses resultados indicam que o CRIT_SCORE_% é mais útil quando o objetivo operacional é priorizar QOT4. A comparação com DIAS_ABERTOS mostra que o *ranking* preditivo consegue concentrar melhor os casos de maior criticidade prevista no topo da lista, reduzindo o esforço de inspeção necessário para atingir a mesma cobertura.

Para QOT3+QOT4, a utilidade permanece dependente do recorte, sendo mais evidente em VEFE Diretoria e mais limitada em EF Geral e VEFM Gabinete.

Assim, a Tabela 12 deve ser interpretada como evidência de eficiência operacional da triagem, e não como medida de validade preditiva, a qual foi avaliada separadamente por acurácia, F1 ponderado e matrizes de confusão.

4.6 Interpretação operacional e estratégia de triagem com capacidade semanal limitada

Os resultados da seção 4.5 permitem traduzir a evidência preditiva em decisão prática. Na operação, a triagem semanal precisa produzir uma lista executável, sob capacidade fixa, com risco controlado de subpriorização. Nesse contexto, o CRIT_SCORE_% atua como critério principal de ordenação por risco previsto, enquanto DIAS_ABERTOS permanece como salvaguarda, pois mantém um sinal temporal simples que reduz exposição a casos em que a probabilidade estimada é pontualmente baixa.

A leitura conjunta dos recortes indica que a utilidade do CRIT_SCORE_% varia entre contextos. Quando o alvo é QOT4, os ganhos observados sugerem maior eficiência para colocar casos de maior criticidade prevista no topo do *TopK*. Esse efeito deve ser lido junto de um fenômeno esperado: à medida que K aumenta, a densidade de QOT4 no *TopK* tende a cair, pois os casos mais evidentes se esgotam primeiro. A partir de certo ponto, o ganho tende a estabilizar ou reduzir, o que é normal em qualquer estratégia de triagem.

Quando o alvo é ampliado para QOT3+QOT4, os resultados mostram que a triagem ampliada é mais vantajosa em recortes específicos, pois aumenta a cobertura de casos críticos e de transição com alto risco sem exigir crescimento proporcional do volume inspecionado. Em recortes nos quais o ganho para QOT3+QOT4 é pequeno, a adoção da triagem ampliada deve ser orientada por decisão de gestão sobre o quanto se aceita incorporar QOT3 no lote semanal, dado o custo operacional de revisar casos que não são QOT4.

Do ponto de vista de execução, uma estratégia objetiva consiste em usar o CRIT_SCORE_% para ordenar o lote semanal, com DIAS_ABERTOS como verificação complementar para reduzir risco residual. Essa combinação é particularmente relevante nas situações de fronteira entre QOT3 e QOT4, já discutidas na seção 4.4, nas quais pequenos deslocamentos de probabilidade podem alterar a posição relativa no *ranking*. Assim, o *ranking* por CRIT_SCORE_% organiza a prioridade fina, enquanto o *baseline* temporal funciona como salvaguarda simples para evitar que casos com longo tempo em aberto fiquem sistematicamente fora do foco semanal.

Em síntese, a seção 4.5 sustenta que o artefato não se limita a classificar, ele viabiliza uma priorização operacionalmente mensurável sob capacidade semanal limitada. A seção seguinte consolida as evidências do Capítulo 4 à luz dos critérios de avaliação H1/C1, H2/C2 e H3/C3, explicitando o que foi sustentado em termos de validade preditiva, padrão de erro e utilidade operacional do artefato.

4.7 Síntese das evidências à luz dos critérios de avaliação

Os critérios de avaliação H1/C1, H2/C2 e H3/C3, definidos na seção 4.1.1, foram atendidos pelo encadeamento empírico apresentado nas seções anteriores. As evidências foram reunidas em três níveis complementares: estabilidade fora da amostra na validação temporal, caracterização do perfil de erro nas matrizes de confusão e quantificação da utilidade operacional do *ranking* sob restrição de capacidade semanal.

H1/C1, validade preditiva, foi sustentado pelos resultados globais da validação *walk-forward* com embargo = 1, apresentados nas Tabelas 6 a 8. Esses resultados evidenciam consistência de F1 ponderado e acurácia entre janelas sucessivas na comparação entre QOT_PRED(t) e QOT_FUTURO(t+1), preservando a lógica prospectiva da avaliação.

H2/C2, adequação do núcleo preditivo, foi sustentado pelo desempenho consistente do LightGBM, com F1 ponderado médio de 0,8387 e acurácia média de 0,8392 fora da amostra, pela importância dos atributos e pela ablação do PCTL_OT. A importância por ganho indicou predominância do PCTL_OT, com 78,80% do ganho normalizado, enquanto a retirada desse atributo reduziu o *F1-weighted* para 0,5688 e a acurácia para 0,5730. Essa convergência entre importância interna do modelo e perda experimental fora da amostra reforça a adequação do núcleo preditivo avaliado, preservada a interpretação não causal dos resultados.

H3/C3, utilidade operacional, foi sustentado por dois blocos de evidência. As dispersões das Figuras 9 a 11 demonstraram que o CRIT_SCORE_% não replica DIAS_ABERTOS, mas organiza o risco previsto em uma régua contínua com separação visual coerente por classe. A análise TOP-N da Tabela 12 quantificou o ganho de triagem para K = 4.000 e K = 8.000, com benefício mais expressivo quando o alvo é QOT4. Para o alvo QOT3+QOT4, os ganhos indicaram utilidade como triagem

ampliada em recortes específicos, com adoção condicionada ao custo operacional de incorporar QOT3 no lote semanal.

No contexto específico da DEFFA/TJPE, os resultados obtidos indicam que a integração entre indicador institucional e risco preditivo produz ganho operacional relevante para a priorização semanal sob capacidade limitada. Esse avanço dialoga com a literatura revisada ao reforçar o potencial da mineração de processos e do aprendizado de máquina como suporte à triagem e à priorização no Judiciário. Os achados também convergem com estudos que destacam a importância de protocolos de validação temporal em cenários com dependência cronológica, especialmente para reduzir o risco de desempenho artificialmente inflado quando não há separação temporal adequada.

O Capítulo 5 consolida essas evidências em perspectiva conclusiva, explicita as contribuições do artefato, apresenta as limitações estritamente necessárias e indica direções de evolução coerentes com o escopo e o contexto institucional analisado.

5 CONCLUSÕES, CONTRIBUIÇÕES, LIMITAÇÕES E TRABALHOS FUTUROS

5.1 Síntese dos resultados e resposta à questão de pesquisa

O JusCritIA alcançou F1 ponderado médio de 0,8387 e acurácia média de 0,8392 fora da amostra, sob validação temporal *walk-forward* com embargo de uma janela semanal, sustentando as três hipóteses avaliativas formuladas e preservando a interpretação não causal dos resultados.

A priorização processual na DEFFA/TJPE baseia-se predominantemente no indicador DIAS_ABERTOS, régua unidimensional de limiar fixo que não considera a heterogeneidade de órgãos, tarefas e trajetórias processuais. Para endereçar essa limitação, este trabalho construiu e avaliou o JusCritIA, respondendo à questão de pesquisa formulada na seção 1.2.

A avaliação empírica consolidada na seção 4.7 confirmou o atendimento dos três critérios estabelecidos: H1/C1, validade preditiva, H2/C2, adequação do núcleo preditivo, e H3/C3, utilidade operacional. As evidências reunidas indicaram estabilidade temporal consistente, perfil de erro concentrado entre classes adjacentes

e ganho de triagem mensurável em capacidades semanais compatíveis com a realidade operacional da DEFFA/TJPE.

A questão de pesquisa formulada na seção 1.2 recebe resposta afirmativa. A ordenação por CRIT_SCORE_% concentra casos críticos no topo das listas com menor esforço de inspeção do que o *baseline* institucional DIAS_ABERTOS, com desempenho preditivo estável e aderência ao ambiente institucional analisado.

5.2 Contribuições do trabalho

As contribuições se organizam em quatro frentes. A primeira contribuição é a entrega de um artefato operacionalmente executável, com regra de priorização transparente. O CRIT_SCORE_% consolida o risco previsto do classificador em uma régua contínua, com lógica explícita e interpretável, viabilizando ordenação fina do lote semanal sem depender apenas do tempo em aberto.

A segunda contribuição é a adoção de um protocolo de avaliação coerente com o uso pretendido. A validação temporal *walk-forward* com embargo = 1, combinada ao pareamento semanal entre t e $t+1$, reduz vieses típicos de avaliação em séries temporais operacionais. Essa decisão fortalece a aderência entre o modo de avaliação e o modo de uso do artefato no ambiente real.

A terceira contribuição é a qualificação do risco operacional com base no padrão de erro. O resultado mais relevante não é apenas “acertar mais”, mas manter o erro dominante em transições adjacentes, com baixo volume de falso negativo severo de QOT4 para o grupo menos crítico. Isso sustenta uma postura conservadora de gestão, em que a cobertura de QOT4 é tratada como prioridade prática.

A quarta contribuição é a mensuração direta do benefício de triagem sob restrição de capacidade. A Tabela 12 evidenciou ganhos operacionais mais expressivos no alvo QOT4, com destaque para VEFE Diretoria, que alcançou 39,52% em $K = 4.000$ e 30,09% em $K = 8.000$, e para VEFM Gabinete, que atingiu 30,04% em $K = 8.000$. No alvo ampliado QOT3+QOT4, o ganho mais relevante concentrou-se novamente em VEFE Diretoria, com 18,28% em $K = 4.000$ e 20,80% em $K = 8.000$.

Esses resultados demonstram que o CRIT_SCORE_% oferece benefício operacional concreto sobretudo nos cenários em que a triagem busca concentrar

processos previstos como críticos no topo da lista, reduzindo o esforço de inspeção em relação à ordenação exclusivamente temporal por DIAS_ABERTOS.

5.3 Implicações práticas para a gestão sob capacidade semanal limitada

Os achados permitem traduzir a evidência preditiva em diretriz de execução. A recomendação operacional é usar CRIT_SCORE_% como critério primário de ordenação do lote semanal, mantendo DIAS_ABERTOS como salvaguarda simples. Essa combinação é útil em situações de transição entre QOT3 e QOT4, nas quais variações pequenas de probabilidade podem alterar posições no *ranking*.

Conforme K cresce, a densidade de QOT4 no *TopK* tende a cair, pois os casos mais evidentes são capturados primeiro. Essa dinâmica não invalida o método, apenas caracteriza o comportamento esperado de qualquer triagem por *ranking* sob saturação progressiva do alvo.

A inclusão do alvo QOT3+QOT4 mantém utilidade como triagem ampliada em recortes específicos. Em recortes com ganho menor, aceitar mais QOT3 no lote semanal implica custo de revisão, embora possa reduzir exposição a fronteiras mais ambíguas.

5.4 Limitações e controles adotados

As limitações são tratadas como condições de interpretação, não como desqualificação dos resultados. A primeira limitação decorre do escopo de dados e do recorte operacional. O estudo foi avaliado em Execução Fiscal, com filtros e recortes definidos no próprio artefato. A generalização para outras classes processuais exige reavaliação, pois o comportamento órgão-tarefa pode mudar.

A segunda limitação está ligada ao uso de um classificador em três classes. O principal *trade-off* ocorre na fronteira QOT3↔QOT4. O artefato mitiga parte desse efeito ao usar CRIT_SCORE_% como régua contínua, além de incorporar peso intermediário para QOT3. Mesmo assim, permanece risco residual de subpriorização quando probabilidades ficam pontualmente baixas.

A terceira limitação diz respeito à avaliação TOP-N baseada na classe prevista (QOT_PRED_LABEL). Esse desenho é coerente com a finalidade operacional, que é

medir eficiência de triagem da lista produzida pelo próprio sistema. A validade preditiva permaneceu ancorada nas matrizes de confusão com QOT_FUTURO em $t+1$. A separação entre validade preditiva e produtividade operacional foi mantida para evitar interpretações indevidas.

A quarta limitação é a exposição de informação em visualizações. Neste trabalho, as dispersões foram apresentadas com marcações resumidas no eixo DIAS_ABERTOS, preservando o limiar 100 como referência operacional. O conteúdo exibido caracteriza relação entre critérios de ordenação, sem identificação de partes, sem exposição de dados pessoais, sem detalhamento que permita reidentificação. A anonimização adotada é compatível com o propósito científico da figura, que é demonstrar comportamento relativo entre variáveis e classes previstas.

5.5 Trabalhos futuros

Os trabalhos futuros se concentram em expansão de escopo, consolidação de governança, além de avaliação em novos contextos. A primeira linha é ampliar a aplicação do JusCritIA para outros recortes institucionais, incluindo novas unidades e diretorias, com manutenção do mesmo protocolo de validação temporal, do mesmo pareamento semanal, das mesmas salvaguardas de triagem. Essa expansão deve preservar rastreabilidade, com registro de versões, parâmetros e logs.

A segunda linha é aprofundar a análise por órgão julgador, com foco em regimes distintos de carga, além de padrões de fronteira $QOT3 \leftrightarrow QOT4$. O objetivo é calibrar, por contexto, a postura de triagem mais conservadora ou mais agressiva, sempre guiada por custo operacional de falso negativo de QOT4.

A terceira linha é fortalecer mecanismos de governança e reprodutibilidade. Isso inclui padronização de pacotes, versão de execução, trilha de auditoria, além de scripts de replicação das tabelas de ganho TOP-N. Também inclui documentação operacional voltada a usuários não técnicos, com ênfase em como interpretar lista semanal, além de como aplicar salvaguardas com DIAS_ABERTOS.

A quarta linha é ampliar a avaliação de utilidade com observação sistemática da adoção. Esse passo envolve coleta estruturada de *feedback* de gestores, medição de tempo de triagem, taxa de atendimento do *TopK*, além de efeitos em backlog crítico ao longo de semanas, preservando o caráter observacional da análise.

Outra linha de evolução consiste em parametrizar o peso atribuído à probabilidade da classe QOT3 no cálculo do CRIT_SCORE_%. Nesta pesquisa, adotou-se o peso 0,6 por aderência à lógica institucional de tratamento dos processos pré-críticos. Em versões futuras do artefato, esse parâmetro poderá ser ajustado conforme capacidade operacional, política gerencial e preferência institucional de priorização, desde que submetido a análise de sensibilidade e validação temporal.

5.6 Considerações finais

Este trabalho demonstrou que a contribuição do JusCritIA vai além de classificar. O artefato viabiliza priorização operacionalmente mensurável sob capacidade semanal limitada, com regra transparente, compatível com salvaguardas institucionais simples.

A contribuição não reside apenas no artefato entregue, mas na demonstração de que é possível construir e avaliar um sistema preditivo de criticidade processual dentro das restrições reais de um tribunal, com dados anonimizados, ambiente computacional isolado e validação prospectiva que reproduz as condições do uso operacional semanal.

Esse caminho pode ser replicado em outros contextos judiciais que enfrentem o mesmo desafio de triagem sob capacidade limitada, desde que adaptado às especificidades institucionais e operacionais de cada ambiente, preservando a leitura já praticada como verificação complementar, sem substituí-la.

REFERÊNCIAS

ARAUJO, Pedro Henrique Luz de; CAMPOS, Teófilo Emídio de; BRAZ, Fabricio Ataides; SILVA, Nilton Correia da. VICTOR: a dataset for Brazilian legal documents classification. In: CALZOLARI, Nicoletta et al. (ed.). Proceedings of the Twelfth Language Resources and Evaluation Conference. Marseille: European Language Resources Association, 2020. p. 1449-1458. Disponível em: <https://aclanthology.org/2020.lrec-1.181/>. Acesso em: 16 jun. 2026.

BHATNAGAR, Mohit; HUCHHANAVAR, Shivaraj. Hybrid *machine learning* modelling with explainability for predicting case delays and durations in Indian lower courts. Journal of Big Data, v. 13, art. 4, 2026. Publicado em: 5 dez. 2025. DOI: 10.1186/s40537-025-01340-1. Disponível em: <https://link.springer.com/article/10.1186/s40537-025-01340-1>. Acesso em: 16 jun. 2026.

BIANCHINI, Davide et al. Challenges in AI-supported process analysis in the Italian Judicial System: what after digitalization? Digital Government: Research and Practice, v. 5, n. 1, art. 5, 2024. DOI: 10.1145/3630025. Disponível em: <https://dl.acm.org/doi/10.1145/3630025>. Acesso em: 09 nov. 2025.

BOUSDENKIS, Alexandros et al. Modelling and predictive monitoring of business processes under uncertainty *with* reinforcement learning. Sensors, v. 23, n. 15, p. 6931, 2023. DOI: 10.3390/s23156931. Disponível em: <https://www.mdpi.com/1424-8220/23/15/6931>. Acesso em: 10 nov. 2025.

CERAVOLO, Paolo et al. *Predictive process monitoring*: concepts, challenges, and future research directions. Process Science, v. 1, art. 2, 2024. DOI: 10.1007/s44311-024-00002-4. Disponível em: <https://link.springer.com/article/10.1007/s44311-024-00002-4>. Acesso em: 09 nov. 2025.

CERQUEIRA, Vitor; TORGO, Luis; MOZETIČ, Igor. Evaluating time series *forecasting* models: an empirical study on performance estimation methods. *machine learning*, v. 109, n. 11, p. 1997-2028, 2020. DOI: 10.1007/s10994-020-05910-7. Disponível em: <https://link.springer.com/article/10.1007/s10994-020-05910-7>. Acesso em: 10 nov. 2025.

CHEONG, Ben Chester. Transparency and *accountability* in AI systems: safeguarding wellbeing in the age of algorithmic decision-making. *Frontiers in Human Dynamics*, v. 6, art. 1421273, 2024. DOI: 10.3389/fhumd.2024.1421273. Disponível em: <https://www.frontiersin.org/articles/10.3389/fhumd.2024.1421273>. Acesso em: 16 jan. 2026.

COLLINS, Gary S. et al. TRIPOD+AI: reporting guidelines for studies developing or validating prediction models using *artificial intelligence*. *BMJ*, v. 385, e078378, 2024. DOI: 10.1136/bmj-2023-078378. Disponível em: <https://www.bmj.com/content/385/bmj-2023-078378>. Acesso em: 10 nov. 2025.

CONSELHO NACIONAL DE JUSTIÇA. *60º relatório trimestral da Ouvidoria do Conselho Nacional de Justiça: outubro, novembro e dezembro de 2024*. Brasília: CNJ, 2025a. 36 p. Disponível em: <https://www.cnj.jus.br/wp-content/uploads/2025/03/60-relatorio-trimestral-ouvidoria-out-nov-dez-2024.pdf>. Acesso em: 23 out. 2025.

CONSELHO NACIONAL DE JUSTIÇA. *61º relatório trimestral da Ouvidoria do Conselho Nacional de Justiça: janeiro, fevereiro e março de 2025*. Brasília: CNJ, 2025b. 34 p. Disponível em: <https://www.cnj.jus.br/wp-content/uploads/2025/05/61-relatorio-trimestral-ouvidoria-jan-fev-mar-2025.pdf>. Acesso em: 23 out. 2025.

CONSELHO NACIONAL DE JUSTIÇA. *Justiça em números 2024*. Brasília: CNJ, 2024. 448 p. Disponível em: <https://www.cnj.jus.br/wp-content/uploads/2024/05/justica-em-numeros-2024-v-28-05-2024.pdf>. Acesso em: 23 out. 2025.

CONSELHO NACIONAL DE JUSTIÇA. Resolução nº 325, de 29 de junho de 2020. Institui a Estratégia Nacional do Poder Judiciário 2021-2026. *Diário da Justiça Eletrônico*, Brasília, DF, 30 jun. 2020. Disponível em: <https://atos.cnj.jus.br/atos/detalhar/3365>. Acesso em: 23 out. 2025.

CONSELHO NACIONAL DE JUSTIÇA. Resolução nº 615, de 11 de março de 2025. Estabelece diretrizes para o desenvolvimento, utilização e governança de soluções desenvolvidas com recursos de inteligência artificial no Poder Judiciário. *Diário da Justiça Eletrônico*, Brasília, DF, 12 mar. 2025c. Disponível em: <https://atos.cnj.jus.br/files/original1555302025031467d4517244566.pdf>. Acesso em: 23 out. 2025.

CORNELL, C.; MITCHELL, L.; ROUGHAN, M. Rank is all you need: development and analysis of robust causal networks. *Applied Network Science*, v. 9, art. 39, 2024. DOI: 10.1007/s41109-024-00648-w. Disponível em: <https://doi.org/10.1007/s41109-024-00648-w>. Acesso em: 16 jun. 2026.

CRUZ, Jaqueline K. L. da; VERÇOSA, Luiz F. V.; SILVA, Vinícius Ferreira; BASTOS-FILHO, Carmelo J. A.; BEZERRA, Byron Leite Dantas. O uso da mineração de processos na análise do tempo das movimentações processuais. *Revista de Engenharia e Pesquisa Aplicada*, v. 9, n. 1, p. 97-104, 2023. DOI: 10.25286/rep.v9i1.2785. Disponível em: <https://doi.org/10.25286/rep.v9i1.2785>. Acesso em: 23 out. 2025.

DELGADO, Andrea; CALEGARI, Daniel; ESPINO, Carolina; RIBERO, Nicolás. *Predictive process monitoring for collaborative business processes: concepts and application*. *Discover Analytics*, v. 3, art. 5, 2025. DOI: 10.1007/s44257-025-00031-8. Disponível em: <https://link.springer.com/article/10.1007/s44257-025-00031-8>. Acesso em: 10 nov. 2025.

DEMPSTER, A.; SCHMIDT, D. F.; WEBB, G. I. Quant: a minimalist interval method for time series classification. *Data Mining and Knowledge Discovery*, v. 38, p. 2377-

2402, 2024. DOI: 10.1007/s10618-024-01036-9. Disponível em: <https://doi.org/10.1007/s10618-024-01036-9>. Acesso em: 16 jun. 2026.

FGV JUSTIÇA. *Inteligência artificial: tecnologia aplicada à gestão dos conflitos no âmbito do Poder Judiciário brasileiro*. 4. ed. Rio de Janeiro: FGV Justiça, 2025. Disponível em: https://justica.fgv.br/sites/default/files/2025-10/inteligencia_artificial_4a-edicao.pdf. Acesso em: 11 nov. 2025.

FRANCISCHINI, Andresa S. N.; FRANCISCHINI, Paulino G. *Indicadores de desempenho: dos objetivos à ação, métodos para elaborar KPIs e obter resultados*. São Paulo: Atlas, 2015.

GUITTON, Clement; DRUTA, Vlada; HINTERLEITNER, Markus; TAMÒ-LARRIEUX, Aurelia; MAYER, Simon. Adoption of *artificial intelligence* in the judiciary: a comparison of 28 advanced democracies. *Discover Artificial Intelligence*, v. 5, art. 169, 2025. DOI: 10.1007/s44163-025-00311-y. Disponível em: <https://link.springer.com/article/10.1007/s44163-025-00311-y>. Acesso em: 14 jan. 2026.

HALL, Timothy; RASHEED, Khaled. A survey of *machine learning* methods for time series prediction. *Applied Sciences*, v. 15, n. 11, art. 5957, 2025. DOI: 10.3390/app15115957. Disponível em: <https://www.mdpi.com/2076-3417/15/11/5957>. Acesso em: 11 nov. 2025.

HEVNER, Alan R.; MARCH, Salvatore T.; PARK, Jinsoo; RAM, Sudha. Design science in information systems research. *MIS Quarterly*, v. 28, n. 1, p. 75-105, mar. 2004. DOI: 10.2307/25148625. Disponível em: <https://aisel.aisnet.org/misq/vol28/iss1/6/>. Acesso em: 10 nov. 2025.

HEWAMALAGE, Hansika; ACKERMANN, Klaus; BERGMEIR, Christoph. Forecast evaluation for data scientists: common pitfalls and best practices. *Data Mining and Knowledge Discovery*, v. 37, p. 788-832, 2023. DOI: 10.1007/s10618-022-00894-5. Disponível em: <https://link.springer.com/article/10.1007/s10618-022-00894-5>. Acesso em: 11 nov. 2025.

HYNDMAN, Rob J.; ATHANASOPOULOS, George. *Forecasting: principles and practice*. 3. ed. Melbourne: OTexts, 2021. Disponível em: <https://otexts.com/fpp3/>. Acesso em: 10 nov. 2025.

IBEBUCHI, C. C. Uncertainty in *machine learning* feature importance for climate science: a comparative analysis of SHAP, PDP, and gain-based methods. *Theoretical and Applied Climatology*, v. 156, art. 476, 2025. DOI: 10.1007/s00704-025-05703-9. Disponível em: <https://doi.org/10.1007/s00704-025-05703-9>. Acesso em: 16 jun. 2026.

JAVED, Kashif; LI, Jianxin. Bias in adjudication: investigating the impact of *artificial intelligence*. *PLOS ONE*, v. 20, n. 1, e0315270, 2025. DOI:

10.1371/journal.pone.0315270. Disponível em:
<https://journals.plos.org/plosone/article?id=10.1371/journal.pone.0315270>. Acesso em: 10 nov. 2025.

KAPOOR, Sayash et al. REFORMS: consensus-based recommendations for machine-learning-based science. *Science Advances*, v. 10, n. 18, eadk3452, maio 2024. DOI: 10.1126/sciadv.adk3452. Disponível em:
<https://www.science.org/doi/10.1126/sciadv.adk3452>. Acesso em: 10 nov. 2025.

KE, Guolin et al. *LightGBM*: a highly efficient gradient *boosting* decision tree. In: *Advances in Neural Information Processing Systems*. v. 30, p. 3146-3156, 2017. DOI: 10.5555/3295222.3295409. Disponível em:
<https://proceedings.neurips.cc/paper/6907-lightgbm-a-highly-efficient-gradient-boosting-decision-tree.pdf>. Acesso em: 09 nov. 2025.

KIM, Sihyun; YI, Sangyoon; PARK, Sung-Pil. Prioritizing challenges in AI adoption for the legal domain. *PLOS ONE*, v. 20, n. 6, e0326028, 2025. DOI: 10.1371/journal.pone.0326028. Disponível em:
<https://journals.plos.org/plosone/article?id=10.1371/journal.pone.0326028>. Acesso em: 10 nov. 2025.

KNAFLIC, Cole Nussbaumer. *Storytelling com dados: um guia sobre visualização de dados para profissionais de negócios*. Edição colorida. Rio de Janeiro: Alta Books, 2018.

LAGE-FREITAS, André et al. Predicting Brazilian court decisions. *PeerJ Computer Science*, v. 8, e904, 2022. DOI: 10.7717/peerj-cs.904. Disponível em:
<https://peerj.com/articles/cs-904/>. Acesso em: 09 nov. 2025.

LIMA, Ricardo Massa F. et al. Mineração de processos no Judiciário brasileiro. *Computação Brasil*, Sociedade Brasileira de Computação, abr. 2023, p. 39-43. Disponível em: <https://journals-sol.sbc.org.br/index.php/comp-br/article/view/4061>. Acesso em: 16 out. 2025.

MARK, David; MORISON, John. Governing AI decision-making: balancing innovation and accountability. *Politics and Governance*, v. 13, art. 10245, 2025. DOI: 10.17645/pag.10245. Disponível em:
<https://www.cogitatiopress.com/politicsandgovernance/article/view/10245>. Acesso em: 10 nov. 2025.

MENEZES-NETO, Elias Jacob de; CLEMENTINO, Marco Bruno Miranda. Using deep learning to predict outcomes of legal appeals better than human experts: a study with data from Brazilian federal courts. *PLOS ONE*, v. 17, n. 7, e0272287, 2022. DOI: 10.1371/journal.pone.0272287. Disponível em:
<https://journals.plos.org/plosone/article?id=10.1371/journal.pone.0272287>. Acesso em: 10 nov. 2025.

MIŠIĆ, Jana; VAN EST, Rinie; KOOL, Linda. Good governance of public sector AI. *AI and Ethics*, v. 5, p. 4875-4889, 2025. DOI: 10.1007/s43681-025-00751-3. Disponível

em: <https://link.springer.com/article/10.1007/s43681-025-00751-3>. Acesso em: 10 nov. 2025.

MOLNAR, C.; KÖNIG, G.; BISCHL, B.; CASALICCHIO, G. Model-agnostic feature importance and effects with dependent features: a conditional subgroup approach. *Data Mining and Knowledge Discovery*, v. 38, p. 2903-2941, 2024. DOI: 10.1007/s10618-022-00901-9. Disponível em: <https://doi.org/10.1007/s10618-022-00901-9>. Acesso em: 16 jun. 2026.

OECD. Governing with Artificial Intelligence: Opportunities and Challenges for the Public Sector. Paris: OECD Publishing, 2025. DOI: 10.1787/398fa287-en. Disponível em: https://www.oecd.org/en/publications/2025/06/governing-with-artificial-intelligence_398fa287.html. Acesso em: 09 nov. 2025.

OLIVEIRA, Raphael Souza de et al. Predicting the number of days in court cases using *artificial intelligence*. *PLOS ONE*, v. 17, n. 6, p. 1-21, 2022. DOI: 10.1371/journal.pone.0269008. Disponível em: <https://journals.plos.org/plosone/article?id=10.1371/journal.pone.0269008>. Acesso em: 09 nov. 2025.

PERNICI, Barbara et al. Why are Italian trials taking so long? A process mining approach. In: Conferenza Italiana di Intelligenza Artificiale (Ital-IA), 2023, Pisa, Italy. Proceedings... CEUR Workshop Proceedings, v. 3486, p. 284-289, 2023. Disponível em: <https://ceur-ws.org/Vol-3486/34.pdf>. Acesso em: 09 nov. 2025.

PROVOST, Foster; FAWCETT, Tom. *Data science para negócios: o que você precisa saber sobre mineração de dados e pensamento analítico de dados*. Rio de Janeiro: Alta Books, 2016.

RAINIO, Oona; TEUHO, Jarmo; KLÉN, Riku. Evaluation metrics and statistical tests for *machine learning*. *Scientific Reports*, v. 14, n. 1, art. 6086, 2024. DOI: 10.1038/s41598-024-56706-x. Disponível em: <https://doi.org/10.1038/s41598-024-56706-x>. Acesso em: 10 nov. 2025.

RESCK, Lucas et al. LegalAnalytics: bridging visual explanations and workload streamline in Brazilian Supreme Court appeals. *Artificial Intelligence and Law*, 2025. DOI: 10.1007/s10506-025-09446-w. Disponível em: <https://link.springer.com/article/10.1007/s10506-025-09446-w>. Acesso em: 10 nov. 2025.

RIM, Patrick; LIU, Erin. Optimizing the C4.5 decision tree algorithm using MSD-Splitting. *International Journal of Advanced Computer Science and Applications (IJACSA)*, [S. l.], v. 11, n. 10, 2020. DOI: 10.14569/IJACSA.2020.0111006. Disponível em: <https://thesai.org/Publications/ViewPaper?Code=IJACSA&Issue=10&SerialNo=6&Volume=11>. Acesso em: 09 nov. 2025.

RIZZI, W. et al. Explainable *predictive process monitoring*: a user evaluation. *Process Science*, v. 1, art. 3, 2024. DOI: 10.1007/s44311-024-00003-3. Disponível em:

<https://link.springer.com/article/10.1007/s44311-024-00003-3>. Acesso em: 10 nov. 2025.

RODRÍGUEZ-SALCEDO, Eliana et al. Evaluating AI decision tools in Ecuador's courts: efficiency, consistency, and uncertainty in legal judgments. *Frontiers in Artificial Intelligence*, v. 8, art. 1688209, 2025. DOI: 10.3389/frai.2025.1688209. Disponível em: <https://www.frontiersin.org/articles/10.3389/frai.2025.1688209>. Acesso em: 10 nov. 2025.

ROSENBLATT, M.; TEJAVIBULYA, L.; JIANG, R.; NOBLE, S.; SCHEINOST, D. *Data leakage* inflates prediction performance in connectome-based *machine learning* models. *Nature Communications*, v. 15, art. 1829, 2024. DOI: 10.1038/s41467-024-46150-w. Disponível em: <https://doi.org/10.1038/s41467-024-46150-w>. Acesso em: 16 jun. 2026.

SEMMELOCK, Harald; ROSS-HELLAUER, Tony; KOPEINIK, Simone; THEILER, Dieter; HABERL, Armin; THALMANN, Stefan; KOWALD, Dominik. Reproducibility in machine-learning-based research: overview, barriers, and drivers. *AI Magazine*, v. 46, n. 2, e70002, 2025. DOI: 10.1002/aaai.70002. Disponível em: <https://onlinelibrary.wiley.com/doi/10.1002/aaai.70002>. Acesso em: 26 fev. 2026.

SEVERINO, Antônio Joaquim. *Metodologia do trabalho científico*. 24. ed. revista e atualizada. São Paulo: Cortez, 2016.

SILVA, Katia Cristina Antunes. What Would Karl Popper Say about Jurimetrics? *Law Theory*. *Beijing Law Review*, v. 16, n. 1, p. 107-132, mar. 2025. DOI: 10.4236/blr.2025.161006. Disponível em: https://www.scirp.org/pdf/blr2025161_63302308.pdf. Acesso em: 17 jan. 2026.

SOBRINO, Fernanda; DE UNÁNUE T., Adolfo; HERNÁNDEZ, Edgar; VILLA, Patricia; VILLALOBOS, Elena; AKÉ, David; CISNEROS, Stephany; CAMACHO OSNAY, Cristian Paul; GARCÍA NERI, Armando; HERNÁNDEZ, Israel. Designing AI for Prosecutorial Governance: Case Prioritization and Statutory Oversight in Mexico. arXiv preprint arXiv:2601.00396, 2026. DOI: 10.48550/arXiv.2601.00396. Disponível em: <https://arxiv.org/abs/2601.00396>. Acesso em: 25 maio 2026.

SOON, Hui Fern; AMIR, Amiza; NISHIZAKI, Hiromitsu; ZAHRI, Nik Adilah Hanin; KAMARUDIN, Latifah Munirah; AZEMI, Saidatul Norlyana. Evaluating Tree-based Ensemble Strategies for Imbalanced Network Attack Classification. *International Journal of Advanced Computer Science and Applications*, v. 15, n. 1, p. 1124-1134, 2024. DOI: 10.14569/IJACSA.2024.01501111. Disponível em: <https://thesai.org/Publications/ViewPaper?Code=IJACSA&Issue=1&SerialNo=111&Volume=15>. Acesso em: 16 jun. 2026.

STARCKE, Jonathan et al. The effect of *data leakage* and feature selection on *machine learning* performance for early Parkinson's disease detection. *Bioengineering*, v. 12, n. 8, art. 845, 2025. DOI: 10.3390/bioengineering12080845.

Disponível em: <https://www.mdpi.com/2306-5354/12/8/845>. Acesso em: 09 abr. 2026.

SUJON, Khaled Mahmud et al. Accuracy, precision, recall, *f1-score*, or MCC? empirical evidence from advanced statistics, ML and XAI for evaluating business predictive models. *Journal of Big Data*, v. 12, art. 268, 2025. DOI: 10.1186/s40537-025-01313-4. Disponível em: <https://doi.org/10.1186/s40537-025-01313-4>. Acesso em: 10 nov. 2025.

TIRINK, Sevtap. *machine learning-based forecasting* of air quality index under long-term environmental patterns. *PLOS ONE*, v. 20, n. 10, e0334252, 2025. DOI: 10.1371/journal.pone.0334252. Disponível em: <https://journals.plos.org/plosone/article?id=10.1371/journal.pone.0334252>. Acesso em: 09 nov. 2025.

TRIBUNAL DE JUSTIÇA DE PERNAMBUCO. Instrução Normativa nº 19, de 29 de abril de 2024. Instala a Diretoria Estadual das Varas de Execução Fiscal, Fazenda Pública e Acidentes de Trabalho (DEFFA); dispõe sobre sua organização e funcionamento. Recife: TJPE, 2024. Disponível em: https://portal.tjpe.jus.br/documents/d/portal/instrucao_normativa-n-19-2024-1-pdf. Acesso em: 20 jan. 2026.

TRIBUNAL DE JUSTIÇA DE PERNAMBUCO. Resolução nº 505, de 18 de setembro de 2023. Regimento Interno da Ouvidoria-Geral do Tribunal de Justiça de Pernambuco. Recife: TJPE, 2023. Disponível em: <https://portal.tjpe.jus.br/documents/56904/57727/RIOG+-+Resolu%C3%A7%C3%A3o+n%C2%BA+505+de+18+de+setembro+de+2023.pdf>. Acesso em: 25 out. 2025.

TURBAN, Efraim; SHARDA, Ramesh; DELEN, Dursun. *Business intelligence e análise de dados para gestão do negócio*. 4. ed. Porto Alegre: Bookman, 2019.

UNGER, Adriana Jacoto et al. Process mining-enabled jurimetrics: analysis of a Brazilian court's judicial performance in the business law processing. In: INTERNATIONAL CONFERENCE FOR ARTIFICIAL INTELLIGENCE AND LAW (ICAIL), 18., 2021, São Paulo. Proceedings of the 18th International Conference for Artificial Intelligence and Law. New York: ACM, 2021. p. 240-244. DOI: 10.1145/3462757.3466137. Disponível em: <https://dl.acm.org/doi/10.1145/3462757.3466137>. Acesso em: 15 abr. 2026.

UNIÃO EUROPEIA. Regulamento (UE) 2024/1689 do Parlamento Europeu e do Conselho, de 13 de junho de 2024, que estabelece regras harmonizadas em matéria de inteligência artificial e altera os Regulamentos (CE) n.º 300/2008, (UE) n.º 167/2013, (UE) n.º 168/2013, (UE) 2018/858, (UE) 2018/1139 e (UE) 2019/2144 e as Diretivas 2014/90/UE, (UE) 2016/797 e (UE) 2020/1828. Jornal Oficial da União Europeia, L 2024/1689, 12 jul. 2024. Disponível em: <https://eur-lex.europa.eu/eli/reg/2024/1689/oj/por>. Acesso em: 10 nov. 2025.

VAN DER AALST, Wil M. P.; CARMONA, Josep (org.). *Process mining handbook: fundamentals, techniques, applications, and tools*. Cham: Springer Nature, 2022. DOI: 10.1007/978-3-031-08848-3. Disponível em: <https://link.springer.com/book/10.1007/978-3-031-08848-3>. Acesso em: 25 out. 2025.

VERÇOSA, Luiz; SILVA, Vinícius; CRUZ, Jaqueline; BASTOS-FILHO, Carmelo; BEZERRA, Byron L. D. Investigation of lawsuit process duration using *machine learning* and process mining. *Discover Analytics*, v. 2, art. 9, 2024. DOI: 10.1007/s44257-024-00015-0. Disponível em: <https://link.springer.com/article/10.1007/s44257-024-00015-0>. Acesso em: 10 nov. 2025.

VOM BROCKE, Jan; GAU, Michael; MÄDCHE, Alexander. Journaling the design science research process: transparency about the making of design knowledge. In: CHANDRA KRUSE, L.; SEIDEL, S.; HAUSVIK, G. I. (org.). *The next wave of sociotechnical design. DESRIST 2021. Lecture Notes in Computer Science*, v. 12807. Cham: Springer, 2021. p. 131-136. DOI: 10.1007/978-3-030-82405-1_15. Disponível em: https://link.springer.com/chapter/10.1007/978-3-030-82405-1_15. Acesso em: 10 nov. 2025.

WATAMURA, Eiichiro et al. Judges versus *artificial intelligence* in juror decision-making. *PLOS ONE*, v. 20, n. 1, e0318486, 2025. DOI: 10.1371/journal.pone.0318486. Disponível em: <https://journals.plos.org/plosone/article?id=10.1371/journal.pone.0318486>. Acesso em: 10 nov. 2025.

WHEELAN, Charles. *Estatística: o que é, para que serve e como funciona*. 1. ed. Rio de Janeiro: Zahar, 2016. ISBN 9788537815120.

ZUIDERWIJK, Anneke; CHEN, Yu-Che; SALEM, Fadi. Implications of the use of *artificial intelligence* in public governance: a systematic literature review and a research agenda. *Government Information Quarterly*, v. 38, n. 3, 101577, 2021. DOI: 10.1016/j.giq.2021.101577. Disponível em: <https://www.sciencedirect.com/science/article/pii/S0740624X21000137>. Acesso em: 09 nov. 2025.